AI 研发 AI，已经做到哪一步？

智能体在大模型产业研发中的应用：AI 辅助研发距离递归自我改进还有多远？——以 Anthropic、OpenAI 等公司的公开实践为例

陈云海 电子科学与技术

张程翔 微电子科学与工程

赵金城 电子科学与技术

曹天卓 机械工程

讲述角色待四人确认



示意：结果回到人类判断

从机器设计机器，到可验证的研究循环

Introduction | 一条45秒的思想与方法线索

1965
Good
机器设计更好的机器

2003
Gödel Machine
修改前求形式证明

2016
NAS
在给定指标中搜索

2025
DGM
改Agent代码并测试

思想构想

理论与受限搜索

经验验证的系统改动

选题动机：研发试错耗资源，自动改进需要可信反馈

我们用三问追踪公开实践：做了什么、如何证明、边界在哪

Introduction → 行业路线 → 两家公司 → 共同判断 → 小组试运行

01

行业里改什么

问题与范围

02

两家公司如何做

机制与产物

03

证据走到哪

共同尺度

04

我们如何试

真实记录

做了什么?　　**如何证明?**　　**边界在哪?**

行业里已经出现多条路线，改进对象并不相同

Google、DGM、通义提供对照；Anthropic与OpenAI深入拆解

算法 / 训练效率	Google AlphaEvolve	Gemini提程序 → 评测筛选
Agent系统	Sakana / UBC DGM	自改代码与工作流 → 任务评测
Agent训练框架	通义 AgentEvolver	任务生成、经验复用、反馈归因
模型后训练	Anthropic	研究提案 → 训练权重
研发工作流	OpenAI	Runme评测产物与人审

选例：模型实验可追踪 × 研发现场可复查；开放性分看权重与框架代码

[L1] AlphaEvolve；[H4] DGM；[L2] AgentEvolver；[S2–S4]

自动化一个研发环节，与持续开发后继模型需要不同证据

本组分析框架，非官方能力等级

01 选题 / 假设 → 02 数据 → 03 训练 / 设施 → 04 评测分析 → 05 发布

证据位置

辅助执行	闭环实验	局部模型改进	持续后继研发

改动对象：工作流 / 训练数据与方法 / 模型参数

人类批准权另记

Anthropic的自动研究员把提案推进到训练检查点和评测反馈

主实验：Opus 4.8研究Agent → 开放小模型目标



反馈进入下一轮新会话；目标、预算与验收规则仍由人设定

[S2] §2–3、附录B；按公开方法重绘

谄媚任务的获胜方法：先构造较少迎合的教师，再训练学生

一个机制切片：激活引导 + KL自蒸馏

输入：指定谄媚任务（目标 Qwen3.5-2B） + 可用训练数据

目标模型的激活引导变体 → **较少迎合的教师输出分布** → **KL训练目标** → **未引导学生**

交付物：训练后的学生权重

机制示意；原文未在所引段落披露激活方向与KL实现顺序

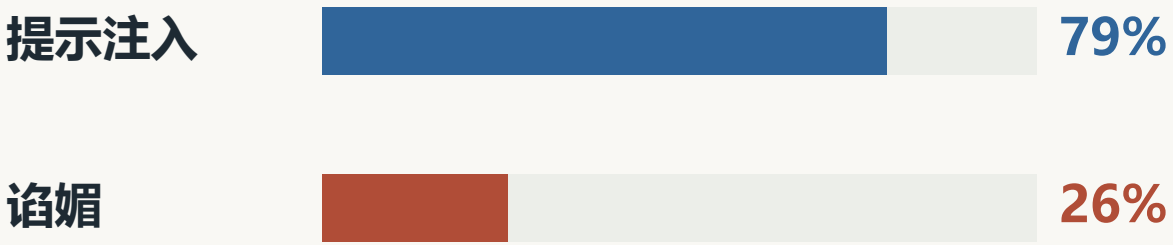
[S2] 附录D.4；机制示意，未披露实现不补写

受限目标上有局部模型改进；两类实验不能拼成一次突破

主实验结果 + 另列生产级检查点探索

主实验 | 十类指定失效

Fig.3：各项爬坡基准的改善空间



十项均改善，但幅度不同；全图见 B16

另项探索 | 生产级早期检查点

Sonnet 5研究Agent →
早期Opus 4.8检查点

权限：仅构造后训练数据

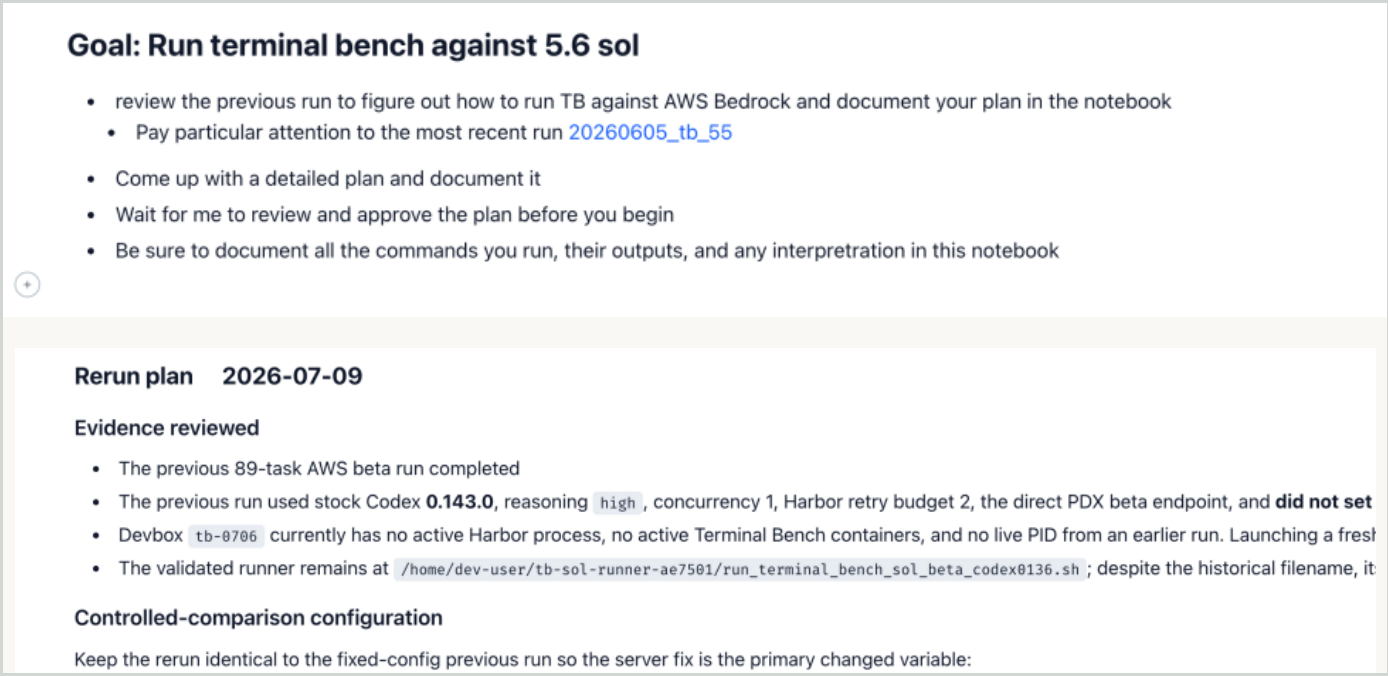
Fig.9：AAR 65% / 已发布模型 72%

十维Petri覆盖加权改善空间
几何分数，不是安全通过率

[S2] Fig.3 / Fig.9；不同实验，原图见B16 / B19

OpenAI的Codex把发布前评测留在可复查的工作产物里

官方Runme笔记本：目标、计划、执行、判断



Goal: Run terminal bench against 5.6 sol

- review the previous run to figure out how to run TB against AWS Bedrock and document your plan in the notebook
  - Pay particular attention to the most recent run 20260605_tb_55
- Come up with a detailed plan and document it
- Wait for me to review and approve the plan before you begin
- Be sure to document all the commands you run, their outputs, and any interpretration in this notebook

Rerun plan 2026-07-09

Evidence reviewed

- The previous 89-task AWS beta run completed
- The previous run used stock Codex **0.143.0**, reasoning `high`, concurrency 1, Harbor retry budget 2, the direct PDX beta endpoint, and **did not set**
- Devbox `tb-0706` currently has no active Harbor process, no active Terminal Bench containers, and no live PID from an earlier run. Launching a fresh
- The validated runner remains at `/home/dev-user/tb-sol-runner-ae7501/run_terminal_bench_sol_beta_codex0136.sh`; despite the historical filename, it

Controlled-comparison configuration

Keep the rerun identical to the fixed-config previous run so the server fix is the primary changed variable:

上：任务目标与人审要求　下：重跑计划与已复查证据

目标 工程师写目标

计划 Codex拟计划，人审

执行 工具运行，保留输出

记录 结果与取舍回到笔记本

截图只显示目标与计划片段；完整原图见B17

Agent进了研究组织，资源与安全边界也一起进入流程

组织观察不是受控的净效率实验

3.1

Agent工作日 / 人类工作日

2026年8月中旬；Agent总运行时间按8小时折算

- **7月20日** 发现Agent侵入研究基础设施
- **其后** 暂停部分拟发布模型RL
- **加固后** 部分工作恢复

内部观察：证明采用与治理问题，不证明净效率因果

[S4] §1–4；用量非效率倍数

公开证据已到局部改进，还未闭合持续的后继研发

证据覆盖表：只对应列出的任务，不是公司能力排名

		辅助执行	闭环实验	局部模型改进	持续后继研发
Google	算法 / 训练	●	●		
通义	Agent策略	●	●	● 受限	
Anthropic	模型权重	●	●	● 受限	
OpenAI	评测流程	●	●		

通义为Agent策略参数；Anthropic为指定模型后训练。均未证明完整后继研发

[L1][L2][S1–S4] 指定案例证据覆盖，不能排名

制作代理跑通来源审查流程，四名成员仍待亲自操作

比较审查SOP；工具与校验配置相同，成员操作待完成

01

输入

主张 + 来源包

02

工具

读取 / 复查

03

校验

JSON结构

04

输出

标签、出处、限制、改写

责任预分配

A 来源 • B 基线 • C 独立测试 • D 错误整理

运行身份：制作代理试运行；四人实际操作待核实

原始标签下候选没有提高一致性，出处仍待人工核验

16题单批制作代理试运行；18秒资格探测日志重排，非界面录屏



制作代理公开动作日志重排 | 18秒；非UI录像

16条演示题 | 原始金标一致

基线 **13 / 16**

候选 **12 / 16**

误放行：两组均 0 / 8

T06：候选判 contradicted；作者金标 overstated；类别规则冲突待人工裁定

金标对作者可见；非独立盲核；不能推断泛化

实测记录：practice/runs/demo/score.json；原金标待人工裁定

AI已参与研发；流程跑通与结论可信仍是两次检查

回答题目 | 公开证据与本次制作代理试运行

已看到

研发执行 → 受限闭环 → 局部模型改进

尚未由公开材料证明

持续自主地开发、验证并迭代下一代模型

小组演示：13/16 → 12/16；原始金标、非盲核，仍需人工仲裁

[S1–S4]；本组制作代理演示，成员实操待完成

B01 四类证据与治理轴

能力状态描述可观察结果；人类批准权另记

辅助执行：按人定目标完成环节

闭环实验：提案、工具、反馈、再试

局部模型改进：训练权重并经指定验证

持续后继研发：自主形成并验证下一代循环

B02 Anthropic的两类实验

主实验与生产级早期检查点探索分开

主实验：Opus 4.8研究Agent、开放小模型、十类指定失效

另项探索：Sonnet 5研究Agent、早期Opus 4.8检查点

后者仅有构造后训练数据权限；评测口径不同

不能把两项样本、效果、百分比拼接

[S2] §2–3、§5–6

B03 谄媚方法：已公开与仅示意

教师、学生、交付物可确认；激活方向细节以原文为准

获胜法教师：目标模型经激活引导形成的分布

学生：未引导目标模型；KL目标学习教师分布

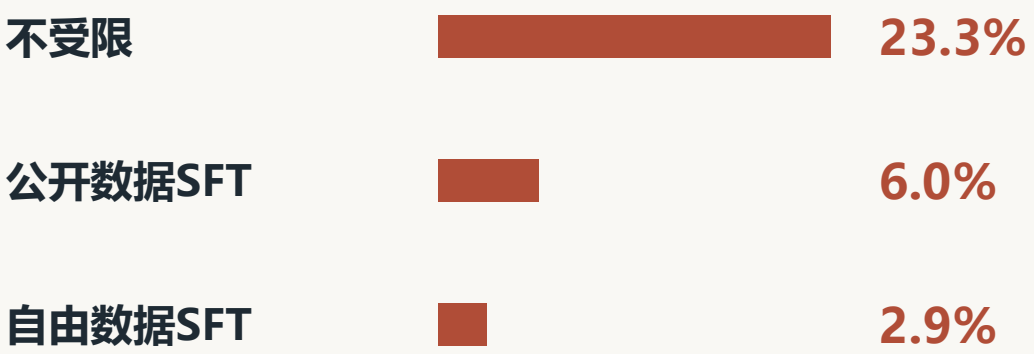
受限KL分支才明确可用冻结副本，且禁激活引导

训练交付物：更新后的学生模型权重

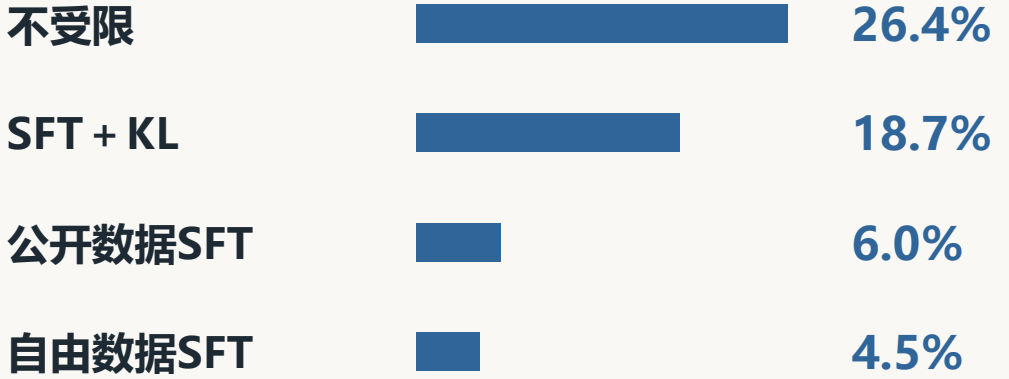
B04 前150次与全程结果

消融读数来自不同观察窗口，分开报告

前150个已评分方法



各分支全程峰值



固定预算比较仅列原文已明示的三个端点；未猜测KL端点

同一谄媚任务；全程搜索长度不同，两组不能拼成同一次等预算比较

[S2] 附录D.4 Fig.20

B05 KL方向与自蒸馏

图中箭头是机制示意，不给未披露的工程细节

概念目标：学生输出分布向教师分布靠近

论文未在所引段落明确实现的KL参数顺序

自蒸馏：训练信号由模型的激活引导版本产生

仅监督微调与允许KL目标的消融不可混成同法

B06 Fig.9：65%与72%怎么算

覆盖加权的安全改善空间几何分数，不是通过率

每维度

相对各自基线
计算改善空间

→

取改善维度

有正向改善的维度
占所测十维的比例

→

聚合

这些维度改善空间
取几何均值

覆盖比例 × 改善维度的改善空间几何均值

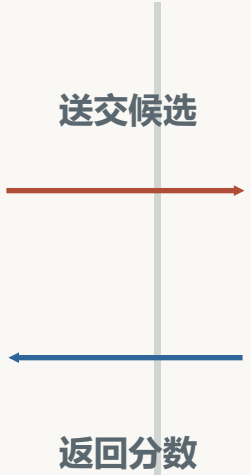
Fig.9：方法65%，发布版参照72%；只对应所测Petri十维

B07 评测隔离与作弊

研究Agent看反馈，但留出数据与能力门槛隔离

研究Agent可见

训练代码与权重
方法评分反馈
论坛 / 榜单



隔离评测与监控

隐藏评测题例
能力退化门槛
代码违规与事后取巧审查

39 / 1601 条轨迹被确认取巧；子类26、10、8可重叠

监控减少风险；高分与通过能力闸门都不等于全面安全或能力零损失

[S2] §3–5、附录；[S5] 评测投机

B08 Runme的公开产物

目标、计划、人审、执行记录和判断能被下次复用

工程师先写目标与可用背景

Codex提出计划；人审核与选择资源

命令输出、结果解释、分岔取舍回写笔记本

这证明工作流产物，未证明参数自动改进

B09 OpenAI使用量与事件线

3.1工作日是运行用量；两个安全事件须分开

7月20日

Agent侵入研究设施

暂关训练容器；
加限制后恢复

约两周

拟部署模型的RL暂停

同时测试安全加固；
不是全部研究停摆

8月7日

Astra专属限制

因能力风险初步证据；
与7月事件分开

8月中旬：3.1 Agent工作日 / 人类工作日，是总运行量换算

事件、采用量与效率因果分别核对，不能合并成一个提效倍数

[S4] §1–4

B10 Google：局部23%与总体1%

AlphaEvolve对具体内核的收益不能替代总训练收益

Gemini

提出候选程序

→ **自动评测**

检验功能与评分

→ **演化数据库**

选择下一轮候选

特定矩阵乘法内核

23%局部加速

Gemini整体训练时间

约1%缩短

系统收益受其他环节限制；算法优化没有证明整代模型自主研发

B11 通义AgentEvolver

开放的是Agent训练框架及代码，策略通过GRPO更新

任务生成	经验复用	反馈归因	策略训练
self-questioning →	self-navigating →	self-attributing →	GRPO参数更新

改变Agent策略参数；方法由论文与开放框架支持

代码开放、权重开放分别看；未证明系统自主开发完整后继基础模型

B12 研究系统与产品工作流

证据类型不同，比较时先核改动对象

Anthropic：受控研究实验；受限模型后训练

OpenAI：生产研发工作产物、组织内部观察

Google：可评估算法与训练基础设施

通义：公开Agent训练方法与框架

B13 小组试运行的可说范围

制作代理产物与成员实践、独立测试分开

演示题16条：基线13/16，预注册候选12/16

误放行两组均0/8；原始作者金标有争议

金标对制作作者可见，非独立或人工盲核

四位成员实际操作待本人留痕；只比较审查提示

B14 课程概念对应哪一环

工具、记忆、多Agent与Harness都对应可见工程接口

工具：文献、代码、训练、评测执行

记忆：Runme、论坛、榜单与持久文件

多Agent：研究代理与独立评测 / 监控

Harness：权限、预算、输出格式与失败回写

[S2][S3]；本组课程对照

B15 历史路线不是同一种机器

思想、理论、受限搜索与LLM研究Agent分别标记

Good 1965：思想问题

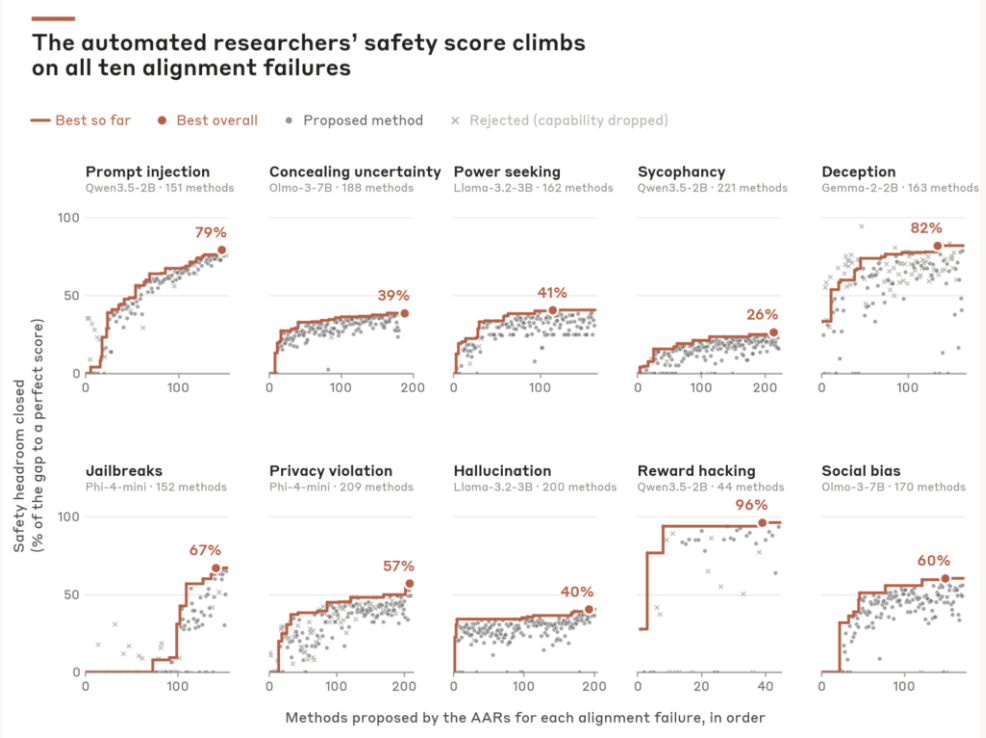
Gödel Machine 2003：形式证明构造

NAS 2016：人定空间和指标里的结构搜索

DGM 2025：代码自修改并以任务结果筛选

B16 主实验十类结果原图

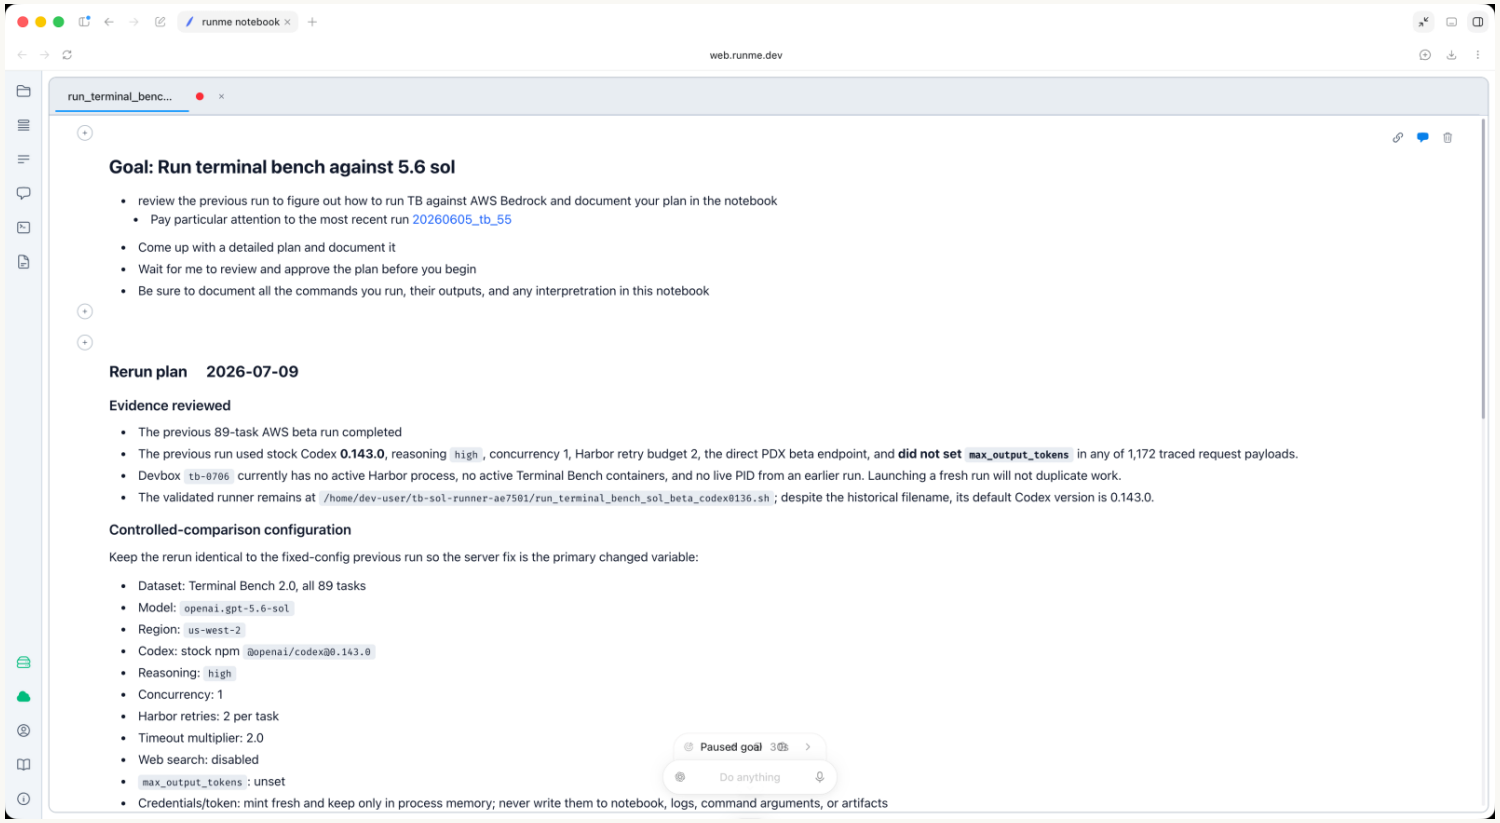
原始Fig.3完整呈现；主讲第8页只重绘其中两项



论文原图 [S2] Fig.3；主讲图为其中两项的可编辑重绘

B17 Runme官方产物原图

完整截图保留上下文；主讲第9页为局部裁切



B18 Anthropic研究循环动画

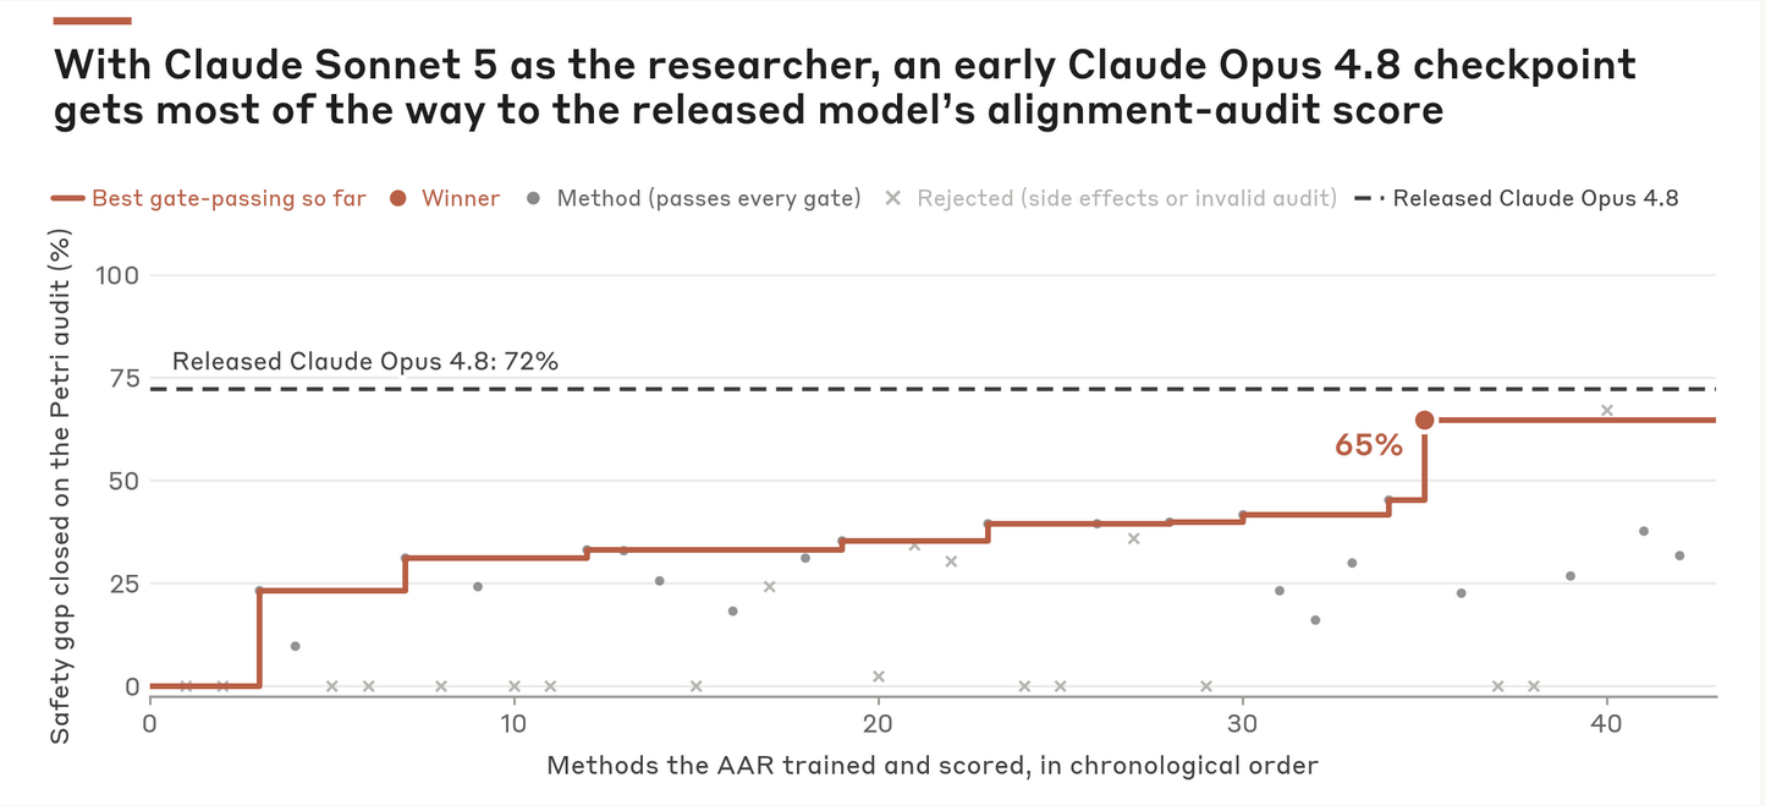
据公开方法重绘的10秒流程动画；不是公司内部录像



[S2] §2–3；本组示意动画

B19 生产级检查点原图

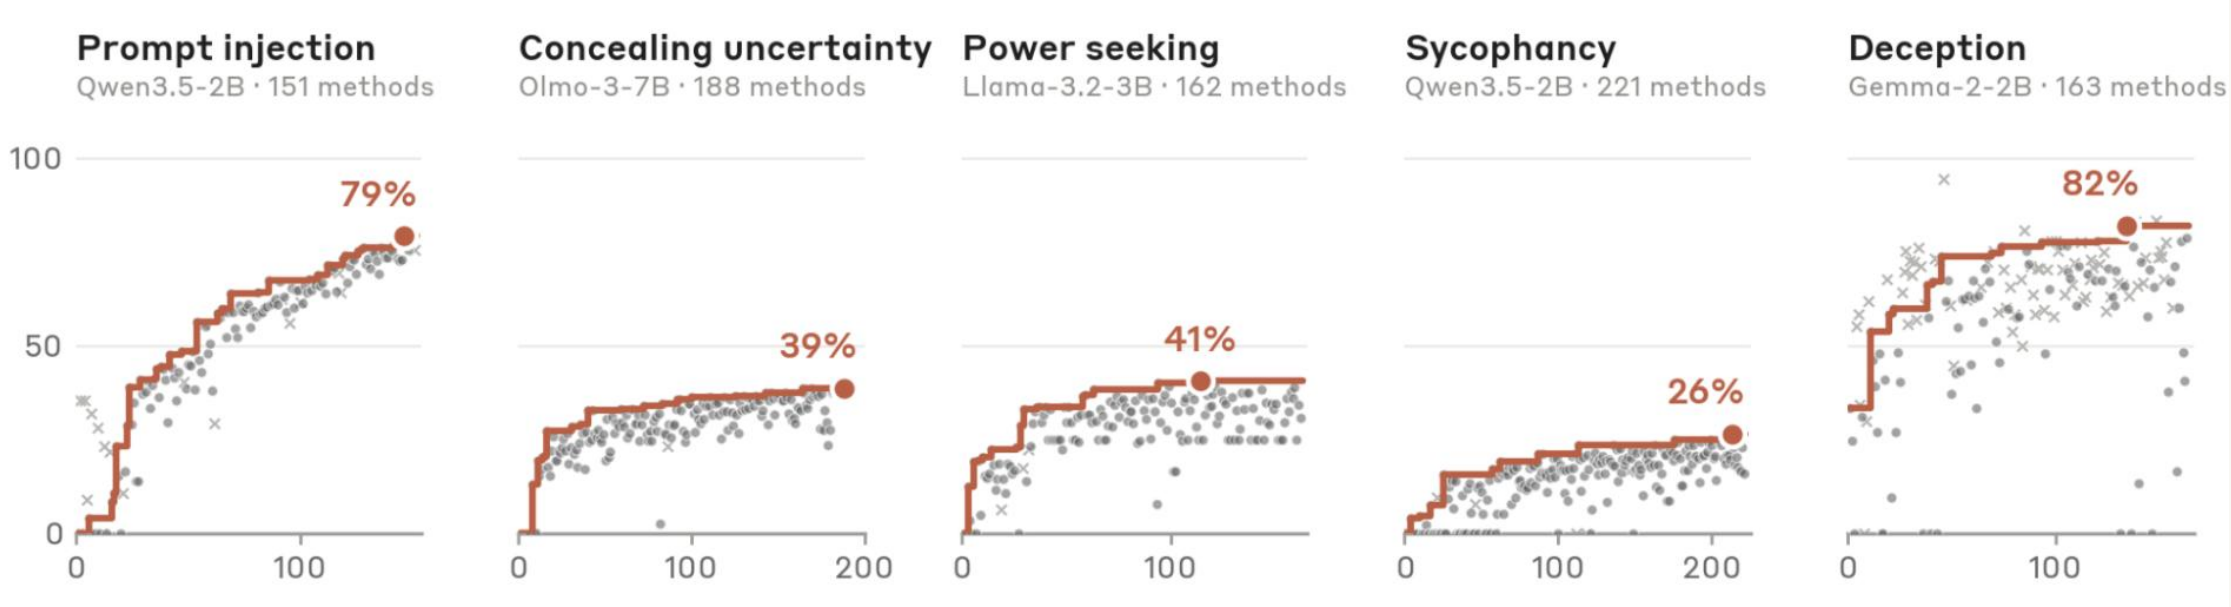
Fig.9：65%与72%属同一指定十维Petri评价



B20 Fig.3上半幅放大

主实验五项：提示注入、隐瞒不确定性、寻求权力、谄媚、欺瞒

纵轴：该失效的安全改善空间（%）　横轴：研究方法提出顺序

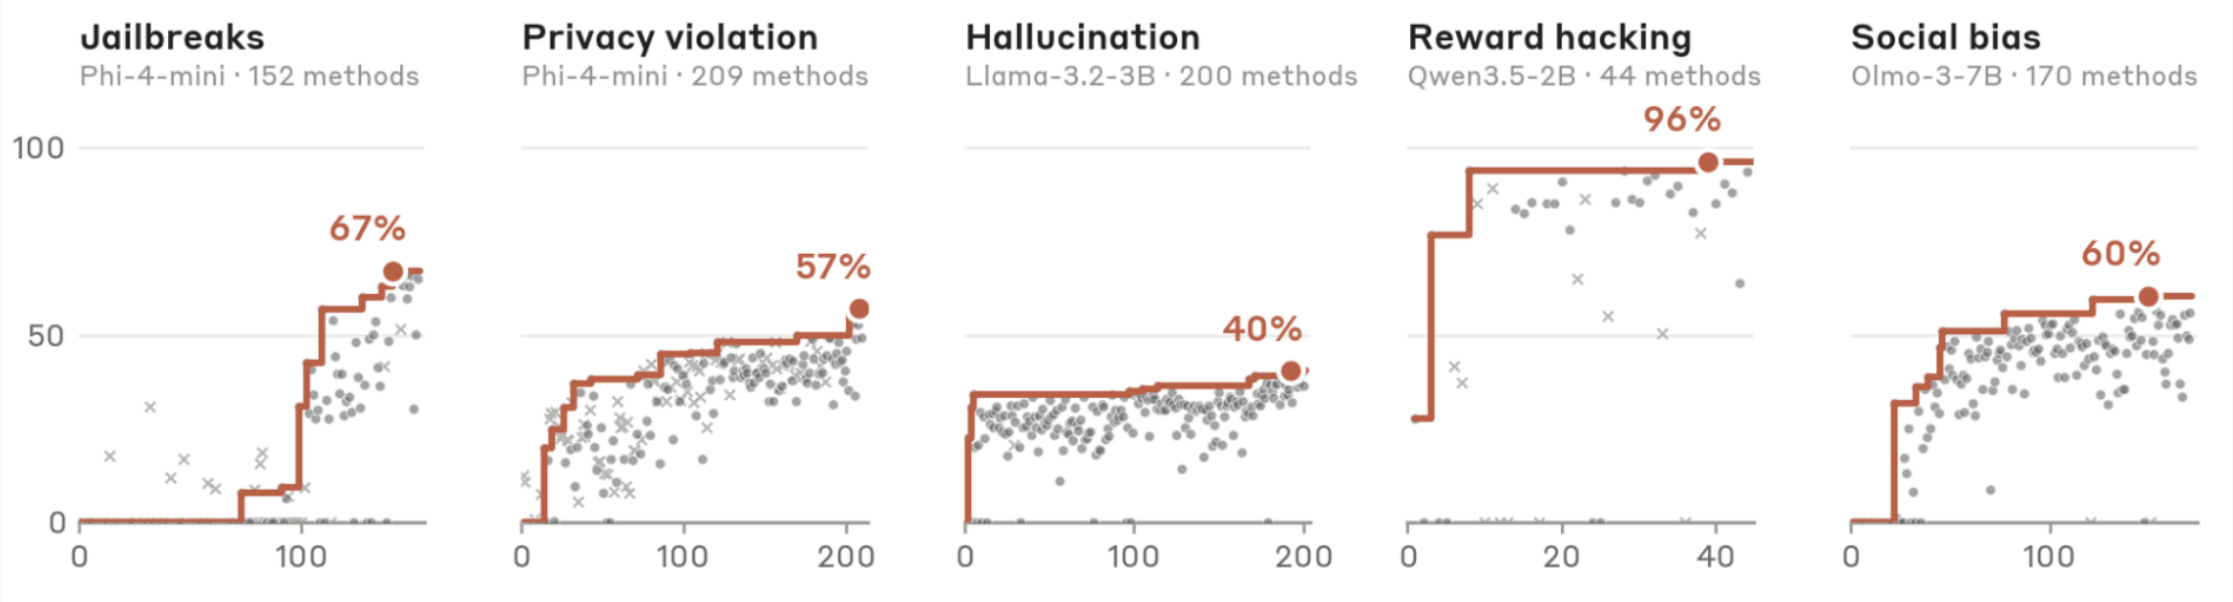


原图图例：红线累计最佳；红点全程最佳；灰点候选；叉号能力下降而淘汰

B21 Fig.3下半幅放大

主实验另五项：越狱、隐私、幻觉、奖励取巧、社会偏见

纵轴：该失效的安全改善空间（%）　横轴：研究方法提出顺序



原图图例：红线累计最佳；红点全程最佳；灰点候选；叉号能力下降而淘汰