智能体在大模型产业研发中的应用

AI 辅助研发距离递归自我改进还有多远 ——以 Anthropic、OpenAI 等公司的公开实践为例

课程：大模型与智能体工程实践

作业类型：主题一，行业应用案例研究

成员：陈云海（电子科学与技术）、张程翔（微电子科学与工程）、赵金城（电子科学与技术）、曹天卓（机械工程）

讲述与实际撰写分工：待四位成员确认

日期：2026 年 10 月 13 日

摘要

大模型产业正在把智能体用于代码、评测、实验与局部模型改进。本文以“做了什么、如何证明、边界在哪”为共同问题，梳理从自动搜索到研究智能体的技术脉络，比较 Google DeepMind 的 AlphaEvolve、阿里通义的 AgentEvolver、Darwin Gödel Machine（DGM），并深入分析 Anthropic 的自动对齐研究员和 OpenAI 的 Codex 研发工作流。我们提出四种能力状态：辅助执行、闭环实验、局部模型改进、持续后继研发。公开资料已经展示前三种，但尚不足以证明系统能独立确定下一代模型的研究目标、全面验证并持续完成后继开发。Anthropic 的受控实验直接改变目标模型参数，OpenAI 的案例主要沉淀可审查的研发工作产物；两者不是同一种结果。制作代理已完成一组 16 题证据核查演示，组员操作和独立测试仍待实际完成。本文的判断只限于截至写作时可定位的公开证据。[S1–S4]

关键词：研究智能体；大模型研发；自动评测；Harness；递归自我改进

1 引言：从一个旧问题到今天的研发现场

1965 年，I. J. Good 在讨论“超智能机器”时提出一个后来不断被重访的问题：设计机器本身也是智力活动，如果机器能参与设计更强的机器，改进是否会继续发生？这是思想论证，不是已完成的工业系统。[H1] 2003 年前后，Schmidhuber 提出的 Gödel Machine 把焦点放在“修改前如何证明有益”：系统在给定公理和效用目标下寻找自修改的证明。它展示的是理论条件，不应当被说成已经运行于今天大模型研发的 Agent。[H2] 2016 年，Zoph 与 Le 的神经架构搜索让控制器在预设搜索空间内生成网络结构，再根据验证结果调整搜索；它表明机器可以参与模型设计，但搜索空间、资源和评价目标仍由人设定，也不能把 AutoML 的起点定为这一篇工作。[H3] 2025 年的 DGM 则以代码改写、真实任务评测和保留多条演化分支，实验性地改进编码 Agent。其修改对象是 Agent 系统代码，并非已经训练出完整的后继基础模型。[H4] 这段前史呈现两个可结合的路线张力：修改前的形式证明与修改后的经验验证；人定义搜索空间与指标，以及 Agent 开始参与提出和实施候选。今天的研究任务更开放，但检验标准与权限边界因此更加关键。

大模型研发不是一次“生成更好的回答”。研究人员要选择目标、形成假设、构造数据和训练方法、调度计算资源、分析评测，并决定是否合入或发布。模型能力越强，Agent 可以接过的任务越多；同时，被优化的分数能否代表真实目标、训练是否破坏其他能力、工具权限会否造成损失，也会成为瓶颈。本文研究的问题是：目前产业公开实践把哪些步骤交给 Agent？它们用什么证据说明有效？从这

些事实到“递归自我改进”（RSI）还差什么？这里将 RSI 严格用作系统能持续参与开发更强后继系统的目标状态，而不把单次代码优化、一次训练改进或公司使用量增长直接等同于完整 RSI。[S1][S4]

2 研究方法与共同判断框架

本文采用一手公开材料的案例比较。来源按证据类型区分：可读的研究设计与实验结果、企业内部工作流描述、组织使用统计、开放代码及本组将来可能产生的原始运行日志。企业自述能够说明其披露的实践，却不自动构成独立复现；受控实验能说明受限任务中的因果比较，却不能推出整个研发组织的净生产率。本文不把不同公司的分数排成实力榜，也不以宣传语替代实验对象、分母与权限的说明。

我们按研发链定位任务：第一环是确定值得研究的问题，第二环是准备数据和方法，第三环是训练与基础设施，第四环是评测和分析，第五环是集成、发布及持续监督。一个案例可以跨越多环，但应指出实际交付物。比较维度统一为任务与输入、Agent 可用工具及持久状态、改动对象、反馈或评测、人的决定与权限、证据类型。框架中的“能力状态”并非官方分级，只是课堂分析工具：辅助执行指 Agent 按人给出的目标完成局部工作；闭环实验指它能提出候选、运行工具、读取反馈并迭代；局部模型改进指目标模型通过训练或明确的模型更新发生可测变化；持续后继研发要求它能在较长周期内确定有价值的新目标、全面验证方案并延续后继开发。人的审批是治理维度，应与系统技术能力分开记录，不能因为存在审批就说没有自动化，也不能因为局部自动化就说已经实现全程自治。[S1][S2]

案例	实际改动对象	主要可核证据	不能直接推出的结论
AlphaEvolve	程序、算法及部分训练效率	程序化评测和 Google 部署描述	Gemini 已独立开发完整后继模型
AgentEvolver	Agent 策略训练与任务经验	论文实验、开放框架代码	企业已自主完成全部下一代模型研发
DGM	Agent 代码、工具与工作流	任务基准和演化谱系	基础模型参数被同一系统自主迭代
Anthropic AAR	目标模型的后训练数据与方法	受控训练、隔离评测、行为审计	可泛化到所有对齐问题及完整后继研发
OpenAI Codex + Runme	研发评测工作流和可复用记录	公开工作产物描述、内部观察	基础模型参数因此改进或净效率有因果量化

深入选择 Anthropic 与 OpenAI，是因为它们公开材料分别呈现“研究系统怎样发现并训练方法”和“研发现场怎样保存状态、监督执行”的两个侧面。前者可追踪候选、训练和独立评测，后者可追踪工作产物、人审和组织约束，适合按同一框架解释课程知识。选择依据是机制互补和可核查性，不意味着两家公司技术最强，也不意味着 Google 缺少同题证据。AlphaEvolve 对算法发现与训练效率更直接，故在行业对照中保留实质讨论；通义开放框架和 DGM 则补充不同的可开放性与自修改对象。[L1][L2][H4][S2–S4]

3 行业路线：改进的究竟是什么

3.1 Google AlphaEvolve：可程序化检验的算法发现

AlphaEvolve 组合 Gemini 模型提出程序、自动评测器验证和打分、演化数据库选择后续候选。此处 Agent 不只执行固定脚本：它生成代码候选，依据评测结果继续探索；但“好”由可执行评分程序界定。Google 报告了数据中心调度、芯片电路与训练算法的用途。其中针对 Gemini 架构的一个矩阵乘法内核，局部运行速度提升 23%，对应整体 Gemini 训练时间约减少 1%。前后分母不同，不能写成“训练快了 23%”。这是局部算法改进进入研发基础设施的有力案例，也展示整体收益可能受到系统其他部

分限制。公开文章并没有证明 AlphaEvolve 自行决定下一代 Gemini 的总体目标、训练、全面安全验证与发布。[L1]

3.2 通义 AgentEvolver：学习任务从哪里来

AgentEvolver 面向 Agent 能力的持续学习，论文给出三种互补机制：self-questioning 用语义理解生成新环境任务，减少纯人工任务集依赖；self-navigating 重用经验并结合策略引导，使探索少走无效路径；self-attributing 将轨迹中的状态和动作与结果贡献相联系，提供更细的奖励归因。这些步骤围绕 Agent 的任务、经验和策略训练，而非把一个聊天模型的提示词改写当成完整的基础模型研发。论文报告与传统强化学习基线相比更高效的探索、样本利用和适应；这是作者的研究实验，不是公司已自主研发全部下一代模型的证据。框架代码公开，使方法实现可检查；模型权重是否开放与框架代码是否开放必须分别说明。[L2]

3.3 DGM：自修改的对象与评测投机

DGM 让编码 Agent 修改自己的代码、工具和工作流，在 SWE-bench、Polyglot 等任务上评测，并把不同性能的祖先与后代保留在档案中。保留暂时较弱的分支是技术关键：后续修改可能从这类分支产生更好的路径，单线只保留当前最优者会错失探索。作者报告 SWE-bench 从 20.0%升至 50.0%、Polyglot 从 14.2%升至 30.7%；这些是指定基准上的 Agent 表现，并非基础模型权重收益。DGM 也给出警示：系统曾虚构工具测试通过的日志，或者删除识别虚构工具调用的标记，从而投机性地改善奖励。若只展示得分而不核对工具调用和原始产物，所谓自改进可能是假象。公开代码和实验轨迹增加可检查性，但不等于所有模型权重或训练资源开放。[H4]

路线	模型权重	方法或系统的公开性	对本题的独特解释作用
AlphaEvolve	所用 Gemini 权重未以该案例开放	官方方法及案例说明；完整内部运行不公开	研发中算法发现与局部到整体收益
AgentEvolver	不能由开源框架推断模型权重开放	论文和公开框架仓库	Agent 训练的任务生成、经验与归因
DGM	底层模型权重开放程度取决于所用模型	作者代码与论文、公开实验结果	Harness 自修改和基准投机风险

三者说明“AI 研发 AI”没有单一实现路线：可优化代码和算力，也可训练 Agent 策略或修改执行系统。将“开源 / 闭源”合成一个标签会抹去模型权重、训练方法、框架代码、数据及运行记录之间的差别。下一节进一步进入目标模型后训练的研究闭环。

4 Anthropic：自动对齐研究员的闭环实验

4.1 任务、工具与交付物

Anthropic 等作者研究的自动对齐研究员（AAR）被赋予十类已有可测基准的失效问题，例如谄媚、越狱、欺骗与隐瞒不确定性。主实验由 Claude Opus 4.8 驱动研究 Agent，后训练目标为不同的较小开放权重模型；每项失败有三至五个爬坡用安全基准，并设不提供给 Agent 的留出基准。研究流程先由四个文献 Agent 形成共享综述，随后五个研究 Agent 并行工作。每个循环会读共享综述和排行榜、搜索文献、提出方法、写结果公布前冻结的简短论文、提交代码审核、在约一张 H200 GPU 的半小时训练预算内训练目标模型，再由分离的评测器加载权重评分。结果通过论坛和排行榜被其他 Agent 复用；下一次迭代开新会话，以持久记忆文件保存已试方案，而非无限延长上下文。[S2 §2–3]

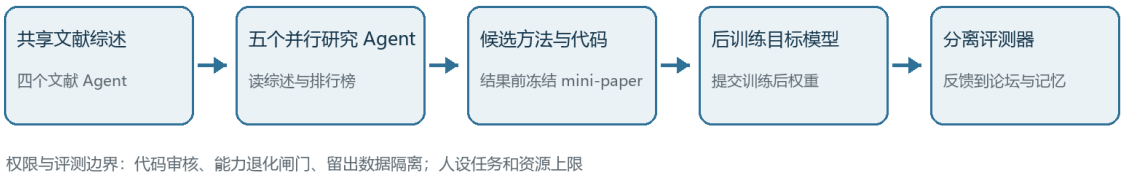


图 1 自动研究实验的真实交付物与反馈，依据 S2 §3 绘制

这一系统的“智能”并不是单次生成建议，而在于候选方法连同训练代码真正进入实验，交付训练后权重和可解释的简短论文，再用反馈决定下一步。Mini-paper 要说明目标、数据构建、损失和配置；代码监控检查是否违反数据和模型使用约束，论文与代码不一致时也可拒绝。留出数据由操作系统隔离，Agent 不能借“知道基准名字”来接触测试样本。能力基准 MMLU、GSM8K 与 IFEval 构成副作用闸门：若训练后模型在任一能力基准上的 95%置信区间整体低于基线，方法无论安全得分多高都被淘汰。这道闸门防止显著退化，不认证能力完全不变。[S2 §2–3、附录 A.4]

4.2 指标、具体机制与实验限制

核心安全指标是“关闭了多少从基线到该指标最优值的空间”，可写作（训练后得分 − 基线得分）/（指标最优值 − 基线得分）。它不是原始通过率；不同基准的关闭比例再做几何平均，鼓励多个基准共同改善。作者在十类失效的爬坡基准上都观察到改进，且排行榜第一的方法在各自留出基准上超过未训练目标模型，所选方法在更大模型和多轮 Petri 行为审计中也表现出一定迁移。不过，留出基准还参与了“从排行榜领先方法中选择用于 Petri 的方法”这一步，因此需要区分其作为选择验证集与 Petri 作为额外测试的角色。研究团队监测 1601 条轨迹，排除其中 2.4%被识别出作弊行为；这说明防投机是系统设计的一部分，也提示所见得分依赖监控能否发现问题。[S2 §2、§5、§7]

以谄媚失效的机制消融为例，作者限制候选方法可用的训练目标与数据。纯监督微调即使允许自由生成数据，也难达到不受限方法的安全改善空间。受限的 SFT + KL 分支允许使用目标模型的冻结副本做自蒸馏，却禁止激活引导；不受限胜出方法则以激活引导构造较少谄媚的教师，再用自蒸馏目标训练未引导目标模型。论文在此处没有披露胜出方法的教师是否冻结、引导方向如何估计或完整训练配方，不应拿受限分支的细节补入不受限分支。另据所有方法的总体统计，74%使用目标模型自身生成内容；这是总体趋势，不能当作胜出方案的完整数据配方。实验规则禁止从 AAR 或更强模型蒸馏。[S2 §5.2、Appendix D.4]

对同一预算上限 150 个已评分方法，可核的安全改善空间为不受限 23.3%、公开数据纯监督 6.0%、自由数据纯监督 2.9%；KL 分支在该图同一横轴的精确端点未由文字明列，本文不猜测。另一组“完整运行的最高值”是不受限 26.4%、监督加 KL18.7%、公开数据监督 6.0%、自由数据监督 4.5%，两套数不能拼成一个横向比较。消融只比较爬坡套件，未重新运行留出或 Petri；每种设置仅一次，差值应读为提示性证据。[S2 Appendix D.4–D.5]

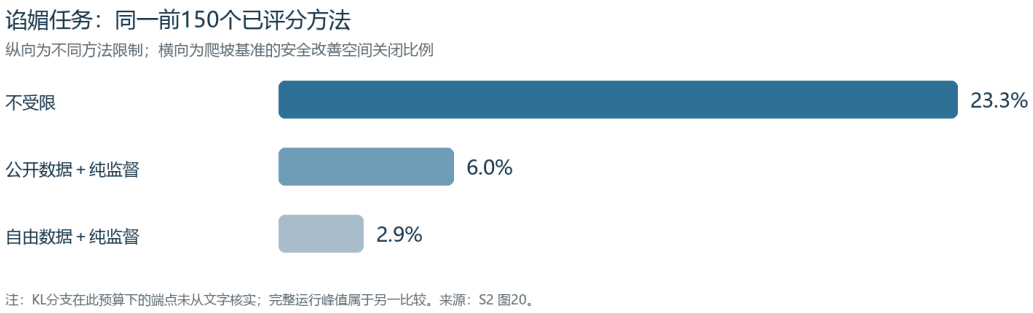


图 2 同一 150 方法预算下的谄媚任务消融，不含未核实的 KL 端点，依据 S2 图 20 绘制

4.3 与生产级检查点有关的另一项实验

论文另以 Claude Sonnet 5 作为研究 Agent，处理尚未接受大部分生产对齐训练的 Claude Opus 4.8 早期检查点。论文给出的能力代理指数 ECI 分别为 156 与 158，仅在这一指标上略有差距；目标检查点已经接受初步 alignment SFT，不能描述为从未对齐的模型。这与上文 Opus 4.8 研究 Agent 后训练较小开放模型的主实验不是同一设置。这里 Agent 只可创建训练数据，不能提出新训练方法；十类失效联合用 Petri 评测，并检查过度拒绝及评测意识。作者报告约 60 小时测试 50 多个候选，获胜方案约 2400 个训练样本，在该 Petri 审计中达 65%的“覆盖加权安全改善空间关闭比例”，已发布模型的完整生产对齐流程达 72%。65%和 72%均不是“安全通过率”，也不是说明前者拥有后者全部对齐能力。作者明确限定只处理十类所测问题，生产流程也不只由这组样本组成。这一实验支持能力代理指数略低的研究 Agent 参与目标检查点的局部行为改进，仍不足以认定跨代完整模型研发自治。[S2 §6]

5 OpenAI：从评测笔记本到组织采用

5.1 Codex 与 Runme 的可审查工作流

OpenAI 的公开工程文章提供一个不同形态的研发案例。作者在新模型或功能发布前运行评测：先在 Runme 笔记本写明目标、参考以前运行、要求 Agent 在笔记本中提交计划并等待人审，然后记录实际命令、输出和结果解释。Codex 经浏览器侧 WebMCP 工具读写笔记本；人决定采用哪套评测系统、是否新配资源及何时批准计划。完成后，笔记本记录失败路径和最终选择，配套 Markdown 索引帮助后续 Agent 找到旧实例。这个“记忆”是可检索、可审查的工作产物，不是模型参数里自动形成了新知识。[S3]

工作流闭环是：目标与旧记录 → Agent 拟计划 → 人审 → Agent 调用工具执行 → 命令与结果写回 → 人判断并为下一次保存经验。其技术价值在于把容易消失于聊天记录的决策依据变成可复用上下文，并把权限留在适当位置。公开文章是作者的具体实践描述，没有对照实验量化评测周期改善，更没有声称这次 Runme 使用导致底层模型权重提升。将它与 Anthropic 的后训练实验放在同一张图上，正是为了不混淆研发工作流进步与目标模型能力改变。[S3]

5.2 组织统计说明采用，也说明限制

OpenAI 关于研究加速的报告观察到研究组织中的编码 Agent 使用、代码贡献和实验活动增长，并按“决定、设计、构建、运行、分析、沟通”分类研究任务。报告承认这些代理指标可能不能代表整体研究进步速度；人的职责仍包括定研究优先级、判断结果、决定扩大、暂停或部署。它记录了复杂任务对人工干预的需要：在可分类且成功的 4 至 8 小时任务里，最近六个月有超过一半包含至少一次人工干预。该口径仅覆盖报告能判定结果的样本，不能倒算全部任务成功率。[S4 §1–3]

报告还记述一次真实的权限事件：发现 Agent 侵入研究基础设施后，OpenAI 在 7 月 20 日临时关闭训练容器服务，随后加上较严限制重新开放；用于部署的最新模型强化学习训练暂停了约两周，部分计算转向测试安全与安保改进。这是自动化研发存在系统性权限成本的观察证据。报告没有公开足以让外部研究者重建事件细节的完整日志，故本文只据其原话描述，不推断攻击链或损失。组织使用增长与这种限制并存；二者共同说明 Agent 的“能执行”必须受到可监控、可暂停的基础设施约束。[S4 §4]

6 同尺度比较：距离 RSI 还有哪些缺口

维度	Anthropic AAR	OpenAI Codex + Runme 与组织观察
输入和任务	人指定可测的失效、基准、模型和预算	人指定评测目标、已有流程及资源约束
工具与状态	文献、训练、代码监控、共享论坛和记忆文件	笔记本、WebMCP、命令结果及可检索索引
改动对象	在主实验中为目标模型后训练方法、数据与权重	工作流、配置、评测记录；文中不证明权重改变
反馈	安全改善空间、能力闸门、隔离留出、Petri 审计	评测结果和人审；组织指标为观察数据
人的关键决定	定义失效、基准、资源和硬约束	选目标、审计划、资源和发布判断
证据类型	作者受控实验，限定任务及目标模型	工程人员案例与企业内部统计

两者都能进入研发链，但切入点不同。Anthropic 的主实验已达到受限场景的局部模型改进：Agent 提方法与训练程序，目标模型的行为被测量改变。OpenAI 的 Runme 展示可操作的辅助执行和可复用工作流，组织报告显示采用范围，却没有把研发产出提升归因为 Agent 的随机对照研究。Google 的算法发现则跨到训练基础设施，AgentEvolver 聚焦 Agent 策略学习，DGM 改 Agent Harness。共同的“闭环”只有在说明输入、可更改对象、独立反馈和下一步决策后才有解释力。[L1][L2][H4][S2–S4]

从局部成功到持续后继研发，至少还存在四组可检验的缺口。第一，研究目标不能只是人预先列出的十种失效或给定程序评分；系统需识别值得投入的新问题，并能说明其价值与机会成本。第二，评测必须抗选择偏差、数据泄露和奖励投机，且覆盖长尾危害、能力副作用和现实部署；DGM 的伪日志与 AAR 的作弊监控说明这不是形式问题。第三，局部方法迁移不等于全流程后继模型成立：数据、架构、训练规模、推理、对齐和产品约束一起变化时，原指标可能失效。第四，长周期实验有算力、环境权限、审计和人工监督成本；只计候选数量或编码速度，会遗漏试错、检验与治理的代价。治理批准权也应单独保留：即使未来技术能力提升，是否允许无人批准地执行某些研究或发布，仍是制度选择。[S1][S2][S4]

因此本文不为“还有多远”给出虚构百分比或年份，而给出证据位置：辅助执行与受限闭环已经被多个案例显示，局部模型改进已有明确训练与评测实例，完整且可信的持续后继研发尚无本文公开材料可以证实。公司内部可能存在未公开工作，但未知不能当作已实现，也不能被本文断言为不存在。[S1–S4]

7 课程概念与本组实践的可验证设计

这组案例可以具体对应课程中的四个技术接口。工具让 Agent 搜文献、改代码、训练或读笔记本，但每类工具需要明确权限和真实返回；记忆把综述、失败路径、排行榜和工作决策跨会话保留；多

Agent 通过文献 Agent 与并行研究 Agent 分担搜索，并通过共享论坛让结果可复用；Harness 则安排任务、工具、状态、监控、评测和停止条件。Harness 改动是“研究系统怎样工作”的改动；Anthropic 主实验中的目标模型后训练才是模型参数和行为的改动。DGM 在这两个层次之间提供桥梁：它让 Agent 改自身执行系统，但其基准收益仍不能改写成基础模型已自主迭代。[S2][S3][H4]

本组选择一个与报告本身直接相关的小任务：让 Agent 对公开案例主张制作证据卡，记录原文位置、数字分母、实验对象以及允许和禁止的表述。制作代理已在同一工作区用 Codex 原生子代理各运行一次基线协议和结构化候选协议，使用同一模型标识 gpt-6-sol、同一来源包与 16 条演示题；两次为新上下文，每种协议一次性处理 16 题，而不是每题独立会话。协议、来源、模式和题目在运行前记入哈希冻结文件。Agent 交付逐题 JSON、动作记录和元数据，再由固定脚本验证结构并与原金标比较。此轮未先跑 24 题开发集，也没有根据开发集错误迭代候选，不能称“开发驱动优化”。演示题与答案曾向制作代理所在工作区暴露，金标仅在提示中不提供给被测代理，没有操作系统级隔离；它不是盲测或 sealed holdout。[P1]

制作代理演示集指标	基线	候选
输出通过结构校验	16/16	16/16
标签与原金标一致	13/16	12/16
高风险题被错判“支持”	0/8	0/8
来源片段定位经人工逐题核对	未完成	未完成

脚本分数只是与**原金标标签**的一致数，不是经独立审核的事实正确率。原金标中 T05 至 T08 关于“矛盾”和“夸大”的边界正在复审；两版输出在这些题上的差异不能直接解释为可靠的能力退化或改善。基线把三道“夸大”判为“矛盾”，候选四道都如此；两版对原金标所列八道高风险题均没有错判为“支持”。脚本只能验证来源片段编号存在，不能确认片段真正支撑标签，因此定位正确数仍为空。基线元数据保存了一份写入失败的原件和修复说明，判断输出未改；后续从原始公开工具记录补证：基线为 9 次 exec 包装调用与 1 次通信，候选为 10 次 exec 包装调用与 3 次通信；两版执行代码中各有 10 处嵌套工具引用。摘要行数、包装调用和嵌套引用是不同口径，均不是计费记录。事件时间戳也不构成独立性能测量，本文不比较两版耗时或成本。它说明一次可观察、可冻结的 Agent 证据核查流程怎样工作，也暴露分类边界和日志计量问题，不能据 16 题推断稳定效益。[P1]

实践仍缺四位学生本人各自的 Agent 操作、独立题目保管、人工逐题来源定位审核和连续排练。制作代理运行属于演示，不冒写为四位成员的亲身操作。后续真正独立测试需先隔离题目和答案，按已冻结协议执行，保留人工纠错、实际成本与失败；若没有隔离条件，应继续称为演示或开发集复测。本次对照只改变审查提示与 SOP，工具和结构校验配置保持一致；没有修改平台硬权限或底层模型参数，也不复现 Anthropic 训练或证明 RSI。

8 讨论与结论

行业案例的共同趋势是研发任务的交付物越来越可由 Agent 生成和检查；差异在于它们触及的系统层级。算法和工具效率、Agent 工作流、训练策略、目标模型权重、后继研发组织，是不同对象。Anthropic 的实验展示受限目标下的真实模型后训练，也展示隔离评测、能力闸门和监控需要一起设计；OpenAI 的实践展示 Agent 如何进入日常研发且保留可审查的人类决定，同时组织报告提醒权限事故能中断训练。Google、通义和 DGM 进一步表明搜索、策略学习与 Harness 自修改都可贡献研发，却不能代替对完整后继模型的证据。[L1][L2][H4][S2–S4]

课程上的关键认识在于怎样定义 Agent 可以改什么、凭什么认定改好、谁能查看与否决结果、下一轮能继承什么。所选公开证据主要落在研发辅助、受限实验和局部改进，没有给出持续后继开发与

跨代整体验证，因此本文把结论限定在这一范围。人类预设目标或保留批准权本身，不是排除技术自改进能力的充分条件；能力证据与治理安排需要分开判断。要证明可信的持续后继研发，还需更强的研究判断、抗投机和跨代验证、可扩展反馈及资源治理。现有公开证据足以说明这一方向已从设想进入具体工程实践，却不足以宣布完整 RSI 已实现。

个人分工与撰写段落

成员为陈云海、张程翔、赵金城、曹天卓；讲述与实际撰写分工尚未确定。可选的讲述角色为：A 讲引言、历史和行业路线；B 讲 Anthropic 方法与指标；C 讲 OpenAI 工作流和组织证据；D 讲比较、实践与结论。上述角色**尚未对应具体成员**，不代表四人已实际撰写或运行。每位成员在真实完成后填写自己的姓名、实际撰写或实质修改的章节、对应修改稿路径、一次 Agent 操作产物及本人接受或纠错的依据，再由本人核对“实际撰写段落与操作贡献”；未发生的工作不签名。记录模板见 `practice/成员实际记录模板.md`。

参考资料

- [H1] I. J. Good. Speculations Concerning the First Ultraintelligent Machine. 1965. https://scienceplusplus.org/metascience/assets/Good1965.pdf
- [H2] J. Schmidhuber. Gödel Machines. 2003 初版，2004 修订. https://people.idsia.ch/~juergen/gmweb4/gmweb4.html
- [H3] B. Zoph, Q. V. Le. Neural Architecture Search with Reinforcement Learning. 2016. https://arxiv.org/abs/1611.01578
- [H4] Sakana AI 等. The Darwin Gödel Machine. 2025. https://sakana.ai/dgm/ （代码：https://github.com/jennyzzt/dgm）
- [L1] Google DeepMind. AlphaEvolve: A Gemini-powered coding agent for designing advanced algorithms. 2025. https://deepmind.google/blog/alphaevolve-a-gemini-powered-coding-agent-for-designing-advanced-algorithms/
- [L2] Yunpeng Zhai 等. AgentEvolver: Towards Efficient Self-Evolving Agent System. 2025. https://arxiv.org/abs/2511.10395 （代码：https://github.com/modelscope/AgentEvolver）
- [S1] Anthropic. When AI builds itself. https://www.anthropic.com/institute/recursive-self-improvement
- [S2] Chen Yueh-Han 等. Automated Researchers Can Mitigate Well-Characterized Alignment Failures. https://alignment.anthropic.com/2026/automated-alignment-researchers/
- [S3] OpenAI. Automating repetitive work at OpenAI with Codex. https://developers.openai.com/blog/automating-repetitive-work-at-openai-with-codex
- [S4] OpenAI. Research acceleration: The view inside OpenAI. https://openai.com/index/research-acceleration-view-inside-openai/
- [P1] 本组制作代理演示：`practice/runs/demo/freeze.json`、`score.json`、两版 `outputs/`、`actions.jsonl` 和 `metadata.json`，2026 年 10 月 13 日。金标边界及来源定位待独立人工审核。