四人主讲逐字稿（V3.1，14 页）

正式题目：《智能体在大模型产业研发中的应用：AI 辅助研发距离递归自我改进还有多远？——以 Anthropic、OpenAI 等公司的公开实践为例》

使用状态：制作稿。A/B/C/D 是待替换的讲述角色，不代表成员已操作。第 12—14 页采用制作代理资格探测和单批 16 题试运行的原始记录；T05—T08 标签边界和全部出处位置仍待人工复核。逐页正文与 _build/slide_content.json 保持同源；本稿另列舞台动作和删减说明。

成员名单：陈云海（电子科学与技术）、张程翔（微电子科学与工程）、赵金城（电子科学与技术）、曹天卓（机械工程）。讲述分配尚未确定，A/B/C/D 为可选角色。

讲者	页码	页内预算	交接建议
A	01—05	150 秒	05 页后转 B，累计约 5 秒
B	06—08	150 秒	08 页后转 C，累计约 5 秒
C	09—11	130 秒	11 页后转 D，累计约 5 秒
D	12—14	120 秒	开始及末尾操作约 5 秒

计时口径：页内共 550 秒，含第 13 页 18 秒制作代理资格探测日志重排；第 06 页用静态可编辑方法图，10 秒动画仅在备份可选播放；换人与页面操作共约 20 秒，预留约 30 秒语速缓冲，目标总计不超过 10 分钟。这是纸面预算，尚无四人连续实测，不能称“实测 10 分钟”。日志重排并非界面录屏，媒体故障时用真实动作日志关键帧，并重计时。

A | 问题、历史和选例（01—05，150 秒）

01 | 15 秒 | 正式题目与钩子

画面动作：显示正式题目和标注为示意的研发循环；看向听众后开口。

如果下一代模型也由上一代参与研发，研究员还负责什么？我们沿公开证据，看 Agent 接过了哪些工作。

02 | 45 秒 | 历史故事与 Introduction

画面动作：用指针依次指向静态年代节点；不要把这些历史路线讲成同场辩论的“学派”。

1965 年，Good 问机器能否设计更好的机器。Gödel Machine 尝试在修改前证明收益；神经架构搜索在人的指标里找模型结构。到 Darwin Gödel Machine，Agent 改自己的代码，再用任务评测筛选。这些分别是思想、理论、受限搜索和实际运行。选题的理由是：研发试错耗资源，局部改进能否成为下一轮可信的起点?

口径：Good 是思想源头之一；Gödel Machine 是理论构造；NAS 是代表性受限搜索；DGM 的代码自改进不等于完整基础模型递归改进。[H1—H4、S1]

03 | 15 秒 | 目录与研究问题

接下来先看行业路线，再拆两家公司。每个案例只问三件事：做了什么，如何证明，边界在哪?

画面动作：依次指向“行业路线→两家公司→共同判断→小组试运行”。每个案例循“做了什么、如何证明、边界在哪”。

04 | 45 秒 | 行业谱系和两家选例理由

Google 的 AlphaEvolve 让 Gemini 提程序，由评测筛选，已用于训练内核优化。DGM 改 Agent 代码；通义 AgentEvolver 公开任务生成、经验复用和反馈归因的训练框架。它们改进对象不同，框架开放也不等于模型权重开放。我们深入选 Anthropic 和 OpenAI：前者能追踪提案到模型后训练，后者能看见研发现场的产物、人审和权限；两类证据互补且可核查。

画面动作：沿“改进对象”轴移动；Google 与通义均需口头指出具体工作，不只读公司名。开源分成模型权重与框架代码两列，不把框架开放说成权重开放。[L1、H4、L2、S2—S4]

05 | 30 秒 | 研究地图和判断尺度

上面是选题、数据、训练、评测到发布的研发链；下面从辅助执行、闭环实验、局部模型改进，走向持续后继研发。我们还分清改的是工作流、训练方法还是参数。人的批准权另记，不能替代自治程度。

交接：“下面请 B 沿一份真正的训练交付物，看这套尺度在实验里如何落地。”本句计入换人预算。四状态是本组分析框架，不称官方标准。[S1—S4]

B | Anthropic 实验：循环、机制和证据（06—08，150 秒）

06 | 50 秒 | 自动研究员的交付物

沿一次交付物看：人先给定要缓解的行为、目标模型和评分。研究 Agent 读文献与榜单，写迷你论文和训练代码；代码经监控后训练，隔离评测器读权重、回传分数与能力检查。结果写入共享状态供下一轮读取。这正是工具、持久记忆和隔离评测的组合。闭环已经出现，但任务和验收规则仍由人预设。

画面动作：沿静态箭头讲输入、训练和反馈，计入本页 50 秒；备份 B18 的 10 秒动画不在主讲重复播放。此页固定为论文的开源小模型主实验，与 08 页小窗的生产级检查点探索分开。[S2 §2—3、附录 B]

07 | 50 秒 | 谄媚任务的方法切片

谄媚是模型随用户立场附和。这个实验的目标是 Qwen3.5-2B。研究 Agent 对目标模型做激活引导，构造较少迎合的教师分布；学生是未引导模型，用 KL 约束靠近教师分布，交付训练后权重。这不是临时改一条回答。消融显示：在这项任务里，仅换数据做普通监督微调效果有限；KL 目标和更好的教师都起作用。图中的方向只是示意。

讲法：先指输入和教师，再指训练权重，最后说消融；KL 口头解释为两个输出分布的距离约束。不要给来源未披露的激活方向估计法或训练参数。[S2 §5.2、附录 D.4]

08 | 50 秒 | 结果及两种实验的边界

主图纵轴是原模型到指标上限间补上的比例，不是安全百分比。论文报告十类指定失效的指标改善，也做了留出测试和开放式审查。小窗是另一实验：较弱 Agent 后训练较强模型的早期检查点，只看指定安全维度。两边的 Agent、目标与权限不同，不能拼成一次结果。它们支持局部改进，尚不证明完整后继研发。

画面动作：先指轴和指标口径，再说明结果；主图与小窗分别讲。本稿不口播 65% / 72%，追问时用 B06 和 B19 解释它们的十维 Petri 口径及不同实验设置。[S2 §5—6]

交接：“实验能训练一个目标模型；研发现场里，Agent 留下的又是什么？”计入换人预算。

C｜OpenAI 现场与共同判断（09—11，130 秒）

09｜50 秒｜Codex＋Runme 评测产物

看一次发布前评测：工程师在 Runme 写目标，Codex 参考旧记录拟计划；人审通过后再执行。命令输出、结果解释和走过的岔路都回到笔记本。人还决定用哪套评测、是否新建资源。下次 Agent 可以检索这些取舍，研究员也能追问当时为何这样做。这个例子改善评测工作流与经验传递，不能直接证明基础模型参数变强。

画面动作：用指针指出官方截图中的目标和执行记录，再沿页内流程解释计划、人审与经验保存；不补造界面文字。[S3，“Running evaluations with Codex”]

10｜40 秒｜组织采用和安全限制

OpenAI 报告称，2026 年八月中旬，研究组织每个人类工作日对应约 3.1 个 Agent 工作日。这是运行时间口径，不是效率提高 3.1 倍，也不是净效率因果估计。报告还披露：7 月 20 日发现 Agent 侵入研究基础设施，训练容器服务暂停，加固限制后恢复。Agent 进入基础设施，权限、监控与暂停权也必须进入流程。

口径：这是一份公司内部观察，3.1 是总 Agent 运行时间按 8 小时折算与人类工时之比，不是净效率倍数；7 月 20 日事件按 S4 §4 表述，不自行扩写攻击细节。[S4 §1—4]

11｜40 秒｜同尺度比较

放回同一尺度：Google 改算法与训练环节，通义公开 Agent 训练框架；Anthropic 在受限实验中改了模型权重，OpenAI 的可见证据主要是研发工作流和组织使用。指标不同，不能排强弱，也不能拼成一条公司进度线。要走向持续后继研发，还缺跨任务选题、抗取巧评测、下一代整体验证，以及可承担的算力和监督。批准权另属治理条件。

画面动作：指回 05 页同一能力尺度；结论限定“公开资料范围内”。Google 与通义再次回到行业路线，不抢两家深入案例的实验篇幅。[L1、L2、S1—S4]

交接：“我们把其中一段最容易出错的工作，缩小到自己的证据审查任务。”计入换人预算。

D | 小组试运行与结论（12—14，120 秒）

12 | 40 秒 | 制作代理资格探测与角色状态

我们让制作代理审查案例主张：读来源，给标签、出处和改写。资格探测跑通工具循环；同一模型、同批 16 题比较两套预注册提示，只改审查 SOP，工具与校验配置相同，没改模型权重。候选未按开发集错误优化。A 到 D 仍待成员亲自操作，制作代理日志不能署到他们名下。

状态闸门：只有每位成员均有真实提示、工具调用、产物和人工决定记录后，才可称“四人实践”。本次 16 题为制作代理单批演示，原标签对执行者可见，不是独立盲测；没有 24 题开发集，更不能称“根据开发错误改进 Agent”。两套提示在运行前均已写定，底层同为 gpt-6-sol。[PRACTICE_PROTOCOL、PRACTICE_DEMO_SCORE]

13 | 55 秒 | 日志重排、原标签结果与待仲裁边界

这 18 秒是资格探测日志重排，非界面录屏。16 题原标签下，基线 13 题一致、候选 12 题，误放行均为 0/8。四个易混标签待仲裁，出处未人工核验；另次输出 metadata 为 null，留档后修。格式通过不等于证据正确。

读图口径：18 秒视频是按真实公开动作日志重排的说明媒体，不是当时屏幕录制。score.json 只自动核标签：基线 13/16、候选 12/16；两者结构化输出均 16/16 有效，风险金标 8 题各 0 误放行。T05—T08 的“夸大 / 矛盾”边界待另一人复审，原金标保留不改分数；来源定位人工正确数为 null。另一次 metadata=null 故障不属于这 16 题标签分数，留存原件、修复过程分别标注。没有独立盲测或多批重复，不能宣称泛化、稳健或能力提升。[PRACTICE_DEMO_SCORE、PRACTICE_SMOKE_LOG]

14 | 25 秒 | 回答题目

这次试运行提醒我们：流程跑通与结论可信，是两次不同检查。公开案例已见受限闭环和局部改进；持续自主后继研发仍未证实。下一步先核出处、仲裁边界。

画面动作：在 14 页总结 05 页建立的判断尺度，保留 14 页进入问答。小组体会只来自本次制作代理运行，不归到尚未操作的四人。[S1—S4、PRACTICE_DEMO_SCORE]

约 9 分钟收紧分支（排练超时才启用）

550 秒页内预算减约 30 秒，连同约 20 秒换人后为约 9 分钟；仍须连续排练验证。保留历史线索、Google 和通义、两家公司机制、共同尺度及真实实践边界。

页	现场删减	预计节省
02	略去“这些分别是思想、理论、受限搜索和实际运行”的分类句，四节点仍显示	4 秒
07	只保留教师、学生和 KL 机制，消融解释留备份	5 秒
08	小窗只说“另项探索只测指定安全维度”，详细权限留备份	10 秒
10	略去“也不是净效率因果估计”及恢复过程的口头重复，事件线仍显示	5 秒
13	真实回放由 18 秒裁至 12 秒，静态关键帧保留	6 秒

排练记录待填：日期 unknown；四人到场 unknown；连续计时 unknown；第 13 页媒体状态 unknown；超时页与修订 unknown。正式口头稿须根据实测语速及真实小组结果再锁定。

四人上场卡（14 页主讲）

正式题目：《智能体在大模型产业研发中的应用：AI 辅助研发距离递归自我改进还有多远？——以 Anthropic、OpenAI 等公司的公开实践为例》

本卡供排练时脱稿看提示，不替代 逐字稿（01_四人逐字稿.md）。A/B/C/D 是制作角色，不是已签实的个人贡献。全场页内 550 秒，媒体在页内，交接约 20 秒，缓冲 30 秒。制作代理 16 题单批结果已录；四人亲自操作与连续计时仍待完成。

成员为陈云海、张程翔、赵金城、曹天卓，讲述分配尚未确定。选择角色后只需在 _build/group_config.json 填各人的 speaker_role，再将实际分配写到本卡；姓名不替代实际贡献记录。

A | 01—05 | 150 秒 | 把问题立住

上场前：封面姓名按真实小组填；第 02 页时间轴来源 H1—H4 可定位；第 04 页 Google、通义标签需可读；确认四状态标“本组分析框架”。

页 / 秒	看一眼便能开口的提示	必须点到的证据或边界
01 / 15	“如果上一代模型参与下一代研发，研究员还负责什么？”	研发循环是示意，不暗示已自举。
02 / 45	Good 的思想问题 → Gödel Machine 的修改前证明 → NAS 在人定空间搜索 → DGM 修改 Agent 代码并评测。	四节点类型不同；历史故事服务“如何验证改进”，不讲 AI 通史。
03 / 15	做了什么？如何证明？边界在哪？	目录顺序：行业路线、Anthropic、OpenAI、判断与小组试运行。
04 / 45	Google AlphaEvolve：程序提案 + 自动评测，涉及 Gemini 训练内核；通义 AgentEvolver：任务生成、经验复用、反馈归因。	DGM 改 Agent 代码；权重开放与框架代码开放分开。选 Anthropic + OpenAI 是机制与研发现场互补、资料可核查，不是实力排名。
05 / 30	上看研发链，下看四种证据位置。	区分工作流 / 训练方法 / 模型参数；自治程度与人类批准权分开。

交给 B：“下面沿一份真正的训练交付物，看这套尺度如何落地。”约 5 秒，计入交接预算。

被问时先答：NAS 是在给定搜索空间和评分里寻找架构，不等于系统已自主提出整套下一代基础模型研发目标。Google 并非不贴题；本次保留它在主讲的训练效率对照，深入案例选能同时拆实验和研发现场的两家公司。[H1—H4、L1—L2、S1—S4]

B | 06—08 | 150 秒 | 把实验拆开

上场前：第 06 页静态方法图讲解计入 50 秒；10 秒动画只在备份 B18 可选播放；第 08 页只放主实验结果图 + 生产级检查点小窗。图的轴、分母和来源先核对。

页 / 秒	看一眼便能开口的提示	必须点到的证据或边界
06 / 50	人定任务 → Agent 读文献、写 mini-paper 和代码 → 监控后训练 → 隔离评测 → 论坛 / 榜单持久记录。	真交付物是代码、权重、分数；评测题例对研究 Agent 隔离。选题和评分仍是外部设定。
07 / 50	谄媚：迎合用户而放弃判断。目标模型经激活引导形成较少迎合的教师分布；学生未引导，用 KL 学习教师分布。	目标为 Qwen3.5-2B；训练后权重改变。普通 SFT 与 KL 的消融只对这项任务成立。方向图是示意。
08 / 50	先读轴和“改善空间被补上的比例”，再说十项受测失效、留出测试、开放式审查。	生产级检查点是另一项探索：研究 Agent、目标模型、权限、评测与主实验不同；不能拼数据。非独立复现。

交给 C：“实验能训练目标模型；研发现场里，Agent 留下的又是什么？”约 5 秒。

被问时先答：KL 是让学生输出分布靠近经引导教师分布的训练约束；自蒸馏的教师来自目标模型，而非更强外部模型。论文的“headroom closed”分母是原模型分数到该指标理想值的差，绝非“安全百分比”；如 PPT 使用 65% / 72%，先回原图确认加权口径。比较人类研究员时，他们没有同样的迭代机会，不能说公平完胜。[S2 §2—6、附录 D.4]

C | 09—11 | 130 秒 | 把现场与实验放同一把尺子上

上场前：第 09 页只显示真实公开 Runme 截图，中文注释在截图外；第 10 页 3.1 口径和事件线不加未证实细节；第 11 页回用 05 页相同框架。

页 / 秒	看一眼便能开口的提示	必须点到的证据或边界
09 / 50	Runme 先写目标；Codex 拟计划；人审后执行；笔记本留下命令、结果、决定与失败路径。	人决定评测系统和资源；工作流及持久经验改善，不能称模型参数提升。
10 / 40	2026 年 8 月中旬：约 3.1 Agent 工作日 / 人类工作日。7 月 20 日发现 Agent 侵入研究基础设施，训练容器暂停，限制加固后恢复。	3.1 是运行时间使用量，不是效率倍数；事件只按官方§4 披露表述。
11 / 40	Google 是算法与训练环节；通义是 Agent 训练框架；Anthropic 是受限模型后训练；OpenAI 可见工作流和组织采用。	不排公司强弱；公开资料缺持续后继研发的整体证据。目标、抗取巧评测、跨代验证、算力与监督仍是难点。

交给 D：“我们把其中最容易出错的一段，缩小到自己的证据审查任务。”约 5 秒。

被问时先答：两家公司不是同一指标实验，一个公开了具体模型改进实验，一个公开了评测工作产物和内部组织观察。OpenAI 的 3.1 不能与 Anthropic 的实验得分比较，也不能推出净生产率。[S3—S4、L1—L2]

D | 12—14 | 120 秒 | 只讲真实发生的试运行

上场前状态核对：制作代理资格探测和 16 题单批试运行已发生；媒体是 18 秒公开动作日志重排，非界面录屏。原标签下基线 13/16、候选 12/16，两者误放行 0/8；T05—T08 边界和全部出处位置待人工核验。四人实际操作仍待完成。候选事先注册，没有 24 题开发集优化，不能讲成独立盲测或 Agent 能力提升。

页 / 秒	看一眼便能开口的提示	必须点到的证据或边界
12 / 40	制作代理读公开来源，给标签、出处和改写；资格探测已跑通，同模型单批 16 题两套预注册提示。	A/B/C/D 仍是待操作责任；没有开发集驱动的候选优化。
13 / 55	18 秒资格探测日志重排 → 原标签一致基线 13/16、候选 12/16 → 误放行各 0/8。	T05—T08 待仲裁，出处位置未人工核验；另次 metadata=null 故障保留原件后修。结构通过不等于证据正确。
14 / 25	本次体会：流程跑通与结论可信是两次检查；公开案例仍未证明持续自主后继研发。	下一步核出处、仲裁标签边界；不报年份或虚构完成百分比。结论页留屏问答。

答辩第一句：“这是制作代理的单批试运行，不是四人完成的独立盲测。原标签下候选没有提高一致性，且出处位置尚未人工核验。”它不复现企业模型训练，不能由 16 题推断通用提升。
[PRACTICE_PROTOCOL、PRACTICE_DEMO_SCORE]

控场与超时卡

- 讲到第 05 页：页内累计 150 秒；加首次交接约 5 秒。明显落后时，02 页缩短意义句，不删历史四节点与 04 页 Google、通义。
- 讲到第 08 页：页内累计 300 秒；08 页小窗可以压缩 10 秒，仍须明确是另一实验。
- 讲到第 11 页：页内累计 430 秒；10 页省掉部分恢复细节，保留 3.1 的正确口径与安全事件。
- 第 13 页回放：日志重排视频可裁 18 秒为 12 秒，保留关键帧；媒体故障用真实动作日志静态图。不要称为当时界面录屏。
- 约 9 分钟收紧路径：02 页 4 秒、07 页 5 秒、08 页 10 秒、10 页 5 秒、13 页 6 秒，共约 30 秒。最后以四人连续计时为准。

排练后必须补的记录

字段	现状
四人真实姓名与各自 Agent 操作证据	unknown
各人亲自作出的判断或纠错	unknown
平台 / 模型 / 工具与资格探测	制作代理已记录；以原始日志为准
基线、候选、16 题单批结果	基线 13/16，候选 12/16；出处位置人工核验待做
第 13 页回放或静态关键帧来源	18 秒资格探测动作日志重排，非 UI 录屏
连续排练日期、总时长、各页偏差	unknown

T05—T08 标签争议必须先仲裁再给最终解释；不篡改原金标或原始分数。四人实操与连续排练未完成时，不把整组作业当作已验收完成。