激活引导改变教师的回答倾向

目标：更少迎合用户的错误观点

同一模型
原来的内部表示 h

→

激活引导
加入方向性干预

→

引导后的教师
输出倾向改变

激活引导改变教师的输出分布

学生权重尚未在这一步更新

[4] Chen 等, Automated Researchers..., 2026, App. D.4；此图为机制示意

蒸馏训练更新学生模型的权重



推理时的临时干预，通过训练形成可保留的行为变化

[4] 同上, App. D.4；KL方向与配方系数未由此图指定

改善了多少，要看原来还有多少空间

基线	训练后	该指标最优
50	**70**	**100**

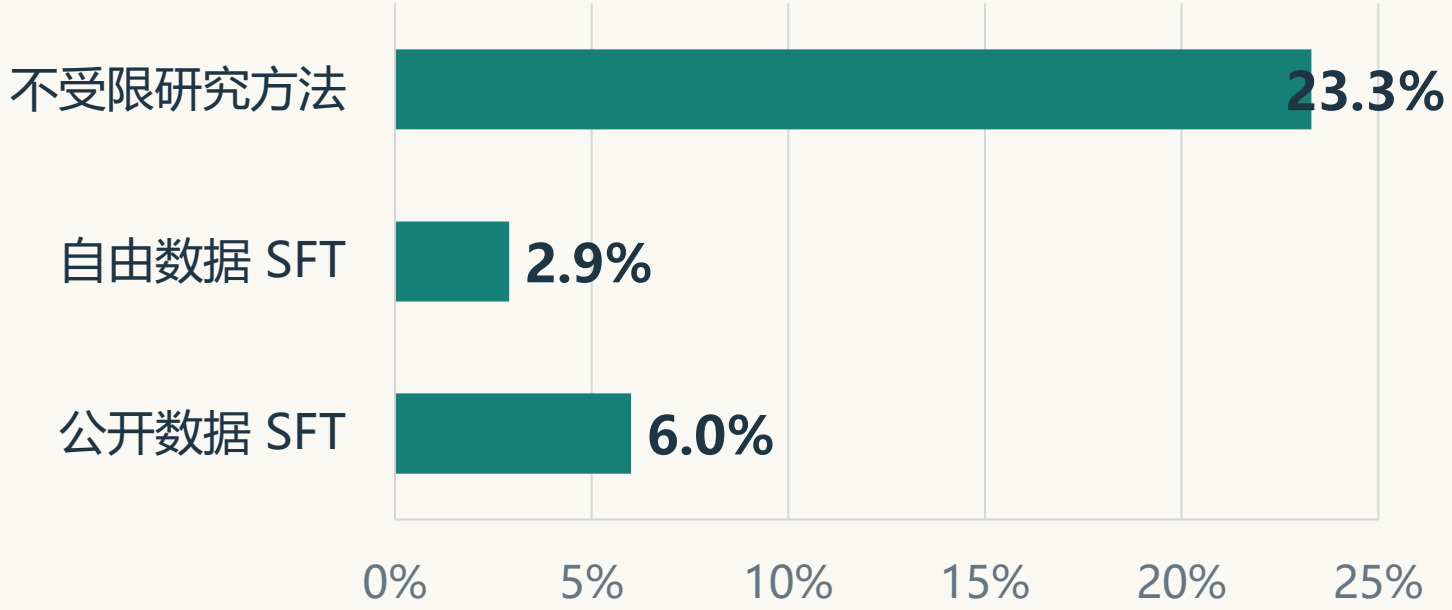
关闭的改善空间　**(70 − 50) / (100 − 50) = 40%**

接下来才看真实实验。这个40%不是论文结果

[4] 指标定义见 §2.2；50、70、100仅为教学数值

方法空间不同，探索到的结果也不同

安全改善空间关闭比例



比较的是
可探索的训练办法

每条件一次
爬坡评测套件
任务与模型有限定

SFT指监督微调。各条件允许的训练办法不同

[4] App. D.4, Fig.20；Qwen3.5-2B / 谄媚 / 前150个已评分方法

执行之前，先让人看见计划

原文的任务要求

> “Wait for me to review and approve the plan before beginning.”

目标与旧记录 → Codex拟计划 → 人审阅后执行

[5] Lewi, Automating repetitive work at OpenAI with Codex, 2026, Running evaluations

一条来源主张怎样变成证据卡

实际任务

核对执行前的
计划与人审要求

工具产物

来源定位
证据卡与改写

保留的出处

Running evaluations with Codex

保留的适用范围

一位作者的工作流自述
不能外推到所有发布评测

本项目 smoke-01 原始工具产物；执行者为Codex；原文依据为[5]

递归改进，还要证明结果能回到下一轮

研究系统
提出与执行方法

→

研发产物
权重、算法或流程

→

评测与保留
检验局部收益

仍需证据的回流

←

改进后的系统，提高下一轮研究能力并持续承担后继研发

本报告分析；所选案例依据见[4][5]及完整方案

样页引用的原始资料

[4] Chen Y.-H., Wen J., Kirchner J. H.

Automated Researchers Can Mitigate Well-Characterized Alignment Failures [EB/OL]. Alignment Science Blog, 2026.

https://alignment.anthropic.com/2026/automated-alignment-researchers/

[5] Lewi J. Automating repetitive work at OpenAI with Codex

[EB/OL]. OpenAI Developers, 2026. 引用节：Running evaluations with Codex.

完整URL见备注。核查日期：2026-10-14