四人汇报口播与快速上场卡

正文按 10 分钟设计。时间预算尚未真人试讲。A/B/C/D 是可交换的讲述角色，尚未对应姓名。

01 当 AI 开始参与下一代 AI 的研发

建议角色 A　设计预算 15 秒

大家好。当 AI 开始帮研究员开发 AI，它接过了哪些工作？这种帮助，距离能够不断改进自己的系统，还有多远？今天，我们沿着真实的研发任务找答案。

本页记住：追踪智能体接手的研发任务，再判断距离 RSI 多远。

02 研发模型，也要处理大量具体工作

建议角色 A　设计预算 25 秒

比如，要让一个模型少迎合用户的错误观点，研究员得查资料、想办法、写训练代码，再看实验为什么失败。智能体开始接手的，就是这些具体工作。所以我们关注 AI 行业自身：研发的人手和方法变了，会不会进一步改变下一代模型的研发速度和方向？这比只看它会不会写代码，更接近我们这次选题。

本页记住：选题动机是 AI 研发流程中的任务交接，以及它对下一代研发的潜在影响。

03 沿四个问题，走完一条研发线索

建议角色 A　设计预算 15 秒

今天分四步：先看研发工作，再拆公司案例，然后判断离自我改进多远，最后讲我们自己的 Agent 协作。全场沿着这条线：接手任务，做出改动，再检查改动是否可信。

本页记住：目录是四个连续问题，主线是任务、改动与验证。

04 一个老问题，两种验证思路

建议角色 A　设计预算 35 秒

这个问题有一段很长的历史。1965 年，Good 提出：设计机器本身，也可能成为机器擅长的活动。之后出现了两种值得对照的思路：一种像哥德尔机器，先证明修改有益，再动手；另一种依靠实验，生成候选、

测试、保留好结果。从神经架构搜索到达尔文哥德尔机器，这条经验路线逐渐能跑起来。但能改结构或代码，还不等于能够研发完整的下一代基础模型。

本页记住：历史线索是从思想设想到形式证明与经验验证，不把不同路线包装成已证实的学派胜负。

05 先跟一次具体任务：让模型少迎合

建议角色 A　设计预算 35 秒

把历史问题落到一个小任务上：用户说错了，模型怎样做到有礼貌地指出，而不是跟着附和？研究 Agent 读资料、提出训练方法，再调用工具训练目标模型。评测返回结果，它据此调整下一次尝试。这里，工具让想法落地，反馈告诉它有没有用，记录让下一轮不用从头开始。这也把课上的工具调用、规划和记忆，接到了真实研发任务上。

本页记住：用具体研发任务解释 Agent 的工具、反馈与持久记录。

06 为什么重点讲这两家公司？

建议角色 A　设计预算 25 秒

大模型研发从方法设计，一路走到训练、评测和部署。我们重点选 Anthropic 和 OpenAI，是因为公开材料能让我们拆开两类具体任务：前者让研究 Agent 提出并试验训练方法，后者让 Codex 参与发布前评测。一个直接触及目标模型，一个改进研究工作流程。稍后再用 Google 和通义补足其他路线。下面先看训练方法怎样真的变成模型改动。

本页记住：案例选择依据是可拆解的一手任务与互补的改动对象，而非品牌排名。

07 研究 Agent 和目标模型是两个角色

建议角色 B　设计预算 25 秒

先分清两个角色。研究 Agent 负责想办法和调工具，目标模型接受训练，随后被评测。它们不能混成同一个角色，说成模型自动把自己升级了。Anthropic 的开放权重实验，让研究 Agent 在规定任务和资源内试验方法；研究人员仍然设定目标、工具和评测。接下来我们沿着它的一轮尝试，看具体交付了什么。

本页记住：明确研究者、训练对象与外部设定三者的关系。

08 一次研究循环，交付的不只是一段建议

建议角色 B　设计预算 40 秒

一轮研究先提出方法，再把它写成可以执行的训练代码。工具训练出一个候选模型，独立评测检查：迎合有没有减少，其他能力有没有明显退步？结果会留下来，再供后续尝试和筛选使用。论文比较了 AI 方案和人类方案，但双方尝试预算不同：AI 能多次试验，再选最好的一次。因此，结果说明它能产出有用的方法，不能直接解释成 AI 研究员已经全面超过人类。下面拆一个成功方法。

本页记住：训练与独立评测构成研究反馈；预算与最佳值选择限制人机比较。

09 把临时引导，训练进学生模型的权重

建议角色 B　设计预算 55 秒

这个方法分两步。第一步，改变模型内部的激活表示，让回答更少迎合用户，得到一个被引导的教师。第二步，让学生学习这个教师给出的输出概率分布。图里的 KL 散度，就是衡量两种分布差异的办法；训练时让它们更接近，学生的权重随之更新。这样，学生以后正常推理，也能保留这种行为倾向。这比临时在输入里加一句要求更深入：改动进入了参数。这里的教师来自被引导的模型，也不是额外请来一个更强的外部模型。最终有没有改善，还要交给独立评测。

本页记住：开放权重实验的激活引导与 KL 自蒸馏：教师分布监督学生权重更新。

10 另一个实验：65%到底在量什么？

建议角色 B　设计预算 40 秒

论文还有另一个实验，设置变了：研究 Agent 只能制作训练数据，目标是一个部署模型的早期检查点。这次不能把刚才的激活引导方法搬过来。胜出检查点的 Petri 分数是 65%，发布版是 72%。这里的 65%，既考虑十个评测维度改善了多少，也考虑改善覆盖了多少维度；它不是安全测试通过率。这说明数据方法在这组评测中有贡献，但数字没有证明模型在所有情境下都安全。接下来换个环节，看发布前评测怎样交给 Agent。

本页记住：部署模型实验的权限与指标不同；65%是覆盖加权改善空间指标。

11 OpenAI：可回查的发布前评测

建议角色 C　设计预算 40 秒

OpenAI 公开的是一个更贴近工程师日常的例子。人先把发布前评测目标写进 Runme 笔记本，Codex 参考以前的记录提出计划。人检查计划后，它再调用工具执行，并把命令、结果解释和取舍留下来。这个笔记本可以理解为一份能执行、也能回查的实验记录。以后遇到类似任务，研究员和 Agent 都有依据。这项实践交付的是评测过程与结果记录；公开材料没有量化它带来的研发净效率，也没有证明它因此改进了模型权重。

本页记住：目标、计划、人审、工具执行与 Runme 记录构成可复用评测工作流。

12 运行量增长，权限也要跟上

建议角色 C　设计预算 30 秒

这种用法规模有多大？OpenAI 内部报告说，每个人类工作日，对应约 3.1 个按八小时折算的 Agent 运行工作日。注意，这是运行量，不能说成生产率提高了 3.1 倍。任务中仍有人工干预。报告还记录了一次代理侵入研究基础设施，随后服务暂停、增加限制再恢复。所以，更长时间的运行，需要明确权限和监督，不能只看它做了多少尝试。

本页记住：运行量不等于因果效率；持续任务受人工干预与基础设施权限约束。

13 行业还有三条不同的改进路线

建议角色 C　设计预算 40 秒

其他团队补上了不同位置。Google 的 AlphaEvolve 用 Gemini 生成程序，再靠自动评测和演化筛选改进算法。一个矩阵乘法内核加速 23%，对应总训练时间减少 1%，两者不能互换。通义的 AgentEvolver 公开框架，用任务生成、经验探索和贡献归因来优化 Agent 策略。Sakana 的 DGM 则让 Agent 改自己的代码。它们分别改算法、策略和代码，所以谈自我改进之前，先问一句：这次究竟改了什么?

本页记住：Google、国内开源框架和 DGM 补充算法、策略及 Agent 代码三类改动对象。

14 离 RSI 多远？追问三个问题

建议角色 C　设计预算 35 秒

现在把案例放回同一把尺子。第一，改了什么，是模型权重，还是算法、代码和工作流程？第二，谁来验证，在什么任务上算有效？第三，改进后的系统，能不能继续承担下一轮研发，让这种收益持续下去？公开案例已经展示了局部改进，也展示了有反馈的研究循环。但这些材料还不足以证明：一个系统能持续、

自主地研发并验证更强的后继基础模型。接下来，我们用自己的协作经历说明，为什么最后这道判断仍然重要。

本页记住：RSI 判断需要改动对象、验证范围和持续后继研发三方面证据。

15 我们的协作：快交付，再检查

建议角色 D　设计预算 35 秒

我们准备报告时，也把检索、整理和制作初稿交给了 Codex。初稿很快就出来了，但项目发起者审阅后发现：主题偏窄，目录不清楚，讲稿也很难直接讲。于是重新限定研究问题，要求补上历史和行业对照，再把抽象结论改成具体任务。这是一段真实发生的协作：人提出任务和判断问题，Agent 执行检索、制作与修订。它给了我们很多产物，但产物齐全，并不自动意味着报告已经讲得清楚。

本页记住：真实课程实践是项目发起者评审与 Codex 执行之间的任务、反馈和版本修订。

16 核查案例：65%的分母

建议角色 D　设计预算 30 秒

再用一个核查案例说明：如果把 65%读成安全通过率，就会以为一百次测试通过了六十五次。我们用这种误读做了核查题，不能说初稿真的犯过这个错。原文算的是十维 Petri 的覆盖加权改善空间。Agent 可以帮忙定位和整理，最终要判断的，是数字的解释是否忠实于原文。这属于报告来源核查，不是复现公司的模型训练。

本页记住：65%通过率是人为设置的待审命题，不冒充已发生的初稿错误。

17 已经发生的进步，与仍需回答的问题

建议角色 D　设计预算 25 秒

回到题目，智能体已经进入真实研发流程，在限定任务上交出了有效结果。距离递归自我改进，关键缺口是这些进步能否持续带来下一轮研发能力，并接受可靠验证。人的职责，也随之集中到选对问题、设定权限和判断结果。一次成功，还不能外推成完整循环。

本页记住：局部研发任务已获支持，持续后继研发及可靠验证仍是缺口。

18 回到任务、改动和验证

建议角色 D　设计预算 15 秒

最后记住：接手什么任务，真正改了什么，怎样验证、能否延续。AI 帮助开发 AI 已经发生；持续的递归自我改进，还需要更多证据。谢谢大家，欢迎提问。

本页记住：结束时回扣全场主线并进入答辩。

15 分钟扩展与答辩准备

四段扩展正文、12 个备课追问和 16 题详细答辩，分别见 01_自然口播稿、02_四人快速备课和 03_答辩手册。此打印稿保留主讲正文，避免上场时从资料堆里找要朗读的句子。