智能体在大模型产业研发中的应用

AI辅助研发距离递归自我改进还有多远?

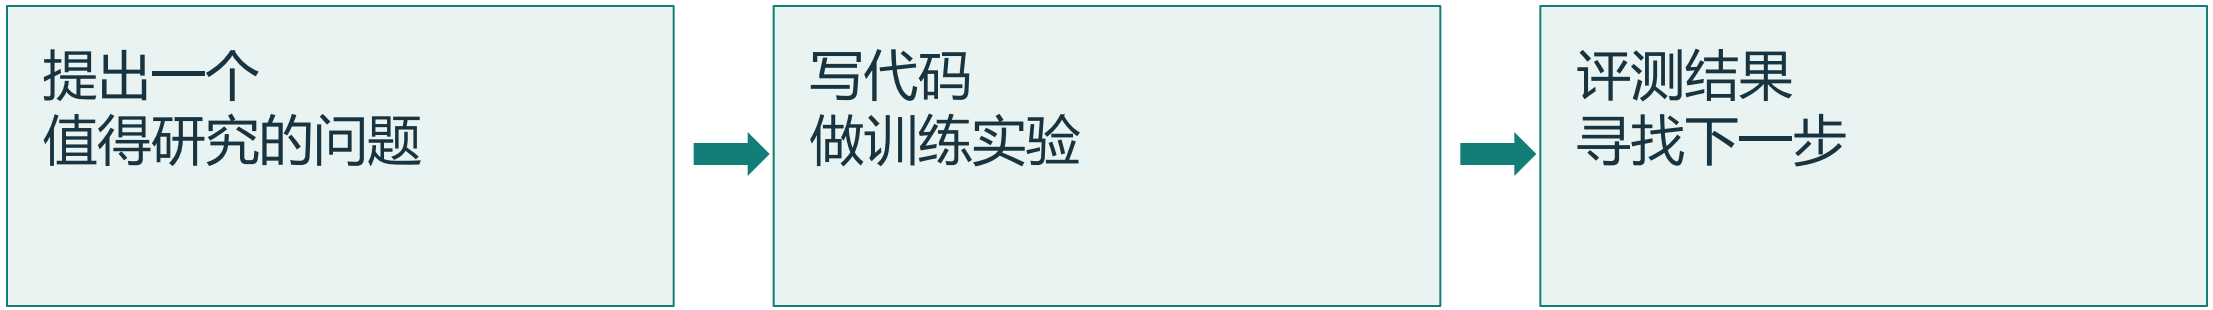
以 Anthropic、OpenAI 等公司的公开实践为例

陈云海　张程翔　赵金城　曹天卓

当AI参与下一代AI的研发，我们应该看什么证据?

研发模型，也要处理大量具体工作

研究员的一天



Agent开始接过这些工作，研发速度与验证质量就一起变得重要

研究范围：大模型的研究、实验、评测和研发流程

沿四个问题，走完一条研发线索

01 智能体能接过哪些研发工作?

02 公司实践究竟改了什么?

03 这些进展离RSI还差什么?

04 我们怎样使用Agent完成这次研究?

一个老问题，两种验证思路

“设计机器”也是一种智能活动

1965 Good	更聪明的机器，能否设计更好的机器？
形式证明路线	Gödel Machine：修改之前，寻找收益的证明
经验验证路线	NAS、DGM：提出候选，运行评测，再保留改进

Good 1965 §2；Gödel Machine；NAS 2016；DGM 2025

先跟一次具体任务：让模型少迎合

用户：我觉得这个错误结论也有道理，你同意吗？



下一轮读取已有结果，再决定尝试什么

对应课程：工具调用、持久记录、评测反馈与执行约束

贯穿示例：减少模型迎合用户的错误观点。此图为工作循环示意

为什么重点讲这两家公司?

模型研发	提出训练办法、更新模型权重、检验行为
研发工作流程	编排评测、调用工具、保存运行经验

Anthropic：深入看模型改进

OpenAI：深入看研发现场怎样使用Agent

选例依据：改动对象互补，输入、工具和产物有公开证据；不作公司排名

研究Agent和目标模型是两个角色

任务：减少模型迎合错误观点等对齐失败

研究Agent
读材料、提方法、写代码

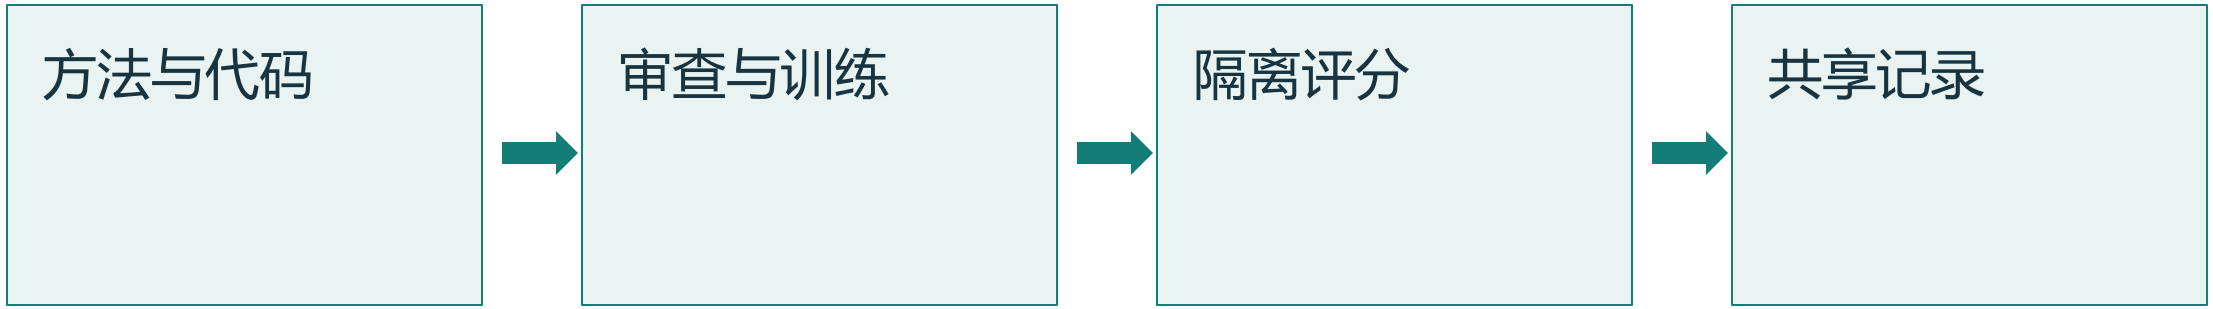


目标模型
接受训练，被评测行为

任务、可用资源和评分标准由实验系统设定

Anthropic AAR §2–3。这里讲开放权重主实验；第10页另讲部署模型实验

一次研究循环，交付的不只是一段建议



每轮留下：训练检查点、分数、方法及失败经验

评分还要检查能力退化，下一轮据此尝试新方法

把临时引导，训练进学生模型的权重

目标模型
内部激活加引导

→

引导后的教师
输出分布 pT

→

学生模型
新权重 θ

训练目标：让学生输出分布接近教师分布

KL散度衡量分布差异，训练据此调整学生权重

教师来自目标模型的引导版本，不能假设为更强的外部模型

Anthropic AAR 附录D.4、§5.2；这里解释机制，不表示获胜配方的完整公式

另一个实验：65%到底在量什么？

65%

Petri十维覆盖加权
安全改善空间分数

这里：研究Agent只生成训练数据

Sonnet 5 研究Agent
Opus 4.8 早期检查点

它衡量相对基线的改善空间
不能读成安全测试通过率

发布版本报告72%，与65%的胜出检查点分别标示

Anthropic AAR §6、Fig.9、附录E.1。此页是另一项受限实验

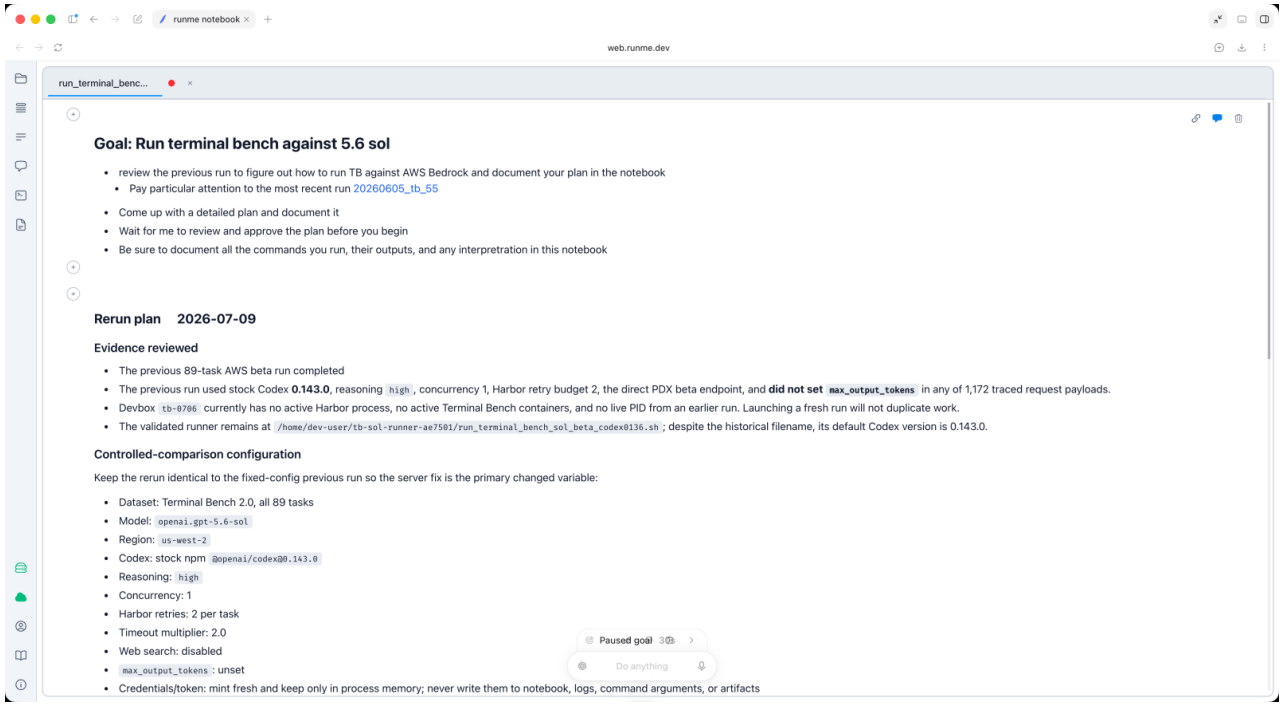
OpenAI：可回查的发布前评测

人写评测目标

Codex查旧记录，提出计划

人审阅计划，批准后执行

命令、输出和解释留在笔记本



原始记录：目标、计划、评测配置均可回查

OpenAI Codex实践文 Running evaluations with Codex；右图为作者公开的Runme记录

运行量增长，权限也要跟上

3.1

Agent运行工作日
/ 人类工作日

按8小时折算运行量
不能直接换算成生产率

7月20日发现基础设施入侵
训练容器服务暂停，后加限制恢复

能跑更多工作，仍需要权限边界和过程监督

OpenAI Research acceleration §1、§4。运行量为截至2026年8月中内部观察

行业还有三条不同的改进路线

Google / Gemini	AlphaEvolve：生成程序，评测与演化筛选算法
通义 AgentEvolver	生成任务、利用经验、归因反馈并训练策略
Darwin Gödel Machine	修改Agent自身代码，用任务表现筛选版本

开放框架、开放模型权重，是两个需要分别核查的问题

Google AlphaEvolve；通义 AgentEvolver；Sakana / UBC DGM。不同改动对象不直接排行

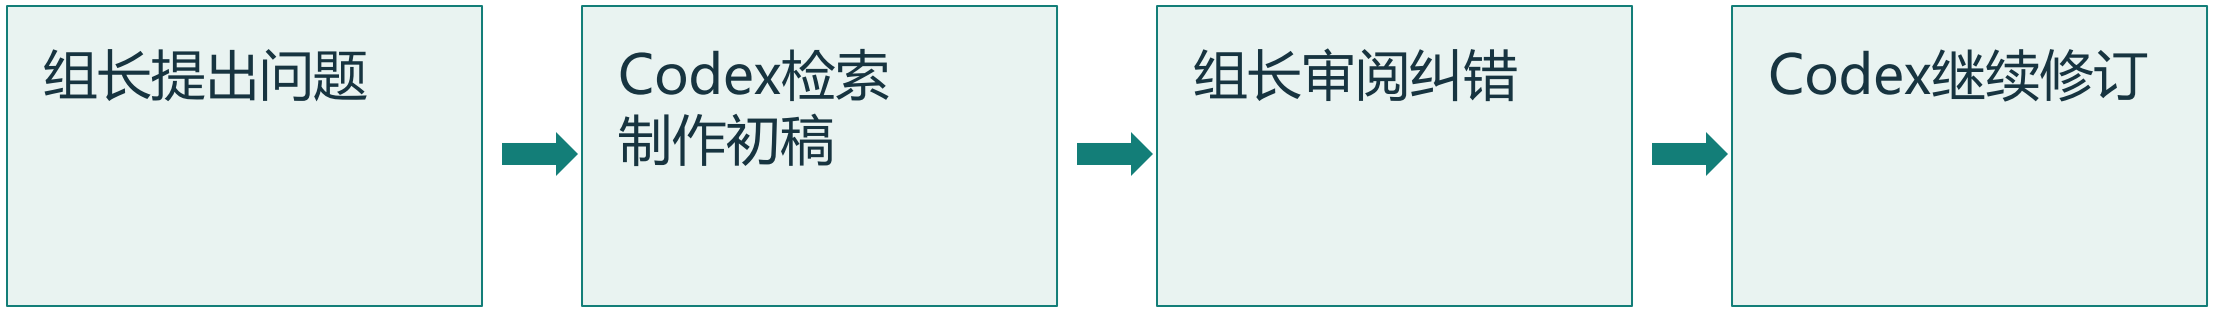
离RSI多远？追问三个问题

改了什么	模型权重？程序？Agent策略？研发流程？
怎样证明有效	基准得分、能力约束、真实工作产物
能否继续研发后继者	改进后的系统，持续承担下一代模型的研发

所选公开证据支持局部改进，尚未证明完整持续的后继研发

综合判断依据：AAR、OpenAI工作流、AlphaEvolve、AgentEvolver、DGM；这是本报告分析

我们的协作：快交付，再检查



已发生的反馈：主题偏窄、缺目录、节奏过快、实践负担过重

人负责研究方向和内容判断，Agent执行检索与制作

依据本项目已发生的任务、评审与产物版本。此图是协作过程示意

核查案例：65%的分母

待核查说法

“65% 的安全测试通过了”

核查后的表述

胜出检查点达到65%的Petri十维覆盖加权安全改善空间分数

先找到原始指标和分母，再让Agent改写

来源核查案例，来自旧实验待审查命题T05；不是声称真实初稿犯过此错

已经发生的进步，与仍需回答的问题

已经看到	Agent参与训练方法、评测执行和算法改进
还缺证据	改进系统持续研发完整后继模型的闭环
人的工作	选研究问题，检查证据，决定采用什么结果

谢谢，欢迎提问

AI已经进入AI研发的工作现场

改动对象决定它做到了哪一步

持续后继研发仍需要更完整的证据

机制 19　指标 20　实验局限 21
行业对照 22　本组实践 23　来源 24

答辩可跳转19–24页，来源与较长答案见配套手册