A 部分口播与练习

对应第 1—7 页：提出全场问题，说明 RSI 与 autoresearch 的关联，再把三个角色交给 B。以下口播与主讲源逐页一致。3 分 25 秒是设计预算，尚未真人计时。

先记住一句话：**自动研究让 AI 做实验；递归自改进一步看，成果能否让研究者更会做下一轮研究。**

对照七页投影讲一遍，记录时长和卡住之处即可；深入解释查组长 A 备课，不把整本问答塞进主讲。

01 智能体在大模型产业研发中的应用

大家好。今天我们看智能体怎样参与大模型研发。AI 不只在帮助完成任务，也开始帮助研发 AI 本身。那么，这些改进能不能让下一轮研发变得更快、更好?

指图与动作：先说研究对象，再指副标题，把“下一轮”留给全场回答。

02 RSI：让改进能力进入下一轮

RSI 的英文是 Recursive Self-Improvement，中文叫递归自我改进。这里的递归，是说改进后的系统还能继续参与后续改进。早在 1965 年，Good 就设想过机器设计更好的机器。今天我们把这个问题落到研发上：不只看它产出了什么，还要看它是否更有能力做下一轮研究。

指图与动作：先读英文与中文，再顺着返回箭头解释“递归”，历史一句带过。

03 autoresearch：先把实验循环交给 AI

一个直观入口是 Karpathy 今年三月开源的 autoresearch。AI 修改训练代码，让小模型训练五分钟，再看验证指标，保留有效修改，继续尝试。原版用一张 GPU 就能开始。它把研究中的实验循环自动化了。RSI 则进一步追问：这些成果能不能让研究者自己更会研究？所以，自动研究是走向递归自改的一条路径，但完成一次实验循环，还没有回答后一个问题。

指图与动作：沿实验循环讲一遍，最后把目光从产出的模型转到做研究的 Agent。

04 研发能力也能改进，意义就不止一次提效

这正是它值得重视的地方。一次提效，只让眼前任务做得更快；如果改进还能提高研发能力，就可能让下一轮更容易找到好方法。更强的 AI 帮助研发，研发再带来更强的系统，形成正反馈。它有机会产生复利式、甚至指数式的增长。不过，这需要增益持续成立、资源和评测跟得上，不能把一张反馈图当成已经发生的智能爆炸。

指图与动作：顺着正反馈讲价值，再指条件；这张图解释机制，不是实测增长曲线。

05 小实验能起步，前沿规模还要过资源关

但从小实验走到前沿模型，是另一道门槛。研究 Agent 需要有用的想法和工具，试验要付出推理成本，模型训练还需要相应算力。方法在小模型上有效，也要检验放大后是否仍有效。这让我们判断所谓 RSI 算法时，不能只看名字，要看实际规模、预算和可重复的提升。数据和 benchmark 本身可以有价值，但有这些产品，不等于已经实现持续自我改进。算法能省多少资源，资源又允许验证到哪一步，要放在一起看。

指图与动作：依次讲会研究、跑得起、能成立，商业判断落在最后的实际检验上。

06 从自动实验，追到下一轮研发

现在，自动跑实验、优化训练程序，以及 Agent 修改自身代码，都已有公开实例。最近的 AIDE²也报告了研究 Agent 代码层的连续改进。接下来，我们重点看 Anthropic 怎样改模型，OpenAI 作者怎样组织评测，再用 Google 和开放研究补齐程序与 Agent。沿着这条研发链，最后再回答：哪些成果已经回到下一轮，还有哪些能力需要继续验证?

指图与动作：沿研发链介绍案例分工，AIDE²一句点到，把技术细节交给后文。

07 任务：让模型少迎合错误观点

先落到 Anthropic Fellows 的一项对齐研究：让模型少迎合用户的错误观点。这里有三个角色。Claude Opus 4.8 驱动研究 Agent，负责想方法、写实现；Qwen3.5-2B 是被训练的目标模型；评测器检查行为改善和能力副作用。先分清谁在研究、谁被改变，下面再看 Agent 怎样把一个想法变成训练和评测。

指图与动作：依次指出研究 Agent、目标模型和评测器，末句接 B 第 8 页的实验流程。