A 部分口播与练习

7 页 205 秒为设计预算，未真人计时；先对照投影讲一遍，深入解释见备课。

01 智能体在 AI 研发中的应用

我们看 Agent 怎样参与 AI 研发，帮助改进模型、工具与 Agent 自身。

指图与动作：题目和一句副标题即可，不在封面展开解释。

02 Inspiration：让 Agent 参与研发

Agent 开始进入越来越多的真实任务。要让它们更可靠，模型能力、工具和行动流程都需要持续改进。这些研发原本主要由人完成。现在，Agent 也能写代码、用工具、运行实验，于是我们想问：能不能让 Agent 在人类引导下，直接参与改进模型与 Agent 自身?

指图与动作：沿因果图讲需求、研发迭代与 Agent 参与。

03 从已有系统出发，沿四部分看它怎样变好

整场沿一条主线：从已有系统出发，Agent 参与修改和验证，让它更好。先讲选题与主线，再看 Anthropic 的模型训练，接着看 OpenAI 与 Google 的研发流程和程序优化，最后看 Agent 自我改进与下一轮研发。

指图与动作：沿四部分目录指出整场路线。

04 从自动研究，走向递归自我改进

RSI 是 Recursive Self-Improvement，递归自我改进：改进后的系统还能推动下一轮改进。Karpathy 今年三月开源的 autoresearch 提供了一个小入口：Agent 改训练代码，让小模型训练五分钟，比较结果，再继续。这是自动研究；要进一步谈 RSI，还得看成果能否让研究者自己更会研究。如果成果能回到研究者身上，就有进一步加速研发的潜力。

指图与动作：先解释 RSI，再指自动实验循环，最后交代能力回流。

05 跟着案例，只抓两个问题

这次我们不展开资源竞争，只跟着实际案例看两件事：Agent 改了什么，怎样验证改进有效。模型训练、程序优化与 Agent 代码修改，改变的是不同对象。先分清对象和结果，最后再看它怎样帮助下一轮研发。

指图与动作：只提出改动对象和验证两个问题。

06 从自动实验，追到下一轮研发

Agent 的能力由模型、工具和运行流程共同支撑。所以我们选 Anthropic 看模型训练，选 OpenAI 与 Google 看评测和程序优化，再用开放研究看 Agent 自身改进。AIDE[2]也报告了代码层的连续改进。这样，后面每个案例都能接回同一个研发问题。

指图与动作：对应模型、工具和 Agent 自身三类案例。

07 任务：让模型少迎合错误观点

先从 Agent 的重要基础——模型能力看起。Anthropic Fellows 的一项研究要减少模型迎合错误观点。Claude Opus 4.8 驱动研究 Agent，提出方法和实现；Qwen3.5-2B 是被训练的目标模型；评测器检查改善和能力副作用。这里，Agent 是研发者，模型是改进对象。下面看它怎样把想法变成训练和评测。

指图与动作：指三个角色，明确 Agent 是研发者、模型是改进对象。