B 部分口播与练习

对应第 8—13 页，接 A 的研究任务与角色介绍，再交给 C 的评测工作流。以下口播与主讲源一致。4 分 20 秒只是设计预算，尚未真人计时；第 11 页配合 18 秒短片，第 12、13 页要解释公式和数字。

先记住一句话：**研究 Agent 提出方法，训练工具改变目标模型，独立评测检查结果；激活引导先改变教师输出，蒸馏再训练学生参数。**

对照六页投影讲一遍，记录时长，反馈不理解或讲不顺之处即可，无需另交技术问答。深入解释由组长查配套备课，不塞进主讲。

08 一轮研究要交付可审查、可训练、可评测的方法

从左往右看，一轮研究需要交付一个真正能运行的方法。研究 Agent 先读资料、看已有结果，提出训练假设；在看到本轮结果之前，先冻结 mini-paper，把方法、数据和训练目标写清楚。随后提交实现，检查代码是否和说明一致、是否违反实验规则。系统再运行训练，更新目标模型权重；典型预算约一张 H200、半小时。最后由独立评测器同时检查安全改善和能力退化，所以不是分数提高就够了，还要看有没有明显副作用。

指图与动作：沿五步流程从左到右，最后点明“独立评测”同时检查改善和副作用。

09 下一次尝试，能读到之前的成功与失败

一次尝试结束以后，结果不会随着聊天结束就消失。多个研究 Agent 可以并行探索不同候选，而文献综述、方法代码、实验得分和失败经验会进入共享记录。新会话开始时，可以重新读取这些持久记录，再决定下一次往哪里试。所以这里的记忆是一套外部工程机制：经验能被后续会话复用，但研究 Agent 自己的模型权重并没有因此自动更新。真正被训练的是目标模型，而不是研究 Agent 本身。

指图与动作：沿共享记录到新会话的箭头，强调经验被读取与参数被训练是两回事。

10 先用激活引导，构造一个更少谄媚的教师

接下来我们看一条真正成功过的技术路线。第一步不是立刻训练学生，而是先构造一个表现更好的教师。模型回答问题时会形成内部表示，激活引导尝试对隐藏状态施加方向性干预；图上的 h 变成 h′只是教学写法。它不是把某道题的答案拼进提示词，而是让内部计算更少迎合用户的错误观点。引导后，目标模型形成一个临时更好的教师版本，但这项变化还没有写进模型权重。下一步的问题就是：怎样把这种临时变化保留下来？

指图与动作：先指出原目标模型与隐藏状态，再指引导后的教师，末句转向下一页的参数训练。

11 再用 KL 蒸馏，把教师行为写进学生权重

下一步，是把教师带来的行为变化真正写进学生参数。教师和学生面对同一个输入，各自产生回答分布。教师是目标模型的引导版本，提供更少谄媚的训练目标；学生是等待训练的目标模型。训练利用 KL 约束，让学生学习教师的输出倾向，所以参数更新发生在学生身上，教师负责提供训练信号。训练结束后，再去掉临时激活引导，让学生正常推理并接受独立评测。短片只是机制教学示意；分布更接近不等于模型必然更安全，最终仍要检查行为改善与能力副作用。

指图与动作：跟随短片依次说明教师分布、KL 训练信号和学生更新，最后指正常推理与评测。

12 改善空间：先弄清百分数的分母

这一页先定义指标。改善空间关闭比例，是训练带来的提升，占“基线到参考最优”原有差距的比例。看这个式子，分子是实际提升，分母是原本还能提高多少。用教学数值代入：基线 50，训练后 70，参考最优 100，分子是 20，分母是 50，所以补回了 40%的原有差距。这个 40%不是训练后正确率；论文还会用几何平均数汇总多个安全测试，所以后面的 23.3%也不能直接读成通过率。

指图与动作：先指公式中的分子和分母，再代入例子，避免把整条公式重复朗读两遍。

13 同一案例中，训练目标比增加数据自由度更关键

现在看真实结果。这是在同一个谄媚任务、同一个目标模型下，对前 150 个已评分方法的比较。原样公共数据 SFT 是 6.0%，自由构造数据 SFT 是 2.9%；允许 SFT 加 KL 自蒸馏后达到 16.5%，进一步放开方法空间则达到 23.3%。所以这张图比较的是不同方法搜索条件：在这个案例里，训练目标和机制比单纯增加数据自由度更关键。每个条件只有一次搜索运行，这些结果也没有重跑 held-out 或 Petri，因此不能当作普遍规律。下一部分换到评测工作流。

指图与动作：依次对照四种搜索条件，说明单任务、单模型、每条件一次运行，再把问题交给 C。