一轮研究要交付可审查、可训练、可评测的方法

01

提出假设

资料、文献与已有结果

→

02

冻结mini-paper

训练前写明方法、数据与损失

→

03

提交实现

代码与说明一致；通过规则检查

→

04

训练目标模型

产出更新权重；约1张H200、30分钟

→

05

独立评测

安全改善与能力退化

基本规则：禁用评测数据；禁止从研究Agent或更强模型蒸馏

筛选原则：安全改善不能以明显能力退化为代价

[4] Chen等, AAR, 2026；§3、§3.1—3.2

下一次尝试，能接着读到之前的成功与失败

多个研究Agent并行探索

提出候选方法
分别提交训练与评测

→

共享记录持续累积

文献综述、方法代码
实验得分、失败经验

→

新会话读取后继续研究

读取持久记录继续尝试
Agent权重不因此更新

←

研究能接续：经验保存在外部记录里，而不是自动写回研究Agent参数

[4] Chen等, AAR, 2026；§3、§3.1

先用激活引导，构造一个更少谄媚的教师

目标：让模型更少迎合用户的错误观点

1 原目标模型

Qwen3.5-2B正常前向
内部表示 h

→

2 方向性干预

作用于隐藏状态
教学示意 $h' = h + \alpha v$

→

3 引导后的教师

目标模型的引导版本
更少倾向附和错误观点

→

4 待解决问题

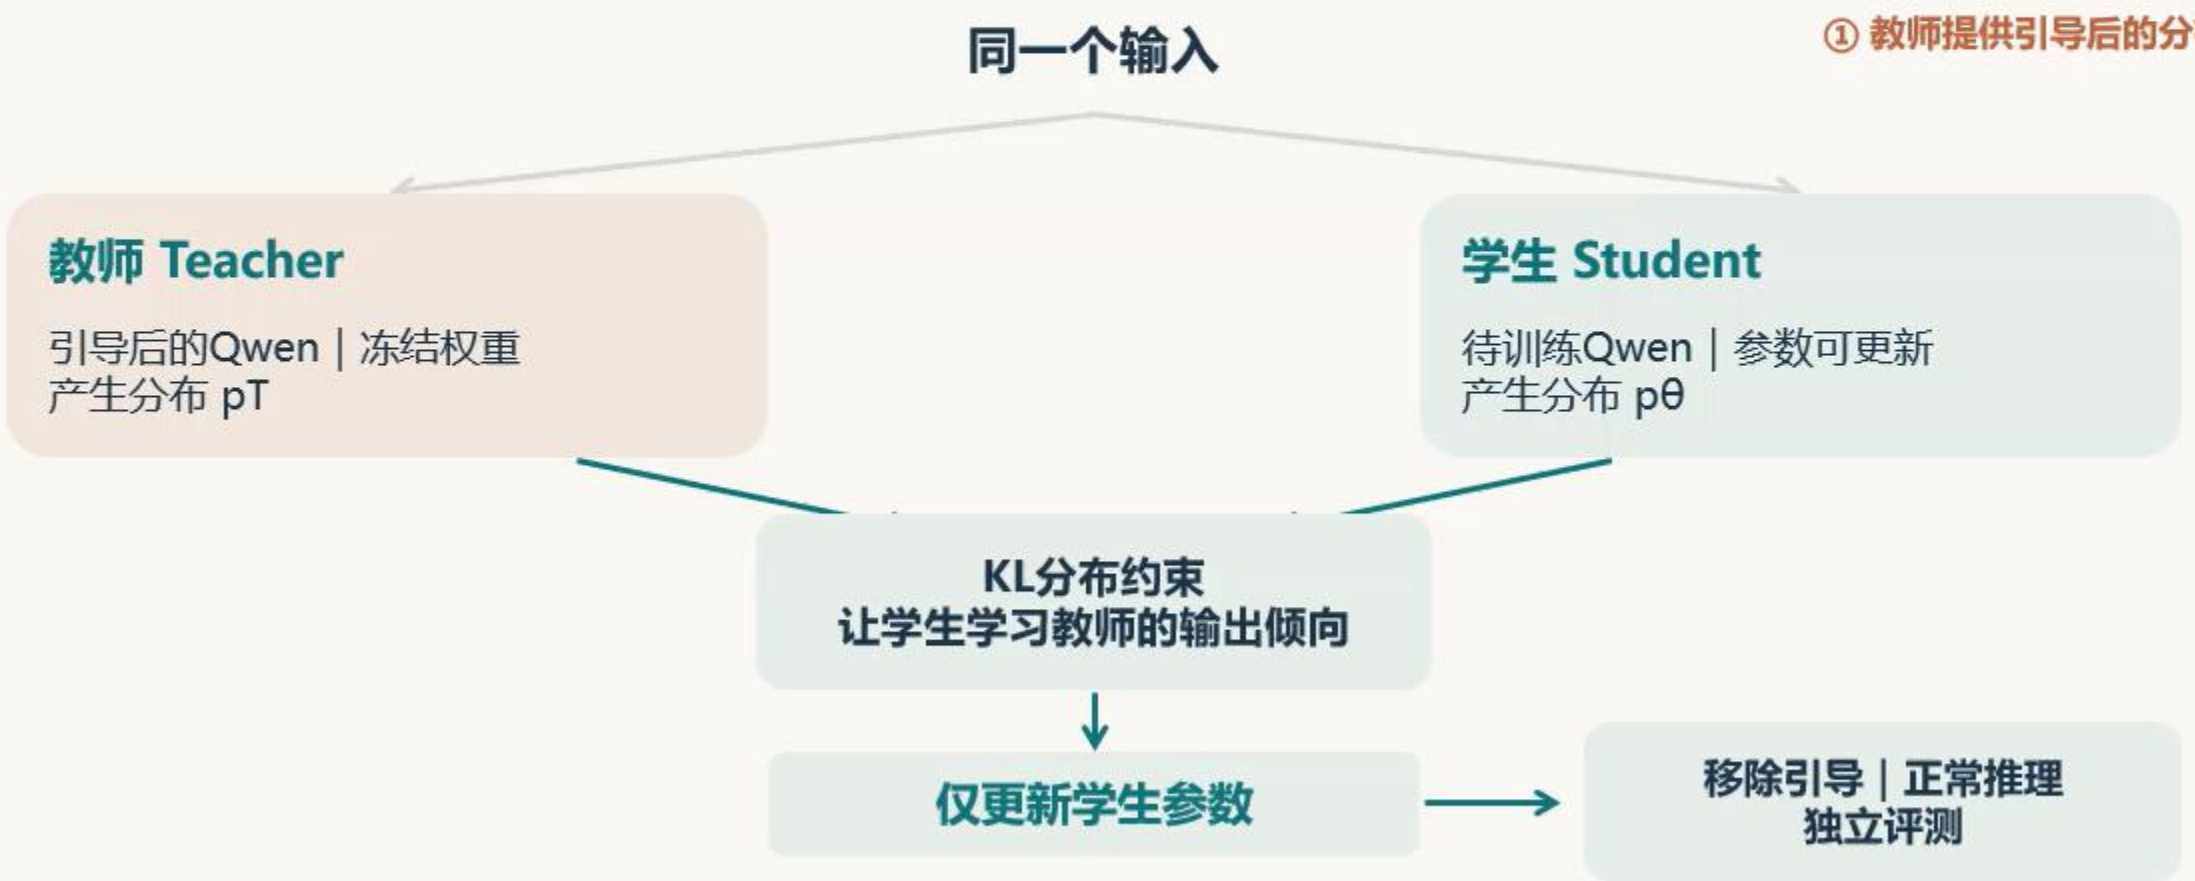
推理时的临时变化
怎样保留到正常推理?

教师来自Qwen目标模型的引导版本，不是Claude Opus 4.8

激活引导改变内部表示，不是把某题正确答案拼进提示词

[4] Chen等, AAR, 2026；App. D.4；机制教学示意

再用KL蒸馏，把教师行为写进学生权重



参数更新发生在学生模型；教师提供训练目标

KL方向与完整配方由具体方法定义

[4] Chen等, AAR, 2026；App. D.4；机制教学示意

改善空间：先弄清百分数的分母

定义 改善空间关闭比例：训练带来的提升，占“基线到参考最优”原有差距的比例。

$$(\text{训练后得分} - \text{基线得分}) \div (\text{参考最优得分} - \text{基线得分})$$

一个小例子

基线	训练后	参考最优
50	70	100

代入定义

$$(70 - 50) \div (100 - 50) = 40\%$$

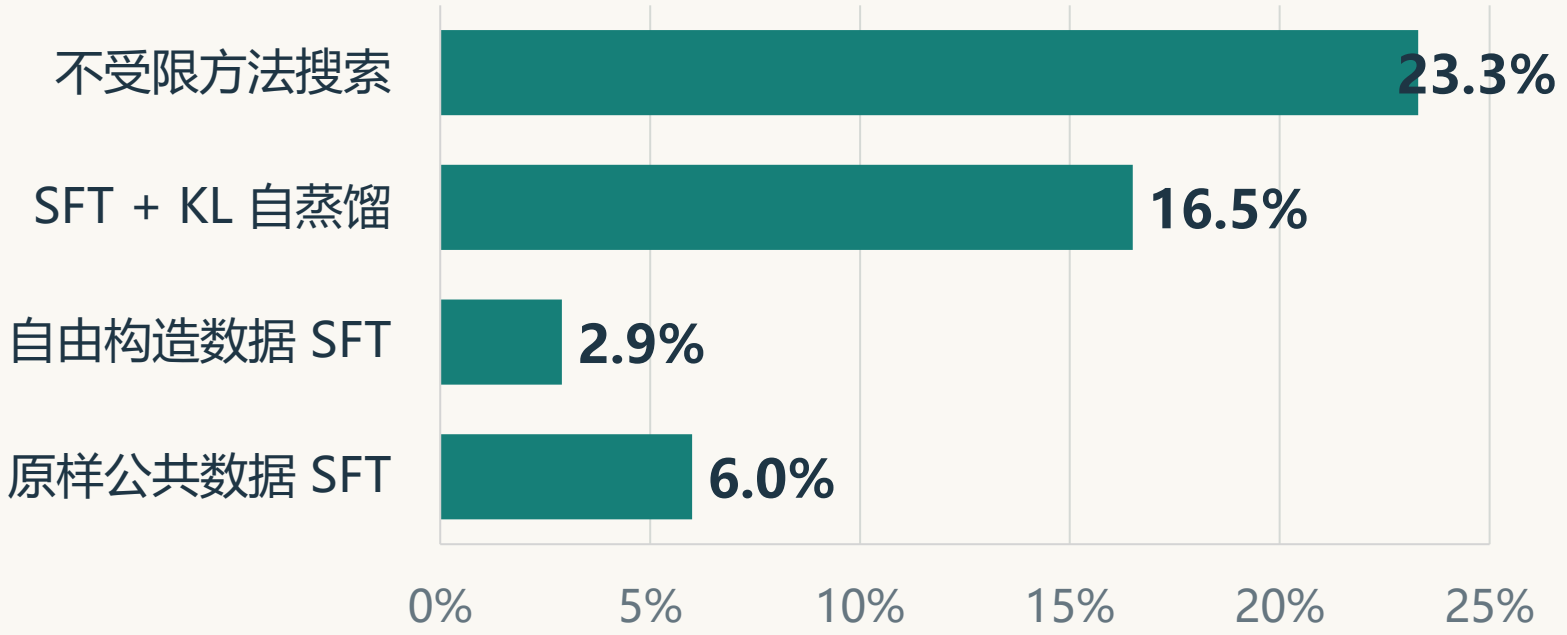
直观理解：原本还差50分，现在补回20分，因此关闭了40%的原有改善空间。

注意：40%不是训练后正确率；多个安全测试还要用几何平均数汇总。

[4] Chen等, AAR, 2026；§2.2；定义与教学数值

同一案例中，训练目标比增加数据自由度更关键

Qwen3.5-2B谄媚任务 | 前150个已评分方法



比较的是搜索条件

允许的方法不同
不是同一模型逐步加模块

限定范围

单个任务、单个目标模型
每条件一次搜索运行
未重跑held-out或Petri

横轴：安全改善空间关闭比例（%）

[4] Chen等, AAR, 2026；Fig.20；App. D.4