C 部分口播与练习

赵金城负责 14—18 页；五页预算 195 秒（3 分 15 秒），未真人计时。作为全场研发流程与程序优化段，承接 B 的模型训练，接向 D 的 Agent 自身改进。以下口播与正式 PPT 备注一致。

14 另一个环节：跑清楚发布前评测｜预算 35 秒

前面看的是训练模型，现在换一个研发环节：发布前评测，也就是在模型或功能上线前，检查它是否符合预期。OpenAI 工程师 Jeremy Lewi 公开过自己的工作流：研究员确定评测目标，Codex 读取工具说明和既有记录，找工具、准备命令、处理执行问题，再帮助解释结果。这里改变的是评测流程。我们顺着任务看下去：谁决定开始执行，结果又怎样留下来？

指图与动作：先指研究员的目标，再指 Codex 的具体工作；先交代改进对象。

15 执行之前，研究员先审阅计划｜预算 40 秒

屏幕上这句原文很直接：开始之前，等我审阅并批准计划。顺序是先有目标和既有记录，Codex 拟计划，研究员批准后，再由 Codex 执行具体命令。命令跑得通，不代表它回答了正确的问题。审阅计划，是为了检查准备跑哪些评测、是否漏掉关键条件。人负责目标、审阅和关键取舍，Agent 负责获批后的具体执行。这展示的是作者自己的工作流，不能替整个公司作保证。

指图与动作：先读中文意思，再沿三步流程；批准后由 Codex 执行。

16 Runme 把过程留给下一次任务｜预算 40 秒

Runme 把命令放在笔记里执行，输出也能跟着保存。目标和计划说明为什么做，命令与输出记录实际发生了什么，解释与取舍交代下一步依据。后续会话找到并读取这些记录，就可以接着处理任务。它和前面的共享实验记录一样，能减少重新摸索。这里改善的是 Agent 可用的上下文，没有展示 Codex 的权重训练。记录可以帮助任务做得更好，但保存下来，还不等于下一次一定正确使用。

指图与动作：从目标、命令到取舍依次指；明确外部记录与参数训练的区别。

17 AlphaEvolve 把程序候选交给自动评测｜预算 40 秒

Google DeepMind 的 AlphaEvolve 把生成、执行和筛选循环用在程序上。Gemini 提出候选，自动评测器验证、运行和打分；程序数据库保存候选，由进化算法挑选父代，再产生下一轮修改。这里改的是程序，不是直接训练 Gemini 的权重。评价也能落到实际运行上：算对没有，快了多少。这样的 Agent 不只给出建议，还要把程序交给运行结果检验。那么，程序改好了，怎样帮助大模型研发?

指图与动作：沿候选、评测、数据库与返回箭头，说明程序如何进入下一轮。

18 算子加速 23%，对应总训练时间减少 1%｜预算 40 秒

官方报告，一个矩阵乘法 kernel 加速 23%，对应 Gemini 总训练时间减少 1%。左边是局部算子，右边是完整训练，分母不同：训练还有其他大量工作，所以局部加速不能直接套到全程。官方还报告，同类 kernel 优化由专家数周工作，转为数天自动实验。这是具体案例中的收益，不是所有研发的通用比例。程序能被改进并用于训练，那么，被改的对象能不能换成 Agent 自身?

指图与动作：先指 23%的局部算子，再指 1%的整段训练；最后一句交给 D。

练习时检查

先自然讲一遍并计时，卡住时删重复解释，不抢读数字。能够说明谁定目标、谁执行、记录存在哪里，以及 23%和 1%分别测量什么。更深追问查组长 C 部分答辩备课。媒体只在 B 第 11 页，本段无需额外操作。