另一个环节：跑清楚发布前评测

发布前评测：模型或功能上线前，检查是否符合预期

研究员	确定本次评测目标			
Codex	找工具	准备命令	处理执行问题	解释结果

Agent参与评测流程：人设定目标，Codex执行获批步骤

[5] Lewi，Codex评测工作流，2026

执行之前，研究员先审阅计划

作者给Codex的要求

> **“Wait for me to review and approve the plan before beginning.”**
> 开始之前，等我审阅并批准计划

目标与旧记录 → **Codex拟计划** → **人批准后由Codex执行**

研究员检查评测选择、关键条件与资源取舍

[5] Lewi，Running evaluations with Codex

Runme把过程留给下一次任务

Runme笔记

执行命令，并保存输出、解释和决定

目标与计划	为什么做，准备怎样做
命令与输出	实际做了什么，发生了什么
解释与取舍	后续会话可以读取判断依据

外部记录提供上下文，不是Codex权重更新的证据

[5] Lewi，Runme笔记与可复用上下文

AlphaEvolve把程序候选交给自动评测

Gemini
提出程序候选

→

自动评测器
验证、运行和打分

→

程序数据库
进化算法选择父代

←

数据库保存候选，选择父代后继续生成

改进对象：算法程序
用正确性与运行性能检验修改

[6] Google DeepMind，AlphaEvolve，2025

算子加速23%，对应总训练时间减少1%

23%

所举矩阵乘法kernel的加速

局部算子

1%

Gemini总训练时间减少

整段训练

同类kernel优化的工程时间（官方报告）

专家数周工作，转为数天自动实验

局部加速不等于整体加速：先看对象与分母

[6] Google DeepMind，Enhancing AI training and inference；官方案例，非本组复现