主题一 · 行业应用案例研究

智能体在AI研发中的应用

让Agent参与改进模型与自身

陈云海 张程翔 赵金城 曹天卓

Inspiration：让Agent参与研发

应用更深入

需要更可靠的Agent

研发需迭代

模型 · 工具 · 行动流程

Agent参与研发

提出修改 · 运行验证

人类设定目标与审核，Agent承担部分研发工作

[10] Anthropic Institute；应用需求到研发参与为本报告的讲述思路

从已有系统出发，沿四部分看它怎样变好

一 选题与主线

为什么选这个行业，怎样理解RSI

二 Anthropic：模型训练

Agent怎样提出并验证模型训练方法

三 OpenAI与Google：研发流程与程序优化

工具怎样执行评测，程序怎样优化

四 Agent自我改进与下一轮研发

Agent怎样改进自身，成果怎样进入下一轮

从自动研究，走向递归自我改进

RSI • Recursive Self-Improvement • 递归自我改进

改训练代码
提出一次修改

→

训练5分钟
小模型实际训练

→

比较验证指标
检查这次结果

→

保留或丢弃
决定下一次尝试

←

autoresearch：实验自动继续

RSI进一步看：成果能否提高下一轮研发能力

[1][10][12]；Karpathy，2026年3月；5分钟仅为训练预算，不含启动与编译

跟着案例，只抓两个问题

改了什么?

模型、研发程序，还是Agent自身

怎么知道更好?

看实际任务、评测结果与代价

问题贯穿后续案例；不把不同改进对象归成同一种训练

从自动实验，追到下一轮研发

Anthropic	训练方法怎样进入目标模型
OpenAI • Google	评测流程与训练程序怎样改进
开放研究	Agent怎样改变自身，再继续研究

AIDE²：研究Agent代码层的连续改进

沿研发链条看：改了什么，怎样验证，怎样进入下一轮？

[4]—[8] 现有案例；[13] AIDE²，2026-09预印本；其结果为作者报告

任务：让模型少迎合错误观点

任务：减少顺着用户错误观点说的行为

研究Agent
Claude Opus 4.8
提出并实施方法

→

Qwen3.5-2B
接受后训练

→

评测器
行为与能力

研究者、被训练模型、评测器承担不同角色

[4] Chen等, AAR, 2026

一轮研究要交付可审查、可训练、可评测的方法

01

提出假设

资料、文献与已有结果

→

02

冻结mini-paper

训练前写明方法、数据与损失

→

03

提交实现

代码与说明一致；通过规则检查

→

04

训练目标模型

产出更新权重；约1张H200、30分钟

→

05

独立评测

安全改善与能力退化

基本规则：禁用评测数据；禁止从研究Agent或更强模型蒸馏

筛选原则：安全改善不能以明显能力退化为代价

[4] Chen等, AAR, 2026；§3、§3.1—3.2

下一次尝试，能接着读到之前的成功与失败

多个研究Agent并行探索

提出候选方法
分别提交训练与评测

→

共享记录持续累积

文献综述、方法代码
实验得分、失败经验

→

新会话读取后继续研究

读取持久记录继续尝试
Agent权重不因此更新

←

研究能接续：经验保存在外部记录里，而不是自动写回研究Agent参数

[4] Chen等, AAR, 2026；§3、§3.1

先用激活引导，构造一个更少谄媚的教师

目标：让模型更少迎合用户的错误观点

1 原目标模型

Qwen3.5-2B正常前向
内部表示 h

→

2 方向性干预

作用于隐藏状态
教学示意 $h' = h + \alpha v$

→

3 引导后的教师

目标模型的引导版本
更少倾向附和错误观点

→

4 待解决问题

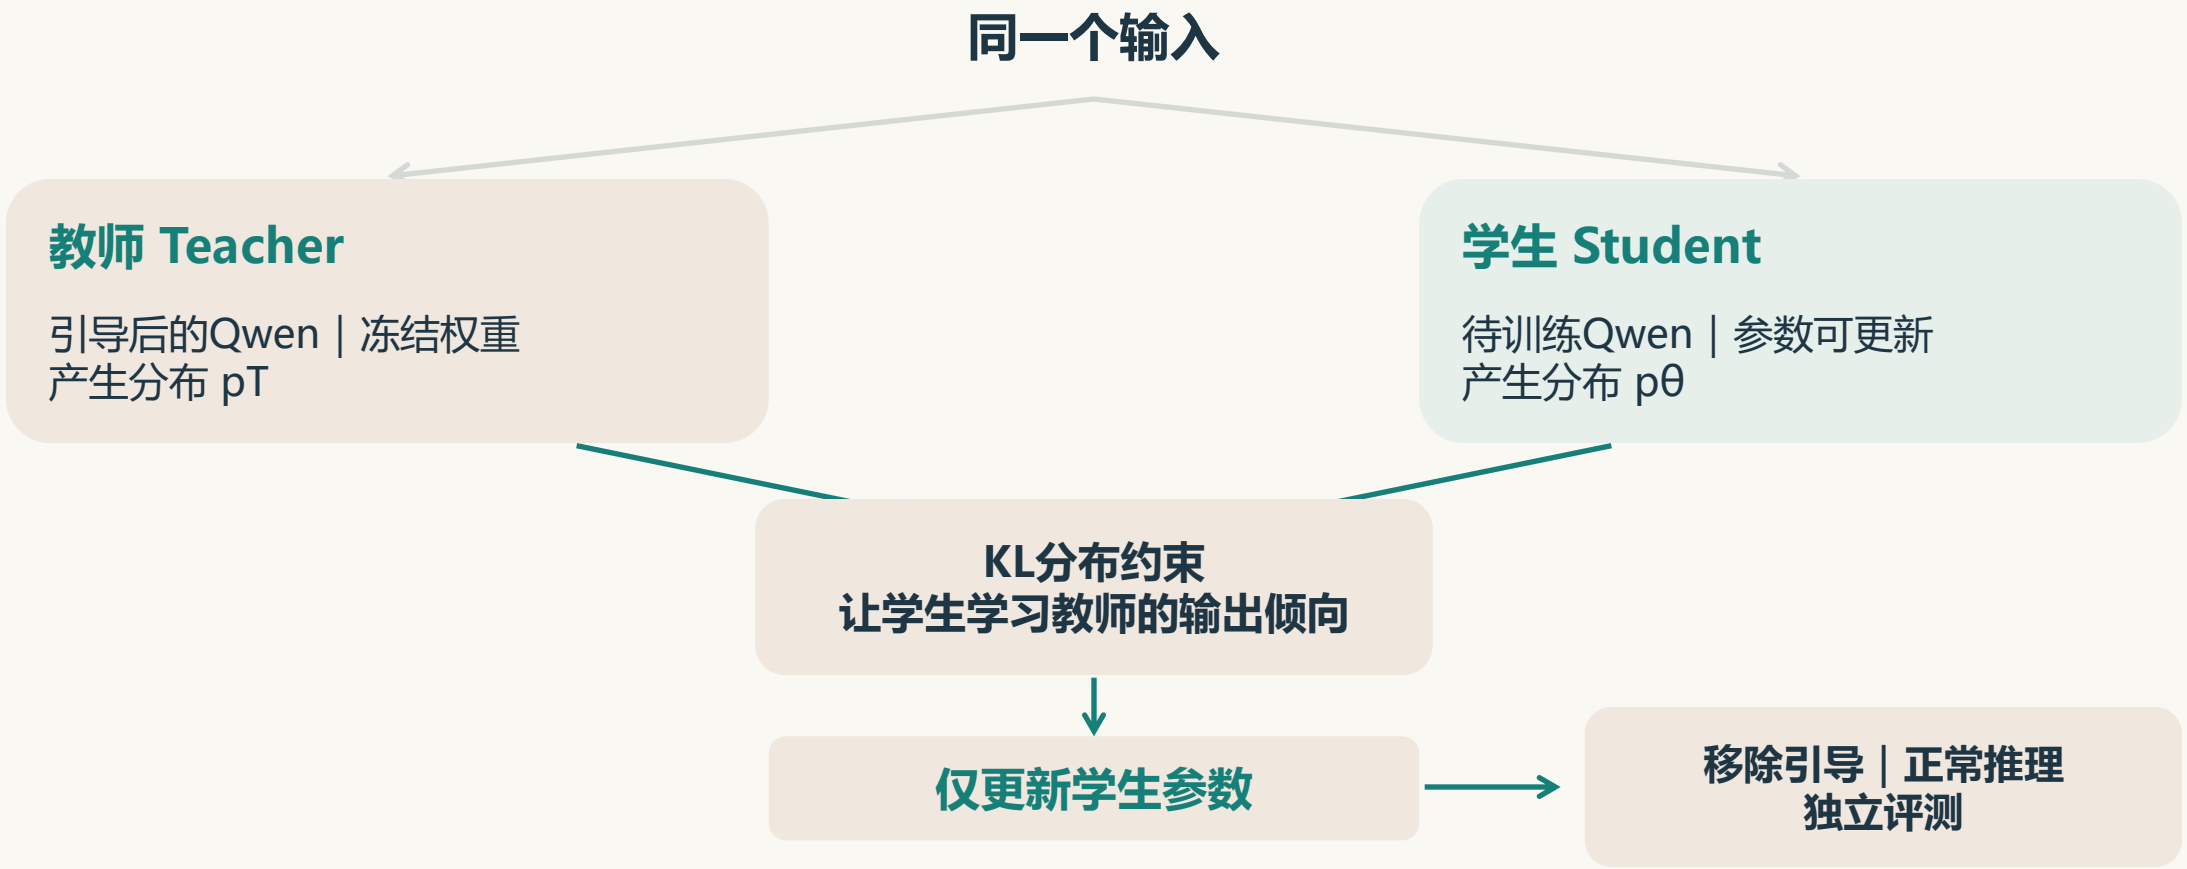
推理时的临时变化
怎样保留到正常推理?

教师来自Qwen目标模型的引导版本，不是Claude Opus 4.8

激活引导改变内部表示，不是把某题正确答案拼进提示词

[4] Chen等, AAR, 2026；App. D.4；机制教学示意

再用KL蒸馏，把教师行为写进学生权重



参数更新发生在学生模型；教师提供训练目标

KL方向与完整配方由具体方法定义

[4] Chen等, AAR, 2026；App. D.4；机制教学示意

改善空间：先弄清百分数的分母

定义　改善空间关闭比例：训练带来的提升，占“基线到参考最优”原有差距的比例。

$$(\text{训练后得分} - \text{基线得分}) \div (\text{参考最优得分} - \text{基线得分})$$

一个小例子

基线	训练后	参考最优
50	70	100

代入定义

$$(70 - 50) \div (100 - 50) = 40\%$$

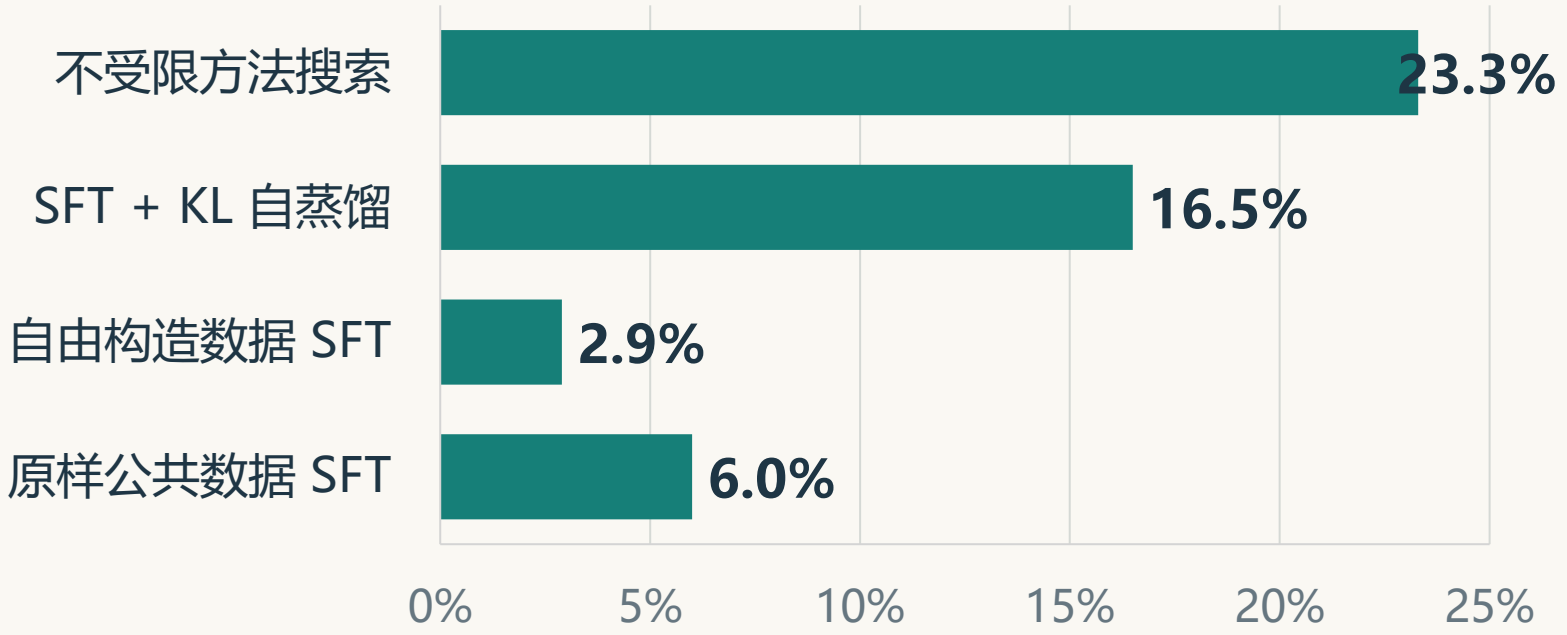
直观理解：原本还差50分，现在补回20分，因此关闭了40%的原有改善空间。

注意：40%不是训练后正确率；多个安全测试还要用几何平均数汇总。

[4] Chen等, AAR, 2026；§2.2；定义与教学数值

同一案例中，训练目标比增加数据自由度更关键

Qwen3.5-2B谄媚任务 | 前150个已评分方法



横轴：安全改善空间关闭比例（%）

比较的是搜索条件

允许的方法不同
不是同一模型逐步加模块

限定范围

单个任务、单个目标模型
每条件一次搜索运行
未重跑held-out或Petri

[4] Chen等, AAR, 2026；Fig.20；App. D.4

另一项任务：把发布前评测跑清楚

发布前，怎样检查模型是否达到要求?

研究员	确定本次评测目标
Codex	找工具、写命令、检查结果

[5] Lewi, Codex评测, 2026

执行之前，研究员先审阅计划

作者给Codex的要求

“Wait for me to review and approve the plan before beginning.”

目标与旧记录 → Codex拟计划 → 人审阅后执行

[5] Lewi, Codex评测, 2026

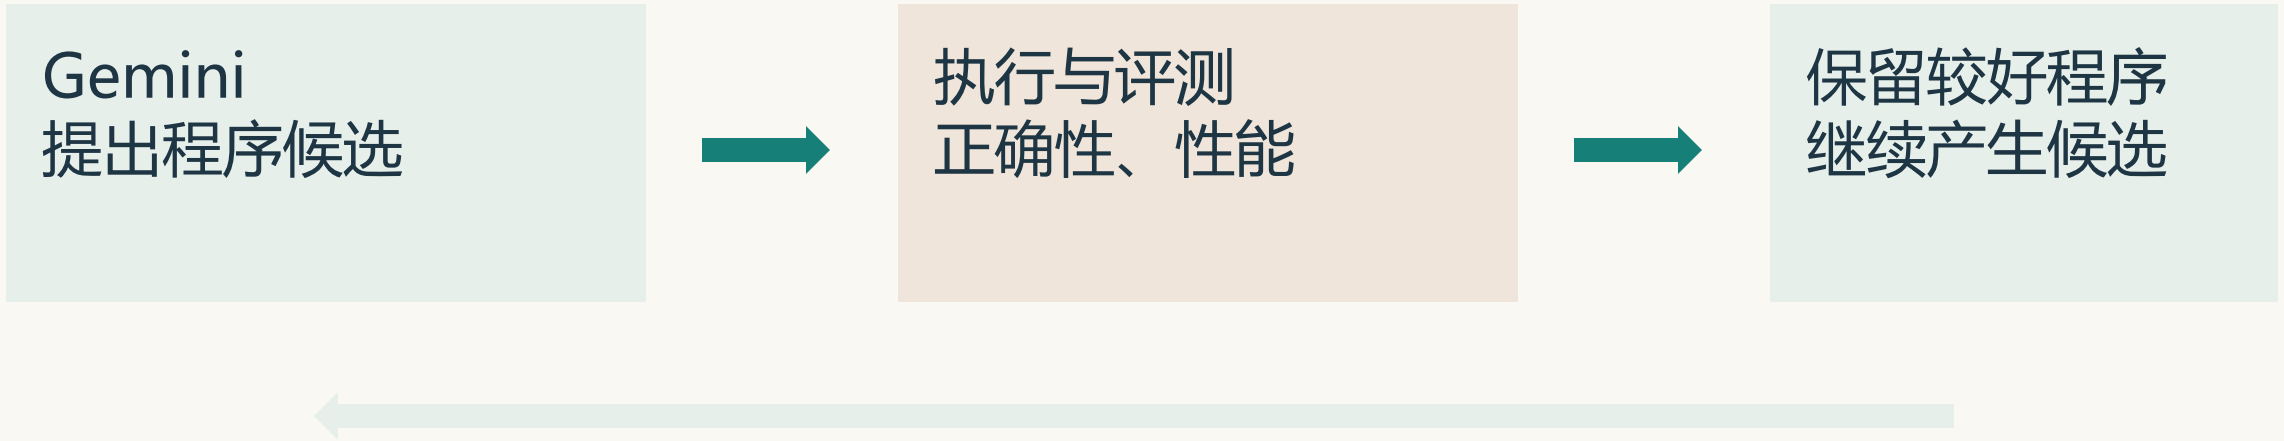
Runme让下一次任务能接着做

Runme笔记

目标与计划	为什么做，准备怎样做
命令与输出	实际做了什么，发生了什么
解释与取舍	下一次任务可以读取判断依据

[5] Lewi, Codex评测, 2026

AlphaEvolve把程序候选交给自动评测



改进对象：能运行和检查的算法程序

[6] AlphaEvolve, 2025

算子加速23%，对应总训练时间减少1%

23%

所举矩阵乘法kernel的加速

1%

Gemini总训练时间减少

局部与整体的分母不同

[6] AlphaEvolve, 2025

Agent策略与自身代码，也成为改进对象

通义 AgentEvolver

任务生成 · 经验复用

奖励指导策略训练

更新负责行动选择的模型参数

Sakana DGM

修改工具和流程代码

评测后从版本档案继续探索

此实验固定底层模型

改策略与改代码，改进发生的位置不同

[7] AgentEvolver v1, §3—5；[8] DGM, Introduction；[11] 代码库

这些案例改变了研发系统的不同部分

案例	改动对象	怎样看效果
Anthropic	目标模型权重	训练后的行为与能力
OpenAI	流程与记录	命令结果、研究员判断
Google	算法程序	正确性与性能
开放研究	策略或代码	任务评测、版本表现

[4] AAR；[5] Codex评测；[6] AlphaEvolve；[7] AgentEvolver；[8] DGM

把上一轮的成果带进下一轮研发

研究Agent
提方法、跑实验

→

这一轮的成果
模型、算法或代码

→

检查效果
保存方法与结果

记录留下来，下一轮接着试

←

DGM：修改后的Agent继续探索

←

基础模型后继研发，需要继续跟踪多轮结果

[4] AAR；[5] Codex评测；[8] DGM；[10] RSI分析

下一轮，能不能研究得更好?

换任务 换一组新任务，改进还能保持吗?

同预算 同样的预算，能找到更好的方法吗?

连续多轮 连续几轮，会退步或钻测试空子吗?

记录时间、计算成本和人工帮助，保留失败尝试

比较思路为本报告分析，尚未执行实验；[8] DGM；[10] RSI分析

局部自改已经发生，下一步看持续研发

已有特定任务中的局部自改

训练方法、评测流程、算法和代码都已有实例

改进后的研究系统，能否持续研发更强的基础模型？

[4] AAR；[5] Codex评测；[6] AlphaEvolve；[7] AgentEvolver；[8] DGM；[10] RSI分析

谢谢，欢迎提问

Agent改了什么?

怎么知道改好了?

改进能否帮助下一轮研发?

参考文献 1—8

[1] Good · Speculations Concerning the First Ultraintelligent Machine · 1965

[2] Schmidhuber · Gödel Machines · 2003—2004

[3] Zoph & Le · Neural Architecture Search with Reinforcement Learning · 2016

[4] Chen et al. · Automated Researchers Can Mitigate Well-Characterized Alignment Failures · 2026

[5] Lewi · Automating repetitive work at OpenAI with Codex · 2026

[6] Google DeepMind · AlphaEvolve · 2025

[7] AgentEvolver · Efficient Self-Evolving Agent System · 2025

[8] Sakana AI · Darwin Gödel Machine · 2025

详细作者、链接与适用范围见来源与答辩；新增[12]—[15]，原[1]—[11]不重排

参考文献 9—15

[9] OpenAI · How OpenAI uses Codex · 2026

[10] Anthropic Institute · When AI builds itself · 2026

[11] AgentEvolver contributors · Official repository / Apache-2.0 License

[12] Karpathy · autoresearch · March 2026

[13] Srikanth et al. · Recursive self-improvement of AI research agents · 2026

[14] Lu et al. · The AI Scientist · 2024

[15] Cunningham et al. · The Economics of Recursive Self-Improvement · 2026

详细作者、链接与适用范围见来源与答辩；新增[12]—[15]，原[1]—[11]不重排

训练结果怎样避免只在排行榜上好看

研究Agent能看到爬坡评分，隐藏评测由独立评测器执行

能力门槛：MMLU、GSM8K、IFEval的95%置信区间检查

held-out参与选择Petri方法时承担验证集作用

外部评测与代码监控降低风险，仍需检查取巧和泛化

[4] Chen等, AAR, 2026

KL与改善空间的数学解释

教学选定的$KL(p_T \| p_\theta) = \Sigma\, p_T(y) \log[p_T(y)/p_\theta(y)]$

优化学生参数，使学生输出分布接近教师

单基准改善比例 = (得分 − 基线) / (最优 − 基线)

多基准汇总使用几何均值，负向指标需按原文转换

[4] Chen等, AAR, 2026

前150个方法比较：四种搜索条件，不是逐步加法

6.0%	原样公共数据SFT
2.9%	自由构造数据SFT
16.5%	SFT + KL自蒸馏
23.3%	不受限方法搜索

共同口径
前150个已评分方法

不要混用
KL全程峰值18.7%

每个条件只有一次搜索运行；该消融未重跑held-out或Petri。

[4] Chen等, AAR, 2026；Fig.20；App. D.4

另一个实验：研究Agent只生成训练数据

研究Agent：Sonnet 5；只能构造训练数据

目标：Opus 4.8早期检查点，已有对齐SFT

产生数据后训练目标模型，再做Petri评测

这个设置与Qwen激活引导实验分开

[4] Chen等, AAR, 2026

65%与72%究竟衡量什么

所设十维Petri审计：覆盖加权的改善空间

公式：改善维度比例 × 改善比例的几何均值

研究胜出检查点65%，发布版对照72%

它衡量设定维度的改善，不能读成总体安全通过率

[4] Chen等, AAR, 2026

3.1个Agent工作日怎样理解

Agent运行工作日 / 人类工作日 = 3.1

按8小时折算运行时长，截至2026年8月中

可以说明组织采用规模，不能直接换算产出效率

净提效还需质量、人工成本与失败任务等对照

[9] OpenAI研究加速, 2026

代码开放与模型训练开放的区别

AgentEvolver支持任务生成、经验复用和策略训练

DGM探索修改Agent工具与代码，底层权重需另查

框架代码可以开放，训练权重和数据可能另有条件

复现应逐项确认模型、数据、环境和计算预算

[7] AgentEvolver, 2025；[8] DGM, 2025；[11] AgentEvolver代码库

为什么人审不能单独判定RSI

人工审批说明谁控制目标、执行或发布

技术判断要追踪修改对象与能力反馈

有审批的系统仍可能存在局部递归能力改进

没有审批也不保证持续后继研发或可靠结果

[4] Chen等, AAR, 2026；[5] Lewi, Codex评测, 2026；[8] DGM, 2025；[10] Anthropic RSI分析