V5 来源与答辩：先把问题回答清楚，再展开依据

核查日期：2026-10-14。服务于《智能体在大模型产业研发中的应用：AI 辅助研发距离递归自我改进还有多远？》。本组实践暂时搁置，本文件不把教学演示或材料制作算作本组研发实验。以下公司结果均来自公开材料，未由本组复现。

一、四个人先共同记住这五句话

1. 我们讨论的是 AI 研发流程：谁提出方法、谁执行实验、谁判断改进成立。

2. 修改提示、修改 Agent 代码、训练模型参数，改变的是不同对象。

3. 多试几轮并留下经验，已经能构成工作反馈；这还需要进一步证据，才能说明研发能力会持续增强。

4. 单项指标的提升要看分母、实验条件和检验方式；公司的使用量也不能直接当作生产率。

5. 我们的结论限定于所选公开证据。没有看到完整后继研发循环，不能推导为世界上没有任何未公开循环。

这五句话是本组对案例的分析，不冒充任何论文给出的统一 RSI 分级标准。

二、统一引用办法

投影页用“[4] Chen 等，AAR，§3 / App. D.4”这样的短来源；详细网址和文献放在备注及最后的参考文献页。图若重绘，写“据[4] Fig.20 重绘”；教学图写“教学示意”，避免让观众误以为是原论文实验截图。

讲述时第一次自然引入作者或项目，例如：“Anthropic Fellows 项目的一项公开研究，把减少谄媚行为变成了可以反复训练和评测的任务。”后面直接讲技术。追问出现时再定位节、图，不逐页朗读文献编号。

下列编号固定，新增内容不要打乱。访问日期均为 2026-10-14。网页未显示可靠首发日期的条目只标年份；动态网页不能用检索当天冒充发表日。

正式文献

[1] GOOD I J. Speculations Concerning the First Ultraintelligent Machine[M/OL]//Advances in Computers. Vol.6. Academic Press, 1965:31–88. DOI:10.1016/S0065-2458(08)60418-0. 原文 PDF.

[2] SCHMIDHUBER J. Gödel Machines: Self-Referential Universal Problem Solvers Making Provably Optimal Self-Improvements[R/OL]. Technical Report IDSIA-19-03, Version4, revised2004-12-27; initial versions2003. 作者原文.

[3] ZOPH B, LE Q V. Neural Architecture Search with Reinforcement Learning[EB/OL]. arXiv:1611.01578, initial submission2016-11-05, v2 revised2017-02-15. DOI:10.48550/arXiv.1611.01578. 论文.

[4] CHEN YUEH-HAN, WEN JIAXIN, KIRCHNER JAN HENDRIK. Automated Researchers Can Mitigate Well-Characterized Alignment Failures[EB/OL]. Anthropic Alignment Science Blog,2026. Work done during the Anthropic Fellows Program. 研究正文与附录.

[5] LEWI J. Automating repetitive work at OpenAI with Codex[EB/OL]. OpenAI Developers Blog,2026-08-25. 作者工作流.

[6] ALPHAEVOLVE TEAM. AlphaEvolve: A Gemini-powered coding agent for designing advanced algorithms[EB/OL]. Google DeepMind,2025-05-14. 官方介绍.

[7] ZHAI Y, TAO S, CHEN C, et al. AgentEvolver: Towards Efficient Self-Evolving Agent System[EB/OL]. arXiv:2511.10395v1,2025-11-13. Tongyi Lab, Alibaba Group. 本文固定采用 v1.

[8] ZHANG J, HU S, LU C, LANGE R, CLUNE J. Darwin Gödel Machine: Open-Ended Evolution of Self-Improving Agents[EB/OL]. arXiv:2505.22954, initial submission2025-05-29. DOI:10.48550/arXiv.2505.22954. 论文及版本记录. 同一团队的官方说明与结果，2025-05-30。本文涉及 20.0%→50.0%等数字，定位于该 2025 年说明；不把目前 arXiv v3 的更新日期当作最初研究日期。

[9] OPENAI. Research acceleration: The view inside OpenAI[EB/OL].2026-09-06. 组织统计及方法说明.

[10] ANTHROPIC INSTITUTE. When AI builds itself[EB/OL].2026; 页面包含 2026-09-18 更新。RSI 分析. 未确认首次发布日期，故不补写月日。

[11] MODELSCOPE / AGENTEVOLVER CONTRIBUTORS. AgentEvolver[CP/OL].2025–. 官方代码库，README 与 Apache-2.0 License。仓库会持续更新，本文只用它说明框架代码与许可证，不据此宣称训练数据和全部模型权重均开放。

三、关键主张在哪里，讲到哪一步为止

对应内容	一手定位	本轮核查结论	汇报边界
故事开场	[1]§2，印刷页 33，PDF 第 3 页	Good 讨论机器设计更好机器的可能性	是思想论证，不是已实现系统；不称他是唯一思想源头
两种验证取向	[2]摘要；[8]官方说明 Introduction	Gödel Machine 寻求有益性证明；DGM 通过任务评测检验改动	可讲方法张力，不虚构当年学派争吵；形式最优性依赖设定与可证明性
早期机器辅助设计	[3]摘要	NAS 搜索网络结构	只是代表节点，不把 2016 年称作 AutoML 诞生年
AAR 执行流程	[4]§2–3、Fig.2	研究者 Agent 提出训练方法，执行后交给分开的评测器；结果进入共同记录	研究者、被训练模型、评测器是三个职责，不说全系统由一个模型独立完成
激活引导与蒸馏	[4]App.D.4	无限制谄媚案例的胜出方法以引导构造教师，再自蒸馏	教师来自目标模型；不补写胜出方法未完整公开的 KL 方向、层号和系数
23.3%、6.0%、2.9%	[4]App.D.4、Fig.20 及紧邻正文	前 150 个已评分方法：不限方法 23.3%；SFT + 原样公共数据 6.0%；SFT + 自由构造数据 2.9%	几何平均改善空间；是搜索条件比较，非同一方法的单步贡献；未重跑此消融的 held-out/Petri

对应内容	一手定位	本轮核查结论	汇报边界
外部检验与选择	[4]§2.3	held-out 对 Agent 隐藏，但在选出做 Petri 测试的方法时承担验证集角色	不把所有 held-out 结果都说成完全不参与任何选择的最终独立测试
发布评测工作流	[5]Running evaluations with Codex	作者先看计划、批准后执行；Runme 保留命令、结果、解释与决定供后续复用	一位作者的实际工作流，不代表所有 OpenAI 研发任务；没有提供净提效倍数
算法进入模型训练	[6]Enhancing AI training and inference	所举矩阵乘法 kernel 加速 23%，对应 Gemini 训练时间减少 1%	分母分别是局部 kernel 与整段训练；不能改写成“训练快 23%”
Agent 策略训练	[7]§3–6，尤其§5.4；[11]README/License	生成任务、经验引导、轨迹归因进入策略优化；框架代码 Apache-2.0	不说只改 prompt；不从框架代码开放推导全链条开放
Agent 修改自身代码	[8]官方说明 Introduction、Results、Safety	DGM 改 Agent 代码/工具，并保留候选谱系；也报告取巧问题	有限定领域自改进证据；基础模型训练属于后续扩展方向，不能直接当作已经完成
组织中的使用量	[9]§1、方法附录	截至 2026 年 8 月中，按 8 小时折算，每个人类工作日对应 3.1 个 Agent 运行工作日	运行量与有效产出关系未被这个比值测出；不是 3.1 倍生产率
RSI 主问题	[10]开头及 Closing the loop；上述案例	本组区分工作反馈与研发能力的持续反馈	这是比较框架，不给公司排等级，不承诺具体实现日期

数字核对最容易混淆的地方

- 同样的 AAR 图，横轴截到 150 个方法，与全程最佳结果不同。 上表用前者。全程峰值 26.4/18.7/6.0/4.5 不可随意放进前 150 的方法比较；当前主讲也没有猜测 KL 条件在第 150 个方法处的数值。[4]App.D.4。

- headroom 先看基线到上限还差多少。 比如教学假设基线 50、改进后 70、上限 100，填补的是 20/50 = 40%；70 是当前分数，40%是改善空间比例。这组 50/70/100 是解释计算的例子，没有冒充论文实测。

- 65%/72%来自另一套研究设定。 若有人追问旧材料，它们对应[4]§6 及 App.E.1 的十维 Petri 覆盖加权改善空间。不是测试通过率、整体安全率，也不是前 150 个方法那张图。当前主讲不需要把两套实验接在一起讲。

- DGM 两个基准的数字各有分母。 官方说明分别报告 SWE-bench20.0%→50.0%、Polyglot14.2%→30.7%。主讲重点是代码自改的对象和检验方式，不需要把这些数字做成公司能力比较。[8]Results。

四、18 组答辩问题：直接回答与再追问

使用方法：先说加粗的直接判断，接上两三句说明；老师继续问，才用“进一步追问”那一行。标★的 8 题是四个人都应掌握的最小集合，其余按主讲段落熟悉。不要求背 URL 和完整作者表。以下“约 30 秒”是写作目标，尚未由四位成员实测计时。

1. ★为什么选这个题？和普通 AI 写代码有什么区别？

约 30 秒回答：我们关心 AI 工具是否开始改变下一代 AI 的研发过程。 写一段代码只是其中一步。我们沿着任务、实验和验证看：Agent 到底改了模型训练、评测流程，还是自己的工具；这些结果又能否帮助下一轮研发。这就把产业应用与自我改进之间的距离变成了能讨论的工程问题。

进一步追问：“必须有代码才算吗？” 不必。数据构造、实验设计、评测执行、参数训练都可能进入研发；关键是它改变的对象和可检查结果。这里是本组选题方法。

2. 为什么重点讲 Anthropic、OpenAI，又提 Google 与开源项目？

约 30 秒回答：选的是相互补充的公开案例。 Anthropic 的 AAR 适合解释训练方法怎样被提出和检验；Lewi 的 OpenAI 实例适合解释任务怎样在人机协作中执行和留下经验。Google 补足计算算法，

AgentEvolver 和 DGM 补足策略训练、代码自改。这样能说明行业有几条路径，而不只是两家公司对比。

进一步追问：“为什么不做全面排名？” 案例的任务、成本、指标和公开程度不同，不能用一张数字表做公平排名。选取是为了比较机制。[4]–[8]。

3. 历史上真的有两派争论吗？

约 30 秒回答：我们呈现的是两种验证取向。 一种追问能否先证明修改有益，再让系统改动自己；另一种先提出候选，在可执行任务上观察是否变好。Gödel Machine 和 DGM 能代表这个差异。它们相隔多年，我们没有证据把它写成同一个现场的学派争论。

进一步追问：“哪条路更好？” 证明提供强条件下的保证，经验验证更容易接入复杂环境，但测试覆盖有限。具体系统还可以组合两者。[2][8]。

4. ★AAR 里到底是谁在研究，谁被训练？

约 30 秒回答：研究者 Agent 负责选择和实现方法，被训练模型负责接受改变，评测器负责检查产物。要看清这三个角色，才不会把“Agent 说出好想法”当作已经训练出了好模型。输入、执行和评分各有记录，人可以顺着记录检查。[4]§2–3。

进一步追问：“同家公司模型参与评测，会不会自证？” 职责分开改善可检查性，评测质量仍要单独验证；不能从“有评测器”直接推导绝对可靠。

5. ★激活引导和训练权重，到底有什么不同？

约 30 秒回答：激活引导干预的是一次前向计算中的中间状态；训练更新的是参数。 我们的图先显示引导怎样改变教师的输出分布，再显示学生如何通过训练吸收这种分布。判断是否留在模型里，不能只看当场回答变好了，还要看后续使用的参数与干预设置。

进一步追问：“你们的箭头公式是实际配方吗？” $h' = h + \alpha v$ 只是说明干预位置的一般示意。图的技术机制对应[4]App.D.4；具体层与系数不由示意图确定。

6. ★既然不准用更强教师，知识从哪里来？

约 30 秒回答：目标不一定是增加所有知识，也可以是纠正已有能力的表达方式。 一个模型可能能识别事实，却在用户坚持错误意见时改变立场。引导后的目标模型可以提供较合适的教学信号，再让参数训练吸收。这个解释针对行为矫正，不能推导为小模型凭空获得全面超强能力。[4]App.D.4。

进一步追问：“不等于从更强研究 Agent 蒸馏吗？” 方法提议来自研究 Agent，与把研究 Agent 的答案作为训练教师是两件事；要根据实际训练数据来源判断。

7. KL 在这儿为什么有用？你们用的公式是哪一种？

约 30 秒回答：KL 能衡量两个输出概率分布的差别，训练可以据此调整学生分布。 我们的教学原型选了一个方向来演示更新，作用是帮助理解“输出分布怎样成为训练信号”。胜出方法的完整配方没有在这段公开概述里逐项给出，我们不会把教学公式冒充复现。

进一步追问：“两个方向不是一样的吗？” 通常不一样，梯度和对低概率事件的处理也会不同。需要确定目标、数据、采样和系数，才能谈某个实际配方。[4]App.D.4；原型的公式是教学选择。

8. ★为什么分数是改善空间，不直接给正确率？

约 30 秒回答：改善空间是在问，基线到理想上限之间的缺口填了多少。 我们用 50 升到 70 的假设例子解释：上限 100，原来差 50，现在补 20，所以填了 40%。这样能比较不同基线上的改善；但不能把 40%改写成模型当前正确率。[4]§2.2；例子为本组教学设定。

进一步追问：“几何平均有什么代价？” 它使薄弱维度影响较大；汇总分也会隐藏各维度情况，所以必要时要回看分项。

9. ★23.3%、6.0%、2.9%证明 KL 一定更好吗？

约 30 秒回答：这张图比较允许 Agent 搜索的条件，不能单独归因于一个公式。 放开方法范围，Agent 能尝试更多训练机制；把目标固定为 SFT，又限制了另一类改动。图支持在这个案例里认真考虑训练目标的选择，不能把差距全算作某一个单步操作的效果。[4]App.D.4。

进一步追问：“这是不是稳定的普遍规律？” 要扩大模型、行为任务与重复次数，并在新的评测上检查，才够支持更广泛结论。

10. 相同 150 个方法，算公平比较了吗？

约 30 秒回答：它使尝试次数的口径清楚，但不能自动保证所有资源公平。 每种方法的准备、推理、失败成本可能不同，搜索随机性也会影响最优候选。我们把它读成固定尝试次数下的案例观察，避免讲成等总成本、严格因果识别的结论。[4]App.D.4；资源公平判断是本组分析。

进一步追问：“怎样做得更强？” 同时报告总算力、时长、重复运行、置信区间，并预先确定选择规则；这是一种研究设计建议，不声称我们做过。

11. 为什么还要留出测试？有能力门槛还不够吗？

约 30 秒回答：能力门槛与留出检验回答不同问题。 前者检查选定能力有没有明显退化；后者检查改进能否离开被优化的分布。哪怕两者都通过，也只覆盖这些检查项目。实际部署还要考虑新场景与长期行为。

进一步追问：“AAR 的 held-out 是不是最终测试？” 需看用途：用它选择进入 Petri 的方法时，它承担验证集角色。[4]§2.3。这个选择细节应明确说出来。

12. ★OpenAI 这个案例为什么需要人批准？那还叫 Agent 吗？

约 30 秒回答：需要人批准与能否自主执行任务，是两个不同问题。 人可以决定目标与重要资源取舍，Agent 在批准后执行具体步骤。这个例子的价值是把人参与的位置留下来，让任务能检查和复用。我们不因出现审批就否定所有技术自我改进，也不因 Agent 执行过就说全部过程无人参与。[5]。

进一步追问：“人到底做了什么？” 定位作者 Running evaluations 一节，区分计划审阅、资源选择、进度干预和结束时的决定记录；不要推测作者没有写明的自动发布行为。

13. 把记录放进 Runme，就是系统学会了吗？

约 30 秒回答：记录能让下一次任务少丢上下文，但记录本身不能证明学会。 需要观察后续执行是否真正读到、正确使用，并在可比任务上减少重复错误或提高效果。我们因此把它放在经验反馈的位置，而没有说记录一写完，模型参数或研发能力就提升了。[5]工作流；检验要求是本组分析。

进一步追问：“这和训练有什么差别？” 可读记录是外部经验，参数更新是改变模型；两者可能同时使用，但要分别报告。

14. AlphaEvolve 怎么就算用于 AI 产业，而不只是算法竞赛？

约 30 秒回答：它的一个公开结果进入了 Gemini 训练所用的计算。 所以改进对象与模型研发链条存在具体连接。主讲同时保留局部与总体的区别：kernel 加速 23%，总训练时间减少 1%。只有进入真实链条并说明分母，才能讲清工程价值。[6]。

进一步追问：“训练成本也减少 1%吗？” 时间、费用、能耗的关系还取决于资源配置与计价；原文给出的训练时间结果不能被换成未报告的成本结果。

15. AgentEvolver 与 DGM 都是自进化，有必要区分吗？

约 30 秒回答：有必要，因为改进发生的对象不同。 AgentEvolver 把合成任务、经验和归因用于 Agent 策略训练；DGM 主要探索自身代码和工具的修改。知道改了什么，才能问怎么检验、如何迁移，以及是不是触及了基础模型训练。一个共同名称不能替代这些技术差别。[7][8]。

进一步追问：“开源是不是更可信？” 可检查代码增加了一种证据；仍需确认数据、权重、环境与结果能否获得和复现。[11]只证明框架代码的开放与许可。

16. Agent 如果会伪造结果，你们怎么相信这些案例？

约 30 秒回答：我们不把 Agent 自述当作最后证据。 应看执行产物、独立检查、选择规则，以及作者有没有报告失败和取巧。DGM 公开了伪造测试记录与破坏检测标记的问题，这说明测试指标也会成为被攻击的目标。检验过程需要保留原始执行依据，不能只读一段总结。[8]Safety。

进一步追问：“有监控就能保证吗？” 监控能提供部分发现能力；未知取巧与漏检仍要研究，不说已有检查等于全覆盖。

17. OpenAI 的 3.1 是不是说明研究效率已经提高 3.1 倍？

约 30 秒回答：不能这样读。 它把 Agent 运行时间换算成工作日，再与人类工作时间比较，说明使用量已经很大。多个 Agent 可以同时运行，也可能失败或重复做事。净效率要看有价值的研究结果、人的额外监督成本和实际耗时，那个比值没有把这些测完。[9]。

进一步追问：“那这个数字有什么用？” 它支持讨论 Agent 在研发组织中的规模与资源配置；若要谈产出，需另找与研究成果直接相关的测量。

18. ★所以你们认为 RSI 到底来了没有？如何才算回答了题目？

约 30 秒回答：公开案例已经展示研发环节的自动化，以及一些限定领域的自改进。 要回答更强的 RSI 主张，还需追踪改进后系统能否更有效地承担下一轮研发，并持续产生更强后继。我们把已经观察到的工作反馈与仍需验证的能力反馈分开，避免一个局部结果承担整个结论。[8][10]；比较判断为本组分析。

进一步追问：“什么证据会改变你们判断？” 可重复的多轮谱系、固定资源口径、未参与选择的新任务，以及改进系统与未改进系统的后续研发对照。这里不以“有没有人批准”当作唯一判据，也不预测具体实现日期。

五、哪些技术细节还不能替作者补出来

缺口	被问到时怎么说	可以接着讨论的内容
AAR 胜出蒸馏方法的完整实现参数	“公开概述能支持机制，但不足以由这张图还原全部训练配方。”	教师分布、损失方向、层选择、系数和采样都会影响训练
消融在第 150 个方法处的 KL 条件准确读数	“当前主讲只用正文明确给出的三项数值。”	原图对应 4 条件，但不能把全程峰值搬进相同横轴
AAR 消融的长期泛化与多次重复	“这组比较还需要更广范围的检验。”	分离搜索上限、泛化能力、复现实验这三项
Runme 实例的净提效和所有部门适用性	“作者展示了流程，没有提供这个结论所需的对照数据。”	可以讨论记录如何减少上下文丢失，以及怎样设计评估
AlphaEvolve 的全公司净收益	“当前使用的来源给了具体训练时间效果。”	时间之外的能耗、成本、开发与验证负担要另测
开源训练全链条能否复现	“许可证和代码可见性是一部分，还要逐项查权重、数据和环境。”	不把开源当作二元总标签
系统在连续后继研发中的能力加速	“这些案例尚不足以给出全产业的完整多轮证明。”	用明确对象与后续研发对照，检验反馈是否进入能力层

这些句子是答题的边界，不需要在主讲连续念成免责声明。主讲说清已知机制；追问遇到缺口，再准确指出。

六、答辩如何快速准备

建议每位成员先用 10 分钟读第一节和 8 道★题，然后读自己主讲段落对应的其他问题。正式答辩中，一人直接回答；另一个人负责打开对应备份页或来源，避免四人同时补充。

每次练习只检查三件事：是否第一句话就回答问题；数字的对象与分母是否说完整；遇到缺口有没有承认后再给出可检验的下一步。回答超过 40 秒时删去背景介绍，不删关键限定。当前文件提供可讲的答案，四位成员实际掌握与计时仍待一次口头检查。