V5 来源与答辩：先把问题回答清楚，再展开依据

基础核查日期：2026-10-14；D 相关机制、分母与 RSI 问答于 2026-10-26 补核并同步 19—24 页。服务于《智能体在大模型产业研发中的应用：AI 辅助研发距离递归自我改进还有多远？》。实践为可选未启动，本文件不把教学演示或材料制作算作本组研发实验。以下公司结果均来自公开材料，未由本组复现。

一、四个人先共同记住这五句话

1. 我们讨论的是 AI 研发流程：谁提出方法、谁执行实验、谁判断改进成立。

2. 修改提示、修改 Agent 代码、训练模型参数，改变的是不同对象。

3. 研究记录可以帮助下一次尝试；DGM 还让修改后的代码版本参与后续修改。局部代码递归自改已有实例，持续基础模型后继研发则需跨轮次检验。

4. 单项指标的提升要看分母、实验条件和检验方式；公司的使用量也不能直接当作生产率。

5. 我们的结论限定于所选公开证据。没有看到完整后继研发循环，不能推导为世界上没有任何未公开循环。

这五句话是本组对案例的分析，不冒充任何论文给出的统一 RSI 分级标准。

二、统一引用办法

投影页用“[4] Chen 等，AAR，§3 / App. D.4”这样的短来源；详细网址和文献放在备注及最后的参考文献页。图若重绘，写“据[4] Fig.20 重绘”；教学图写“教学示意”，避免让观众误以为是原论文实验截图。

讲述时第一次自然引入作者或项目，例如：“Anthropic Fellows 项目的一项公开研究，把减少谄媚行为变成了可以反复训练和评测的任务。”后面直接讲技术。追问出现时再定位节、图，不逐页朗读文献编号。

下列编号固定，新增内容不要打乱。原有基础核查为 2026-10-14；[7][8][10][11]的 D 相关内容补核日期为 2026-10-26，具体定位见 D 备课。网页未显示可靠首发日期的条目只标年份；动态网页不能用检索当天冒充发表日。

正式文献

[1] GOOD I J. Speculations Concerning the First Ultraintelligent Machine[M/OL]//Advances in Computers. Vol.6. Academic Press, 1965:31–88. DOI:10.1016/S0065-2458(08)60418-0. 原文 PDF.

[2] SCHMIDHUBER J. Gödel Machines: Self-Referential Universal Problem Solvers Making Provably Optimal Self-Improvements[R/OL]. Technical Report IDSIA-19-03, Version4, revised2004-12-27; initial versions2003. 作者原文.

[3] ZOPH B, LE Q V. Neural Architecture Search with Reinforcement Learning[EB/OL]. arXiv:1611.01578, initial submission2016-11-05, v2 revised2017-02-15. DOI:10.48550/arXiv.1611.01578. 论文.

[4] CHEN YUEH-HAN, WEN JIAXIN, KIRCHNER JAN HENDRIK. Automated Researchers Can Mitigate Well-Characterized Alignment Failures[EB/OL]. Anthropic Alignment Science Blog,2026. Work done during the Anthropic Fellows Program. 研究正文与附录.

[5] LEWI J. Automating repetitive work at OpenAI with Codex[EB/OL]. OpenAI Developers Blog,2026-08-25. 作者工作流.

[6] ALPHAEVOLVE TEAM. AlphaEvolve: A Gemini-powered coding agent for designing advanced algorithms[EB/OL]. Google DeepMind,2025-05-14. 官方介绍.

[7] ZHAI Y, TAO S, CHEN C, et al. AgentEvolver: Towards Efficient Self-Evolving Agent System[EB/OL]. arXiv:2511.10395v1,2025-11-13. Tongyi Lab, Alibaba Group. 本文固定采用 v1.

[8] ZHANG J, HU S, LU C, LANGE R, CLUNE J. Darwin Gödel Machine: Open-Ended Evolution of Self-Improving Agents[EB/OL]. arXiv:2505.22954, initial submission2025-05-29. DOI:10.48550/arXiv.2505.22954. 论文及版本记录、本文机制与评测所用 v1。同一团队的官方说明与结果，2025-05-30。本文涉及 20.0%→50.0%等数字，定位于该 2025 年说明及原论文 v1；不把后续版本更新日期当作最初研究日期。

[9] OPENAI. Research acceleration: The view inside OpenAI[EB/OL].2026-09-06. 组织统计及方法说明.

[10] ANTHROPIC INSTITUTE. When AI builds itself[EB/OL].2026; 页面包含 2026-09-18 更新。RSI 分析. 未确认首次发布日期，故不补写月日。

[11] MODELSCOPE / AGENTEVOLVER CONTRIBUTORS. AgentEvolver[CP/OL].2025–. 官方代码库，README 与 Apache-2.0 License。仓库会持续更新，本文只用它说明框架代码与许可证，不据此宣称训练数据和全部模型权重均开放。

三、关键主张在哪里，讲到哪一步为止

对应内容	一手定位	本轮核查结论	汇报边界
故事开场	[1]§2，印刷页 33，PDF 第 3 页	Good 讨论机器设计更好机器的可能性	是思想论证，不是已实现系统；不称他是唯一思想源头
两种验证取向	[2]摘要；[8]官方说明 Introduction	Gödel Machine 寻求有益性证明；DGM 通过任务评测检验改动	可讲方法张力，不虚构当年学派争吵；形式最优性依赖设定与可证明性
早期机器辅助设计	[3]摘要	NAS 搜索网络结构	只是代表节点，不把 2016 年称作 AutoML 诞生年
AAR 执行流程	[4]§2–3、Fig.2	研究者 Agent 提出训练方法，执行后交给分开的评测器；结果进入共同记录	研究者、被训练模型、评测器是三个职责，不说全系统由一个模型独立完成
激活引导与蒸馏	[4]App.D.4	无限制谄媚案例的胜出方法以引导构造教师，再自蒸馏	教师来自目标模型；不补写胜出方法未完整公开的 KL 方向、层号和系数
23.3%、6.0%、2.9%	[4]App.D.4、Fig.20 及紧邻正文	前 150 个已评分方法：不限方法 23.3%；SFT + 原样公共数据 6.0%；SFT + 自由构造数据 2.9%	几何平均改善空间；是搜索条件比较，非同一方法的单步贡献；未重跑此消融的 held-out/Petri

对应内容	一手定位	本轮核查结论	汇报边界
外部检验与选择	[4]§2.3	held-out 对 Agent 隐藏，但在选出做 Petri 测试的方法时承担验证集角色	不把所有 held-out 结果都说成完全不参与任何选择的最终独立测试
发布评测工作流	[5]Running evaluations with Codex	作者先看计划、批准后执行；Runme 保留命令、结果、解释与决定供后续复用	一位作者的实际工作流，不代表所有 OpenAI 研发任务；没有提供净提效倍数
算法进入模型训练	[6]Enhancing AI training and inference	所举矩阵乘法 kernel 加速 23%，对应 Gemini 训练时间减少 1%	分母分别是局部 kernel 与整段训练；不能改写成“训练快 23%”
Agent 策略训练	[7]§3—5，策略目标见§4.3 式(17)、动作优势见§5.3—5.4；[11]README/License	任务生成、经验引导与动作归因产生训练信号，策略梯度更新参数；框架代码 Apache-2.0	不说只改 prompt；输入经验与参数学习分开解释，不从框架代码开放推导全链条开放
Agent 修改自身代码	[8]v1 §3、§4.4、App.A.3—A.4、App.C 及 F；官方 Introduction、Results、Safety	固定底模，改工具与流程代码；从档案选父代，后代 Agent 可继续参与修改；论文也报告具体幻觉与取巧实例	档案不只保留当前最高分；诊断仍由固定 o1 承担。不能将特定反幻觉实验的取巧泛化为主实验整体作弊，也不能说基础模型训练已经完成
组织中的使用量	[9]§1、方法附录	截至 2026 年 8 月中，按 8 小时折算，每个人类工作日对应 3.1 个 Agent 运行工作日	运行量与有效产出关系未被这个比值测出；不是 3.1 倍生产率

对应内容	一手定位	本轮核查结论	汇报边界
RSI 主问题	[10]开头及 Closing the loop；[8]§3 及上述案例	局部代码递归已有实例；持续基础模型后继研发需看连续几轮产物	第 22 页是本组提出、未执行的比较建议，不是统一 RSI 分级；人类审批不是否定一切自改的充分条件，不承诺具体实现日期

数字核对最容易混淆的地方

- **同样的 AAR 图，横轴截到 150 个方法，与全程最佳结果不同。** 上表用前者。全程峰值 26.4/18.7/6.0/4.5 不可随意放进前 150 的方法比较；当前主讲也没有猜测 KL 条件在第 150 个方法处的数值。[4]App.D.4。

- **headroom 先看基线到上限还差多少。** 比如教学假设基线 50、改进后 70、上限 100，填补的是 20/50 = 40%；70 是当前分数，40%是改善空间比例。这组 50/70/100 是解释计算的例子，没有冒充论文实测。

- **65%/72%来自另一套研究设定。** 若有人追问旧材料，它们对应[4]§6 及 App.E.1 的十维 Petri 覆盖加权改善空间。不是测试通过率、整体安全率，也不是前 150 个方法那张图。当前主讲不需要把两套实验接在一起讲。

- **DGM 结果先看任务范围与采样口径。** SWE-bench 的 20.0%→50.0%来自 SWE-bench Verified 中原研究选取的 200 题子集，搜索先用更小子集筛选；Polyglot 的 14.2%→30.7%来自完整 225 题复评，原论文采用 pass@1。搜索时 50 题 Polyglot 子集的 14.0%→38.0%是另一口径，不能互换；Aider 公开榜单常用 pass@2，也不能直接当成同条件比较。定位：[8]v1 §4.2、§4.4、Fig.2 及官方 Results；225 题见官方链接的 Aider 基准说明。这些百分数都不是全领域智能水平。

- **pass@1 不是只许调用一次模型。** DGM 论文的口径是不读取评测的真实测试反馈；Agent 仍可在内部尝试多个方案。不要把这个限定说成“一次模型输出就得到结果”。[8]v1 App.B.5。

四、18 组答辩问题：直接回答与再追问

使用方法：先说加粗的直接判断，接上两三句说明；老师继续问，才用“进一步追问”那一行。标★的 8 题是四个人都应掌握的最小集合，其余按主讲段落熟悉。不要求背 URL 和完整作者表。以下“约 30 秒”是写作目标，尚未由四位成员实测计时。

1. ★为什么选这个题？和普通 AI 写代码有什么区别？

约 30 秒回答：我们关心 AI 工具是否开始改变下一代 AI 的研发过程。 写一段代码只是其中一步。我们沿着任务、实验和验证看：Agent 到底改了模型训练、评测流程，还是自己的工具；这些结果又能否帮助下一轮研发。这就把产业应用与自我改进之间的距离变成了能讨论的工程问题。

进一步追问：“必须有代码才算吗？” 不必。数据构造、实验设计、评测执行、参数训练都可能进入研发；关键是它改变的对象和可检查结果。这里是本组选题方法。

2. 为什么重点讲 Anthropic、OpenAI，又提 Google 与开源项目？

约 30 秒回答：选的是相互补充的公开案例。 Anthropic 的 AAR 适合解释训练方法怎样被提出和检验；Lewi 的 OpenAI 实例适合解释任务怎样在人机协作中执行和留下经验。Google 补足计算算法，AgentEvolver 和 DGM 补足策略训练、代码自改。这样能说明行业有几条路径，而不只是两家公司对比。

进一步追问：“为什么不做全面排名？” 案例的任务、成本、指标和公开程度不同，不能用一张数字表做公平排名。选取是为了比较机制。[4]–[8]。

3. 历史上真的有两派争论吗？

约 30 秒回答：我们呈现的是两种验证取向。 一种追问能否先证明修改有益，再让系统改动自己；另一种先提出候选，在可执行任务上观察是否变好。Gödel Machine 和 DGM 能代表这个差异。它们相隔多年，我们没有证据把它写成同一个现场的学派争论。

进一步追问：“哪条路更好？” 证明提供强条件下的保证，经验验证更容易接入复杂环境，但测试覆盖有限。具体系统还可以组合两者。[2][8]。

4. ★AAR 里到底是谁在研究，谁被训练？

约 30 秒回答：研究者 Agent 负责选择和实现方法，被训练模型负责接受改变，评测器负责检查产物。 要看清这三个角色，才不会把“Agent 说出好想法”当作已经训练出了好模型。输入、执行和评分各有记录，人可以顺着记录检查。[4]§2–3。

进一步追问：“同家公司模型参与评测，会不会自证？” 职责分开改善可检查性，评测质量仍要单独验证；不能从“有评测器”直接推导绝对可靠。

5. ★激活引导和训练权重，到底有什么不同？

约 30 秒回答：激活引导干预的是一次前向计算中的中间状态；训练更新的是参数。 我们的图先显示引导怎样改变教师的输出分布，再显示学生如何通过训练吸收这种分布。判断是否留在模型里，不能只看当场回答变好了，还要看后续使用的参数与干预设置。

进一步追问：“你们的箭头公式是实际配方吗？” $h' = h + \alpha v$ 只是说明干预位置的一般示意。图的技术机制对应[4]App.D.4；具体层与系数不由示意图确定。

6. ★既然不准用更强教师，知识从哪里来？

约 30 秒回答：目标不一定是增加所有知识，也可以是纠正已有能力的表达方式。 一个模型可能能识别事实，却在用户坚持错误意见时改变立场。引导后的目标模型可以提供较合适的教学信号，再让参数训练吸收。这个解释针对行为矫正，不能推导为小模型凭空获得全面超强能力。[4]App.D.4。

进一步追问：“不等于从更强研究 Agent 蒸馏吗？” 方法提议来自研究 Agent，与把研究 Agent 的答案作为训练教师是两件事；要根据实际训练数据来源判断。

7. KL 在这儿为什么有用？你们用的公式是哪一种？

约 30 秒回答：KL 能衡量两个输出概率分布的差别，训练可以据此调整学生分布。 我们的教学原型选了一个方向来演示更新，作用是帮助理解“输出分布怎样成为训练信号”。胜出方法的完整配方没有在这段公开概述里逐项给出，我们不会把教学公式冒充复现。

进一步追问：“两个方向不是一样的吗？” 通常不一样，梯度和对低概率事件的处理也会不同。需要确定目标、数据、采样和系数，才能谈某个实际配方。[4]App.D.4；原型的公式是教学选择。

8. ★为什么分数是改善空间，不直接给正确率？

约 30 秒回答：改善空间是在问，基线到理想上限之间的缺口填了多少。 我们用 50 升到 70 的假设例子解释：上限 100，原来差 50，现在补 20，所以填了 40%。这样能比较不同基线上的改善；但不能把 40%改写成模型当前正确率。[4]§2.2；例子为本组教学设定。

进一步追问：“几何平均有什么代价？” 它使薄弱维度影响较大；汇总分也会隐藏各维度情况，所以必要时要回看分项。

9. ★23.3%、6.0%、2.9%证明 KL 一定更好吗？

约 30 秒回答：这张图比较允许 Agent 搜索的条件，不能单独归因于一个公式。 放开方法范围，Agent 能尝试更多训练机制；把目标固定为 SFT，又限制了另一类改动。图支持在这个案例里认真考虑训练目标的选择，不能把差距全算作某一个单步操作的效果。[4]App.D.4。

进一步追问：“这是不是稳定的普遍规律？” 要扩大模型、行为任务与重复次数，并在新的评测上检查，才够支持更广泛结论。

10. 相同 150 个方法，算公平比较了吗？

约 30 秒回答：它使尝试次数的口径清楚，但不能自动保证所有资源公平。 每种方法的准备、推理、失败成本可能不同，搜索随机性也会影响最优候选。我们把它读成固定尝试次数下的案例观察，避免讲成等总成本、严格因果识别的结论。[4]App.D.4；资源公平判断是本组分析。

进一步追问：“怎样做得更强？” 同时报告总算力、时长、重复运行、置信区间，并预先确定选择规则；这是一种研究设计建议，不声称我们做过。

11. 为什么还要留出测试？有能力门槛还不够吗？

约 30 秒回答：能力门槛与留出检验回答不同问题。 前者检查选定能力有没有明显退化；后者检查改进能否离开被优化的分布。哪怕两者都通过，也只覆盖这些检查项目。实际部署还要考虑新场景与长期行为。

进一步追问：“AAR 的 held-out 是不是最终测试？” 需看用途：用它选择进入 Petri 的方法时，它承担验证集角色。[4]§2.3。这个选择细节应明确说出来。

12. ★OpenAI 这个案例为什么需要人批准？那还叫 Agent 吗？

约 30 秒回答：需要人批准与能否自主执行任务，是两个不同问题。 人可以决定目标与重要资源取舍，Agent 在批准后执行具体步骤。这个例子的价值是把人参与的位置留下来，让任务能检查和复用。我们不因出现审批就否定所有技术自我改进，也不因 Agent 执行过就说全部过程无人参与。[5]。

进一步追问：“人到底做了什么？” 定位作者 Running evaluations 一节，区分计划审阅、资源选择、进度干预和结束时的决定记录；不要推测作者没有写明的自动发布行为。

13. 把记录放进 Runme，就是系统学会了吗？

约 30 秒回答：记录能让下一次任务少丢上下文，但记录本身不能证明学会。 需要观察后续执行是否真正读到、正确使用，并在可比任务上减少重复错误或提高效果。我们因此把它放在经验反馈的位置，而没有说记录一写完，模型参数或研发能力就提升了。[5]工作流；检验要求是本组分析。

进一步追问：“这和训练有什么差别？” 可读记录是外部经验，参数更新是改变模型；两者可能同时使用，但要分别报告。

14. AlphaEvolve 怎么就算用于 AI 产业，而不只是算法竞赛？

约 30 秒回答：它的一个公开结果进入了 Gemini 训练所用的计算。 所以改进对象与模型研发链条存在具体连接。主讲同时保留局部与总体的区别：kernel 加速 23%，总训练时间减少 1%。只有进入真实链条并说明分母，才能讲清工程价值。[6]。

进一步追问：“训练成本也减少 1%吗？” 时间、费用、能耗的关系还取决于资源配置与计价；原文给出的训练时间结果不能被换成未报告的成本结果。

15. AgentEvolver 与 DGM 都是自进化，有必要区分吗？

约 30 秒回答：有必要，因为它们改变的对象不同。 AgentEvolver 生成任务、复用经验，对动作贡献归因，再把过程与结果信号用于强化学习，更新 Agent 策略参数。DGM 在该实验中固定底模，修改工具与流程代码；评测后把不同版本留在档案，供后续选择和继续修改。训练策略与修改代码，应分别检查。[7]§3—5；[8]§3、App.A。

进一步追问：“保存经验就算训练了吗？为什么保留低分版本？” 把经验放进输入，只是推理时利用外部信息；AgentEvolver 另有策略参数优化。DGM 保留不同路线，因为暂时低分的版本仍可能产生好的后代，并非每轮只留最高分。[7]§4—5；[8]Fig.3。开源仍需逐项查数据、权重、环境与结果，[11]只用于说明框架代码与许可，不能保证本组已能复现。

16. Agent 会幻觉或绕过检测，你们怎么相信结果？

约 30 秒回答：应对照实际执行，不能只相信 Agent 声称成功。 DGM 论文分别报告了未真实调用工具、却在文字中声称测试通过的幻觉，以及在一项反幻觉改进实验中删除记录标记、绕过检测的实例。它们提醒我们保存执行依据、隔离评测器；不能因此把整个主实验写成作弊。[8]Safety、v1 App.F。

进一步追问：“删除标记发生在哪个实验？有监控就能保证吗？” 删除标记的 node114 来自独立的反幻觉改进实验：150 轮探索、每个 Agent 用 3 题评测；不是主基准结果的统一发生率。监控仍可能漏检。本组未运行这些实验，也没有测量取巧频率，不能从个案推算全部版本。[8]v1 App.F。

17. OpenAI 的 3.1 是不是说明研究效率已经提高 3.1 倍？

约 30 秒回答：不能这样读。 原文截至 2026 年 8 月中、按 8 小时折算，每个人类工作日对应 3.1 个 Agent 运行工作日。这是运行量的比值；多个 Agent 可以同时运行，也可能失败或重复做事。净效率还要看研究产物、人的监督成本和实际耗时，那个比值没有把这些测完。[9]§1 及方法附录。

进一步追问：“那这个数字有什么用？” 它支持讨论 Agent 在研发组织中的规模与资源配置；若要谈产出，需另找与研究成果直接相关的测量。

18. ★所以你们认为 RSI 到底来了没有？如何才算回答了题目？

约 30 秒回答：局部代码递归自改已有实例；持续的基础模型后继研发还需跨轮次检验。 DGM 修改工具与流程代码，后代 Agent 还能参与后续修改，但底模不因此得到训练。我们接着问：改进后的研究系统能否在后续几轮持续提出有效方法，研发更强的基础模型。所选材料尚不足以证明这个更大的命题。[8]§3、App.A；[10]。

进一步追问：“22 页你们做过吗？有人审批还算不算？” 第 22 页是本组建议，未开展：让原版与改进版在同样预算下研究同一组新任务，再换任务、连续观察几轮，并记录失败、人工帮助、退化与取巧。它不是统一 RSI 认证。审批说明决策边界，不足以单独否定自我改动；还要分别看谁提出修改、谁执行和检验、改后系统是否接手下一轮。不据此预测实现日期。

五、被追问到实现细节时怎样回答

具体问题	直接回答	后续讨论
AAR 胜出蒸馏方法的完整实现参数	“公开概述能支持机制，但不足以由这张图还原全部训练配方。”	教师分布、损失方向、层选择、系数和采样都会影响训练
消融在第 150 个方法处的 KL 条件准确读数	“当前主讲只用正文明确给出的三项数值。”	原图对应 4 条件，但不能把全程峰值搬进相同横轴
AAR 消融的长期泛化与多次重复	“这组比较还需要更广范围的检验。”	分离搜索上限、泛化能力、复现实验这三项
Runme 实例的净提效和所有部门适用性	“作者展示了流程，没有提供这个结论所需的对照数据。”	可以讨论记录如何减少上下文丢失，以及怎样设计评估

具体问题	直接回答	后续讨论
AlphaEvolve 的全公司净收益	“当前使用的来源给了具体训练时间效果。”	时间之外的能耗、成本、开发与验证负担要另测
开源训练全链条能否复现	“许可证和代码可见性是一部分，还要逐项查权重、数据和环境。”	不把开源当作二元总标签
系统在连续后继研发中的能力加速	“这些案例尚不足以给出全产业的完整多轮证明。”	用明确对象与后续研发对照，检验反馈是否进入能力层

这些句子是答题的边界，不需要在主讲连续念成免责声明。主讲说清已知机制；追问遇到缺口，再准确指出。

六、答辩如何快速准备

建议每位成员先用 10 分钟读第一节和 8 道★题，再读自己负责内容对应的问题，帮助理解全场。正式答辩暂由组长一人参加，组长还需熟悉其余问题并练习按导航打开备份或来源；ABCD 不作为现场轮流回答的安排。成员无需另交整套技术说明或问答。

每次练习只检查三件事：是否第一句话就回答问题；数字的对象与分母是否说完整；遇到缺口有没有承认后再给出可检验的下一步。回答超过 40 秒时删去背景介绍，不删关键限定。当前文件提供可讲的答案，四位成员实际掌握与计时仍待一次口头检查。