组长 A 部分答辩备课

覆盖第 1—7 页，供陈云海理解开场、掌握全场主线和准备追问。公司与论文结果均来自公开材料，未由本组复现；205 秒主讲预算和以下回答均未真人计时。

先把全场问题说清楚

AI 开始参与研发 AI。autoresearch 把实验循环交给 Agent；RSI 进一步问，改进能否提高研究者下一轮的能力。若这种收益持续回流，研发可能加速。但模型能力、算力、工具和可靠评测共同决定它能走多远。我们沿模型训练、评测与程序优化、Agent 自身改进追踪真实成果，最后回答“改了什么、怎么知道更好、怎样进入下一轮”。

1—2 页提出问题与定义，3 页用小实验解释自动研究，4 页讲潜在意义，5 页讲落地条件，6 页交代选例，7 页进入 B 的任务。先练第 1、2、5、8、12 问，再补其余。无需让其他成员另交一套技术问答。

十二个可能追问

1. RSI 的“递归”到底指什么

短答：Recursive Self-Improvement，递归自我改进；改进后的系统还能参与后续改进。

追问：我们关注研发能力是否回流。对象可以是 Agent 程序，也可以是更强的后继模型，范围要说清。一次回答自检不自动证明研究能力提升；也不能只承认模型权重改变这一种形式。[1][10][13]。

2. RSI 与 autoresearch 是不是同一件事

短答：自动研究描述研究过程自动化，RSI 还要看研究者的改进能否进入下一轮。

追问：Karpathy 原循环主要改训练代码、训练小模型并筛选结果。产物变好，不等于提出实验的 Agent 也因此变强。若把研究 Agent 自身的搜索、记忆或工具程序作为改进对象，并验证下一轮研究能力，则多了一层反馈。[12][13]。

3. 这个方向是 Karpathy 在 2026 年首创的吗

短答：他的 autoresearch 项目署名 2026 年 3 月；自动研究这一方向更早就有。

追问：2024 年的 The AI Scientist 已研究自动提出想法、写代码、运行实验和撰写论文。我们选择 Karpathy，是因为“改代码、短训练、比较、再试”很直观；不据此争论全球首创，也不把整个方向的历史归给一个项目。[12][14]。

4. 原版循环每轮五分钟，训练出了什么

短答：五分钟是训练预算，不是包含推理、改代码和启动的整轮总耗时。

追问：Agent 改 train.py 中的模型、优化器或训练设置，运行训练，再比较验证集每字节比特数 val_bpb，越低越好，决定保留或丢弃。固定 prepare.py 和评测设置帮助比较；这个指标不直接测通用智能或安全性，跨硬件结果也不能直接互比。[12]How it works、Design choices。

5. 研究 RSI 一定要先有大集群吗

短答：小循环可以单卡起步；宣称前沿规模有效，就要有对应规模的验证。

追问：原版 autoresearch 用单 NVIDIA GPU，示例测试 H100；Agent 程序层改进还可主要依赖模型调用。研究模型生成想法、代码消耗推理资源，被训练模型又消耗训练资源。两笔成本要分开，也不要求团队必须自己拥有集群。[10][12]。

6. 所以算力比算法更重要吗

短答：二者共同决定有效实验能做多少、做多大、成本多高，不能简单二选一。

追问：算法可能改善搜索方向、减少无效训练或节省上下文；更强模型和更多计算则扩大可探索范围。比较时固定总预算，观察新任务与放大规模后的表现，比只比卡数或算法名字有意义。这是本报告的判断办法，不是宣布统一 RSI 认证标准。[10][13]。

7. 怎样评价“某公司有最好的 RSI 算法”

短答：看可复查的改进对象、规模、成本和结果，不靠产品标签判断。

追问：需要区分公开可核实成果、公司自述和外部猜测。数据、benchmark 与评测服务本身可以有用，但销售这些产品不单独证明、也不直接否定 RSI。我们没有开展公司级商业调查，不能将“很多公司只在炒作”当作已证实事实。

8. 齿轮转起来，就会指数增长吗

短答：正反馈提供加速的可能，不保证持续指数增长。

追问：教学上可设想每轮保持固定比例增益、周期近似稳定，得到指数式情景；这不是观测到的增长定律。现实中收益可能递减，验证要耗时，算力与能源也可能跟不上。经济建模研究讨论这些反馈条件，不能用它预测某个“爆发日期”。[10]Possible futures；[15]。

9. AIDE²的新进展说明了什么

短答：作者报告了研究 Agent 程序层的连续改进，没有证明前沿基础模型多代自研。

追问：主运行 8 天接受 7 次改写，涉及搜索、上下文等程序；各循环内底模固定。论文另测改进 Agent 担当外层研究者，但未明确区分其相对强基线的优势。A 只点到这种局部进展，不把数字堆进主讲，也不据此宣称指数增长。[13]§2.2、§3.2、§3.6。

10. 底模不变，为什么仍可能算局部自改

短答：Agent 能力也取决于工具、搜索和记忆程序；改这些，系统行为可以改变。

追问：同一个模型配上不同程序，可能以不同顺序探索、读取不同信息、用不同预算解决问题。若修改后的 Agent 继续参与后续修改，就有代码层面的反馈。D 会用 DGM 展开；同时说明程序自改与训练更强基础模型是不同范围。[8][13]。

11. Good、Gödel Machine 和 NAS 怎样放进这条线

短答：Good 提出设想，Gödel Machine 强调证明有益，NAS 展示搜索设计；它们是背景。

追问：Good 在 1965 年讨论机器设计更好机器；Gödel Machine 在给定形式设定下寻找有益修改的证明；NAS 用搜索与实验评价网络结构。它们不能合成一个已实现的无限自改系统。主讲只留历史一句，把“如何验证更好”的思路用于理解当代案例。[1]§2；[2][3]摘要。

12. A 怎样与 B、C、D 连成完整回答

短答：A 提出研发正反馈的问题，B—D 沿实际改动与下一轮用途给出回答。

追问：第 7 页先分研究 Agent、目标模型、评测器，B 再讲训练方法；C 看评测记录与训练程序优化；D 比较策略和代码改动，追踪记录及修改后 Agent 如何继续探索。结论承认局部进展，再问能否持续研发更强基础模型，与 A 的潜力和条件同时呼应。[4]—[8][10]。

查源与练习

编号沿用全场来源与答辩。新来源为[12]Karpathy 原仓库、[13]AIDE²论文、[14]The AI Scientist、[15]RSI 经济建模；[10]为 Anthropic 的 RSI 文章，未重复编号。

先用自己的话说清“自动做实验”和“提高研究能力”，再对照七页口播试讲，标记卡住之处。个人报告结合本人负责内容和实际体会撰写；文件完成不代表本人已理解、计时或通过答辩。