组长 B 部分答辩备课

覆盖主讲第 8—13 页。依据本项目已核对的 Anthropic AAR 公开研究和当前 B 稿整理，供组长理解、练习与查源。以下公司实验没有由本组复现，口头回答与 260 秒主讲预算也未真人计时。

先掌握整段答案

研究 Agent 提出并实现训练方法，训练工具更新目标模型，独立评测器检查安全改善与能力副作用。共享记录让下一轮继续研究，但不会自动更新研究 Agent 参数。在谄媚案例中，一条成功路线是用激活引导构造教师，再训练学生学习教师的输出分布。四条件实验表明，这个案例里训练目标与可用机制值得重视；它没有证明所有任务都如此，也没有完成基础模型的多代递归研发。 [4]§2—3、App.D.4。

第 8 页讲一轮交付，第 9 页讲外部记录，第 10—11 页解释临时干预与参数训练，第 12 页定义量尺，第 13 页才用这把量尺读真实结果。先读第 1、4、6、8、9 问，再补其余问答。

讲清两个阶段

激活引导作用于模型前向计算的隐藏状态，使输出更少迎合错误观点。图中的 $h' = h + \alpha v$ 只是一般教学写法，不指定原研究的精确层号、方向和系数。教师来自 Qwen 目标模型的引导版本，不是 Claude 研究 Agent。[4]App.D.4。

蒸馏阶段让教师和学生对同一输入产生分布，以 KL 相关目标约束学生，更新学生参数。训练后用不带该临时引导的正常推理评测，才能检查变化是否保留及是否有副作用。教学短片帮助解释这条链，不能据此宣称完整复现了胜出配方。

数字先看比较条件

条件	共同前 150 个方法处	完整运行峰值
原样公共数据 SFT	6.0%	6.0%
自由构造数据 SFT	2.9%	4.5%
自由数据与 SFT + KL 自蒸馏	16.5%	18.7%
不受限方法搜索	23.3%	26.4%

均为 Qwen3.5-2B 谄媚任务的几何平均改善空间，每种条件一次搜索运行。主讲采用中列，末列仅用于区分取值口径；不能混在同一横轴比较。[4]Fig.20、App.D.4。

十个可能追问

1. AAR 里谁在研究 谁被训练

短答：Claude Opus 4.8 驱动研究 Agent，Qwen3.5-2B 是本例被训练模型，评测器检查训练产物。

追问：研究 Agent 提出方法和代码，不代表把它自己的回答直接蒸馏给目标模型。训练结果需要单独提交评测。[4]§2、§3、Table1。

2. 为什么先冻结 mini paper

短答：先留下不含结果的方法说明，防止看到分数后倒写原来的假设。

追问：冻结说明与审查代码是两项检查；代码不能实质偏离说明，改变代码还需要重新批准。[4]§3.2、App.B.5。

3. 外部记录算不算模型学会了

短答：记录提供下一轮可读的经验，参数是否改变要另外检查。

追问：AAR 每轮开启新会话，持续性来自记忆文件、共享论坛和排行榜。第 9 页没有把这种接续当成研究 Agent 权重更新。[4]§3、§3.1。

4. 激活引导和训练参数有什么区别

短答：前者干预当前前向计算的中间状态，后者改变以后推理要使用的参数。

追问：第 10 页临时改变教师输出，第 11 页才训练学生。公式只解释干预位置，不是原研究的完整配方。[4]App.D.4。

5. 不能用更强教师 为什么仍会改善

短答：这项任务可以纠正模型表达已有能力的方式，不必把全面更强模型的知识灌进去。

追问：目标模型经引导后可以更少迎合错误观点，再提供训练信号。这不能推导为小模型凭空获得任意新能力。[4]§3.2、App.D.4。

6. KL 变小就能证明更安全吗

短答：不能。分布更接近只说明训练目标取得进展，行为与能力还要独立评测。

追问：KL 两个方向通常不同。当前教学图不替胜出方法补写未完整公开的损失方向、数据或系数。教师提供目标，学生接受参数更新。[4]§2.3、App.D.4。

7. 40%为什么不是正确率

短答：分母是基线到参考最优的差距，不是测试题数。

追问：教学例子中 70−50 = 20，100−50 = 50，所以关闭 40%的差距；训练后得分仍是 70。论文再对多个基准的关闭比例取几何平均，汇总值不能代替分项表现。[4]§2.2。

8. 16.5%与 18.7%哪个正确

短答：两者取自不同位置；前 150 个方法处是 16.5%，KL 条件完整运行峰值是 18.7%。

追问：四条路线分别搜索，不是一个模型依次加数据、加 KL、加引导。受限 KL 条件禁止激活引导，不受限路线才可以构造引导教师，不能把这两种条件混成同一配方。[4]Fig.20、App.D.4。

9. 四项比较能证明什么

短答：支持在这个任务中重视训练目标与可用机制，不能直接证明普遍规律。

追问：共同 150 个方法使尝试次数可比，不保证推理、失败等总成本完全相同。每条件一次运行，该消融没有重跑 held-out 或 Petri，因此不是泛化结论。主研究为 Petri 选方法时，held-out 承担验证集角色。[4]§2.3、App.D.4。

10. 这一段怎样接全场的 RSI 问题

短答：它证明 Agent 可以参与一次真实模型改进，但尚未证明改进后的研究者能连续研发后继模型。

追问：A 先定义三个角色；B 跟踪目标模型怎样变；C 再看评测流程和训练程序优化。到 D 才分别讨论记录、Agent 版本和下一轮研发。不要把这些不同对象直接合成一个已实现的无限递归系统。

一手来源和现场定位

文献[4]：研究正文与附录。§2.2 查指标，§2.3 查评测，§3—3.2 查研究规则，App.D.4 及 Fig.20 存档查教师、KL 和四条件。现场看主讲 10—13、备份 28—29 页；其他追问查全场来源与答辩。