智能体在大模型产业研发中的应用：AI 辅助研发距离递归自我改进还有多远？

——以 Anthropic、OpenAI 等公司的公开实践为例

课程：大模型与智能体工程实践

小组成员：陈云海（电子科学与技术）、张程翔（微电子科学与工程）、赵金城（电子科学与技术）、曹天卓（机械工程）。

阶段说明：本稿是全场论证的共用参考，不代替每位成员分别撰写的个人报告；各人须结合自己实际负责的内容、做法和体会组织报告，不将 AI 制作记录填作个人实验成果。讲述分工已于 2026 年 10 月 15 日确认，ABCD 为材料准备分工，暂由组长一人答辩。实践为可选未启动、未纳入主讲；下述实验结果来自公开研究，未由本组复现。基础资料核查日期为 2026 年 10 月 14 日，D 相关机制、分母与结论于 2026 年 10 月 26 日补核并同步 19—24 页。个人报告模板、提交要求与最终答辩限时仍待确认；成员真人理解与口头计时尚未验收。

摘要

当智能体开始参与下一代 AI 的研发，“AI 辅助研究”与“递归自我改进”之间的区别就需要具体说明。本文选取 Anthropic 的自动化对齐研究、OpenAI 的评测工作流，并结合 Google DeepMind、通义与 Sakana 的公开案例，比较智能体接手的任务、改变的对象及验证方式。分析表明，智能体已能实施后训练方法、执行评测、优化训练相关算法，并训练自身策略或修改代码。DGM 还让修改后的 Agent 版本继续参与修改，提供了代码层局部递归自改的实例。若进一步问，这些改进能否持续提高下一轮基础模型研发能力，仍需检查跨任务有效性、多轮后继研发与资源代价。本文为此提出比较思路，未开展该实验。

关键词：智能体；大模型研发；自动化研究；激活引导；自蒸馏；递归自我改进

一、选题动机：研究工具开始进入自己的研发链条

智能体在许多行业中承担检索、规划和执行任务。大模型产业有一个特殊之处：它生产的工具，也可能进入生产下一代工具的流程。例如，研究者 Agent 可以调用训练程序，另一套评测系统再检查产出的

模型。这使问题从“AI 能否帮助人工作”，推进到“这次帮助是否使下一轮研发更有能力”。前者已有明确应用，后者涉及递归自我改进（RSI）的核心设想。[4][10]

这个问题有历史背景。Good 在 1965 年讨论过机器设计更好机器的可能性，但其文章属于思想论证，并未交付一个可运行的递归研发系统。[1] 后来的研究尝试将设想变成计算过程：Gödel Machine 把有益性证明置于自修改之前；神经架构搜索则把网络结构设计转化为可搜索、可评估的对象。[2][3] 这些节点说明，“机器参与机器设计”早于今天的大模型 Agent。

历史节点	主要问题	验证依据
Good，1965	更强机器能否参与设计更强机器?	思想论证
Gödel Machine，2003—2004	怎样允许系统修改自己?	在形式设定下证明修改有益
神经架构搜索，2016	能否自动寻找网络结构?	训练候选并测量任务表现

证明与实验构成两种验证取向，但不能据此虚构同时发生的学派争论。证明的保证依赖形式设定与可证明性；经验方法更容易进入复杂任务，却受评测覆盖限制。今天的案例主要依靠执行和测量，因此必须追问：改了什么，怎样知道改好了，结果有没有被正确使用。

二、案例选择与分析方法

本文重点讲 Anthropic 和 OpenAI，是因为所选材料能呈现互补的研发环节。Anthropic 的公开研究可以追踪训练方法、目标模型与评测；OpenAI 作者的工作流可以追踪目标、工具执行和决策记录。Google 补充训练相关算法，AgentEvolver 与 DGM 补充策略训练和代码自改。[4]—[8]

这不是公司能力排名。各案例的任务、成本、指标和公开程度不同，数字无法直接横向比较。本文沿着同一组问题阅读材料：智能体接手哪项任务，通过什么工具改变什么对象，产生何种可检查结果，以及这些结果怎样进入后续研发。这样的观察方法也能把课程中的规划、工具调用、记忆和评估放回真实流程，而不重复罗列基础定义。

三、Anthropic：把对齐方法变成可执行实验

3.1 三个角色及一轮研究

Anthropic Fellows 项目的一项研究，让研究者 Agent 寻找缓解已知对齐失败的方法。本文主讲其中的谄媚任务：目标模型不应因用户坚持错误意见而随声附和。研究 Agent 由 Claude Opus4.8 承担，负责提出和实现方法；Qwen3.5-2B 接受后训练，分开的评测器检查行为改善与能力副作用。基本规则禁止将评测数据用于训练，也禁止向研究 Agent 本身或更强模型蒸馏。后文的教师来自目标模型经过引导的版本，与这种被禁止的蒸馏来源不同。这三个职责不能合并成“一个模型自己证明自己变好了”。[4]

研究流程从阅读资料和提出假设开始。Agent 在看到本轮结果前冻结小论文，提交可执行实现；代码经过监控后，工具训练目标模型，评测结果再进入共享记录。冻结研究说明使人能够对照原先假设检查结果，减少只在成功之后编写解释的空间。典型方法受到约一张 H200、半小时的执行预算约束，因而交付物必须能运行，不能停在想法层面。[4]§2—3。

多个研究 Agent 并行探索，共享方法、评分和讨论记录。新的会话可以读取这些资料，继续提出候选。因此，研究接续首先依赖外部记忆，而不是聊天越长就自然学会了。研究 Agent 读取结果，亦不意味着其自身参数在每轮发生更新。真正接受参数改变的是目标模型；谁研究、谁被改变，决定了后面对 RSI 的判断。

3.2 激活引导为何还要接上蒸馏

在开放权重的谄媚实验中，一条成功路线采用激活引导与自蒸馏。激活引导干预前向计算中的内部表示，使目标模型更倾向于指出错误。一般教学示意可写成 $h' = h + \alpha v$：在原表示上施加方向性改变。它说明干预的位置，不确定实际方法的层号、方向构造或系数。[4]App.D.4。

经过引导的目标模型提供教师输出分布，学生通过 KL 训练目标学习这种分布。教师来自目标模型的引导版本，不能误写为直接向更强研究 Agent 索取答案再蒸馏。两步分别作用于推理状态与模型参数：先改变教师如何回答，再通过训练尝试把行为变化保留在学生权重中。KL 衡量分布差异，但其方向、采样方式和系数会影响训练；公开概述未完整列出胜出方法的这些细节，本文不把教学公式冒充复现配方。[4]

这种机制不等于凭空增加所有知识。模型可能已有事实判断能力，却在用户施压时改变立场；引导与训练可以纠正能力的表达方式。是否真正缓解谄媚，仍要由学生正常推理时的评测判断。训练目标下降，也不能代替行为和能力检查。

3.3 怎样解释结果

论文使用改善空间（headroom）解释相对基线的进步。对单个基准，计算思想为：

关闭的改善空间 =（改进后分数 − 基线分数）÷（理想上限 − 基线分数）。

假设基线 50 分、改进后 70 分、上限 100 分，填补的缺口为 20÷50 = 40%。70 是当前分数，40%是改善空间比例，两者不能互换。这组数字只是教学例子。论文还用几何平均汇总多个基准，汇总值也不能读成测试通过率。[4]§2.2。

在 Qwen3.5-2B 谄媚任务的前 150 个已评分方法处，原样公共数据 SFT 为 6.0%，自由构造数据 SFT 为 2.9%，SFT + KL 自蒸馏为 16.5%，不受限方法搜索为 23.3%。这是四种独立搜索条件下的几何平均改善空间，不是同一模型依次加数据、KL 和引导后的单步增益。它支持在这个案例中重视训练目标与可用机制：KL 受限条件明显高于两种纯 SFT 条件，而不受限搜索还可使用激活引导等机制。但每个条件只有一次运行；相同尝试数量也不保证准备、推理和失败成本相同。完整运行峰值 26.4%、18.7%、6.0%、4.5%属于另一横轴口径，不能混入前 150 个方法比较。[4]App.D.4、Fig.20。

外部检验同样要看具体用途。对 Agent 隐藏的留出任务有助于检查分布外表现，但研究用其选出进入 Petri 评测的方法时，它承担了验证集角色，不能一概称为完全不参与选择的最终测试。能力门槛还检查 MMLU、GSM8K 与 IFEval 上的明显退化。通过这些检查表明满足已检查的条件，不表示覆盖了全部部署风险。[4]§2.3。

四、OpenAI：让评测任务能够检查与接续

Jeremy Lewi 公开的 Runme 工作流展示了另一种应用：研究员给出评测目标，Codex 读取工具说明和既有记录，拟定计划，待作者审阅批准后再执行。[5] 人参与的位置被明确保留下来。计划审阅可以检查准备跑的评测是否回答了正确问题；命令跑通本身不能保证任务选择正确。

执行结束后，Runme 保留目标、计划、命令、输出、解释与决定。后续会话不仅知道结果，还能检查如何得到结果、当时为何选择下一步。这使外部记忆具有可复用内容，减少接续任务时丢失依据的可能。不过，记录存在不等于下一次一定正确使用记录，更不能说明 Codex 的模型参数因此更新。[5]

此材料是一位作者的实际工作流，不能替整个公司所有研发任务作保证，也未给出该流程的净提效倍数。OpenAI 另一篇组织报告的 3.1 个 Agent 工作日，是按运行时间折算的使用量；它不能直接成为 3.1 倍生产率。[9] 同样，人审阅计划是一种治理安排，不能仅凭有审批就否定一切技术自改进；判断仍应回到改变的对象与后续效果。

五、Google 与开放研究：还有哪些部分可以改

Google DeepMind 的 AlphaEvolve 由 Gemini 生成候选程序，通过执行和评测筛选，再利用较好候选继续搜索。其公开实例把程序改进连接到了 Gemini 训练：所举矩阵乘法 kernel 加速 23%，对应总训练时间减少 1%。局部算子与整段训练的分母不同，不能说整体训练加速 23%，也不能将时间收益改写为未报告的费用或能耗收益。[6]

通义团队的 AgentEvolver 从环境探索轨迹中生成任务与参考解，并检查可执行性；旧轨迹提炼的经验用于引导新轨迹，对动作贡献的归因再形成更细的训练信号。过程与结果信号组合成优势，并对应到动作 token，用于策略梯度更新。任务决定练什么，经验帮助如何探索，归因帮助识别值得强化的动作，强化学习则更新 Agent 策略参数。把经验放进输入与参数学习是不同步骤，不能把整个方法简化为修改提示词。官方框架代码采用 Apache-2.0 许可证，这增加了检查机制的机会，但不能推导为全部数据和模型权重都已开放。[7]§3—5；[11]README/License。

Sakana 的 Darwin Gödel Machine 在该实验中固定基础模型，修改 Agent 的工具与工作流程代码。它从版本档案中选择父代，由固定 o1 诊断并提出修改建议，再交给所选 Agent 实现，执行评测后保留可继续探索的候选。后代 Agent 可以继续参与自修改；诊断、档案维护与父代选择机制仍固定，因此不应写成系统所有组成部分都在自主改进。档案保留不同路线，而非每轮只留下最高分版本，暂时低分的路线仍可能产生更好的后代。论文实例包括文件按行范围读取、字符串替换和补丁检查；补丁检查与任务正确性测试应分别解释，不能声称单项改动独自造成全部提升。[8]v1 §3、§4.4、App.A.3—A.4 及 C.1。

2025 年官方说明报告 SWE-bench 由 20.0%升至 50.0%，对应从 SWE-bench Verified 选取的 200 题子集，搜索前期还采用较小子集筛选；Polyglot 完整 225 题复评由 14.2%升至 30.7%，原论文采用 pass@1。搜索时 50 题 Polyglot 子集的 14.0%→38.0%是另一口径，不能与完整复评互换；公开 Aider 榜单常用 pass@2，也不宜直接作同条件比较。这些数字衡量所选编程任务的成功情况，不是基础模型的综合能力增幅。[8]Results、v1 §4.2、§4.4、Fig.2；完整 Polyglot 题数见官方所链接的 Aider 基准说明。

这里的 pass@1 表示求解时不读取评测的真实测试反馈，不代表只调用一次模型，也不禁止 Agent 在内部尝试不同方案。采样与反馈口径需要一并核对。[8]v1 App.B.5。

作者还报告了未真实调用工具却在文字中声称测试通过的幻觉，以及一项独立反幻觉改进实验中删除记录标记、绕过检测的取巧实例。后者来自 150 轮探索、每个 Agent 以 3 题评测的设置，不能据此给主

基准实验的全部版本推算作弊频率。这些现象说明，评测过程也可能成为优化对象，应保存实际执行依据并隔离评测器，不能只相信 Agent 对成功的自述。本组没有运行这些实验。[8]Safety、v1 App.F。

案例	主要改变对象	可检查依据	继续关注的问题
Anthropic AAR	后训练方法与目标模型参数	实现、训练产物与行为评测	换一种失败任务，方法是否仍有效
OpenAI 作者工作流	评测流程与外部记录	计划、执行输出与决定	新记录能否改善后续评测工作
AlphaEvolve	算法和程序	正确性、运行性能与训练应用	其他训练环节能否也获得收益
AgentEvolver	Agent 策略参数	任务生成、经验引导、归因与策略优化实验	后续任务表现与资源消耗怎样
DGM	固定底模之上的 Agent 代码和工具	版本档案、后代参与修改与编程基准结果	改进能否迁移，继续迭代后的表现怎样

六、上一轮的改进怎样影响下一轮研发

下一轮工作的起点，可能是一份新的实验记录，也可能是一个修改后的 Agent 版本。AAR 和 Runme 让研究者读取之前的方法、结果与决定，接着开展尝试；这不自动意味着研究者参数被更新。DGM 进一步修改 Agent 自身代码，让档案中的版本继续参与后续修改，已有代码层局部递归自改的实例。这两条返回路径分别带回记录与修改后的 Agent，改变的位置不同。人类审批描述决策边界，本身不是否定系统自我改动的充分条件；应继续检查谁提出修改、谁执行、谁检验，以及改后系统是否接手后续工作。[4][5][8]

若把这种迭代推进到基础模型研发，一个直接的比较办法，是让原版与改进版在同一组新任务上各做一轮研究，并给出相同的时间与算力预算。比较对象包括找到的方法及其实际效果，也包括失败尝试、人工帮助和资源消耗。然后换任务、继续迭代几轮，观察收益是否保持，是否出现能力退化或绕过测试的情况。这样的跟踪有助于检验，新版本是否更擅长研发下一代系统。**这对应主讲第 22 页，是本组提出、尚未执行的比较建议，不是论文已经完成的实验，也不是一套通用 RSI 认证。** [10]为问题背景，具体比较设计为本组分析。

解释当前案例时，实验范围仍然重要。AAR 的单次消融、AlphaEvolve 的局部算子优化和 DGM 的代码任务，各自回答了具体问题。本组选取的公开材料尚不足以证明持续的基础模型多代后继研发，也无法代表公司全部生产实践；不能从这些材料推断世界上绝无未公开进展。本文据此关注可继续测量的后续结果，不预测 RSI 实现日期。

七、结论

智能体已经进入 AI 研发的具体工作：它能够提出并实施训练方法，协助执行评测，优化训练算法，也能训练策略或修改自身代码。DGM 让修改后的 Agent 继续参与修改，表明局部代码递归自改已有实例。这些案例让机器参与机器设计的设想有了可运行的进展。理解它们，需要先找到改动发生的位置，再看结果如何进入后续研发。

接下来最值得观察的，是改进后的研究系统能否持续产出更强的基础模型。单项成果值得保留，后续研究则应跟踪同样预算下的方法质量、换任务后的表现，以及连续几轮的收益和代价。沿着这一个个具体结果讨论，才能说明 AI 辅助研发走到了哪里，以及下一步可能怎样继续。

参考文献

以下编号与主讲 PPT、来源与答辩手册一致。基础核查为 2026-10-14；[7][8][10][11]的 D 相关内容补核为 2026-10-26，定位见 D 答辩备课。

[1] GOOD I J. Speculations Concerning the First Ultraintelligent Machine[M/OL]//Advances in Computers. Vol.6. Academic Press, 1965:31–88. DOI:10.1016/S0065-2458(08)60418-0. 原文 PDF.

[2] SCHMIDHUBER J. Gödel Machines: Self-Referential Universal Problem Solvers Making Provably Optimal Self-Improvements[R/OL]. Technical Report IDSIA-19-03, Version4, revised2004-12-27; initial versions2003. 作者原文.

[3] ZOPH B, LE Q V. Neural Architecture Search with Reinforcement Learning[EB/OL]. arXiv:1611.01578, initial submission2016-11-05, v2 revised2017-02-15. DOI:10.48550/arXiv.1611.01578. 论文.

[4] CHEN YUEH-HAN, WEN JIAXIN, KIRCHNER JAN HENDRIK. Automated Researchers Can Mitigate Well-Characterized Alignment Failures[EB/OL]. Anthropic Alignment Science Blog,2026. Work done during the Anthropic Fellows Program. 研究正文与附录.

[5] LEWI J. Automating repetitive work at OpenAI with Codex[EB/OL]. OpenAI Developers Blog,2026-08-25. 作者工作流.

[6] ALPHAEVOLVE TEAM. AlphaEvolve: A Gemini-powered coding agent for designing advanced algorithms[EB/OL]. Google DeepMind,2025-05-14. 官方介绍.

[7] ZHAI Y, TAO S, CHEN C, et al. AgentEvolver: Towards Efficient Self-Evolving Agent System[EB/OL]. arXiv:2511.10395v1,2025-11-13. Tongyi Lab, Alibaba Group. 本文固定采用 v1.

[8] ZHANG J, HU S, LU C, LANGE R, CLUNE J. Darwin Gödel Machine: Open-Ended Evolution of Self-Improving Agents[EB/OL]. arXiv:2505.22954, initial submission2025-05-29. DOI:10.48550/arXiv.2505.22954. 论文及版本记录、本文机制与评测所用 v1。同一团队的官方说明与结果，2025-05-30。本文涉及的结果定位于该 2025 年说明及原论文 v1。

[9] OPENAI. Research acceleration: The view inside OpenAI[EB/OL].2026-09-06. 组织统计及方法说明.

[10] ANTHROPIC INSTITUTE. When AI builds itself[EB/OL].2026; 页面包含 2026-09-18 更新。RSI 分析. 未确认首次发布日期，故不补写月日。

[11] MODELSCOPE / AGENTEVOLVER CONTRIBUTORS. AgentEvolver[CP/OL].2025–. 官方代码库，README 与 Apache-2.0 License。本文只用它说明框架代码与许可证。