智能体在 AI 研发中的应用

——从模型与工具，到 Agent 自身的改进

课程：大模型与智能体工程实践

小组成员：陈云海（电子科学与技术）、张程翔（微电子科学与工程）、赵金城（电子科学与技术）、曹天卓（机械工程）。

阶段说明：本稿是全场论证的共用参考，不代替每位成员分别撰写的个人报告；各人须结合自己实际负责的内容、做法和体会组织报告，不将 AI 制作记录填作个人实验成果。讲述分工已于 2026 年 10 月 15 日确认，ABCD 为材料准备分工，暂由组长一人答辩。实践为可选未启动、未纳入主讲；下述实验结果来自公开研究，未由本组复现。基础核查为 2026 年 10 月 14 日，D 于 10 月 26 日补核；A 的 RSI、autoresearch、资源与正反馈论点于 10 月 28 日补核并同步 01—07 页。个人报告模板、提交要求与最终答辩限时仍待确认；成员真人理解与口头计时尚未验收。

摘要

本报告采用主题一的行业应用案例研究，考察 Agent 在人类设定目标和审核下怎样参与 AI 研发。随着 Agent 从问答走向使用工具执行任务，其依赖的模型、工具和运行流程仍需持续改进。本文从已有系统出发，沿修改、训练或评测、判断与保留成果的主线，分析研发正反馈的价值、资源与验证门槛，再沿 Anthropic、OpenAI、Google 及开放研究的公开案例，比较任务、改动对象和结果如何进入后续研发。所选材料显示，智能体已能实施后训练方法、执行评测、优化训练程序，并训练策略或修改自身代码；DGM 及 AIDE²还报告了 Agent 代码层的连续改进。局部进展值得重视，持续基础模型后继研发与指数式加速则需进一步检验。本文据此提出跨任务、同预算及多轮比较思路，未开展该实验。

关键词：智能体；大模型研发；自动化研究；激活引导；自蒸馏；递归自我改进

一、选题动机：Agent 开始参与支撑自身能力的研发

Agent 的应用性能既取决于模型能力，也取决于工具、评测和行动流程。过去主要依赖人编写实现和运行实验的研发工作，今天也开始由 Agent 参与。因此，我们选择 AI 研发作为应用行业，而不把它泛化成所有软件开发。本报告沿同一个问题比较不同改动对象，不声称所有案例都训练了同一个 baseline Agent。[4]—[8][10]

RSI 是 Recursive Self-Improvement，递归自我改进，强调改进后的系统继续推动后续改进。Good、Gödel Machine 与神经架构搜索提供历史和方法背景；当前主讲先交代行业与目录，再落到今天可追踪的研发工作。[1]—[3][10]

Karpathy 在 2026 年 3 月的 autoresearch 项目提供了直观入口：Agent 修改训练代码，让小模型训练，再比较验证指标，保留或丢弃修改后继续尝试。原版单 GPU，训练预算为 5 分钟，不含启动与编译；整轮还需代码修改、推理和检查等开销。[12] 自动研究方向并非始于此，2024 年的 The AI Scientist 已探索自动科学发现。[14] autoresearch 自动化研究过程，RSI 进一步追问研究者的后续改进能力是否随之提高；二者相关，不能仅凭一次循环就视为同一个已实现结果。

这种关联的意义在于研发正反馈。更强的 AI 帮助找到和验证方法，研发成果又可能提高下一轮研究能力，收益便有机会逐轮积累。若增益持续、周期与资源允许，可能出现复利式甚至指数式加速；一张反馈图本身并不能证明这种速度已经实现。算力、能源、评测和研究判断仍可能成为瓶颈。[10] 相关经济学研究讨论反馈强度和加速条件，是建模与估计，不能当作已测得的增长定律。[15]

二、案例选择、资源门槛与分析方法

小规模实验能开始，不代表成果已在前沿模型上成立。研究 Agent 的推理能力与调用成本、目标模型训练的算力与实验周期，需要分别考察。好算法可能节省资源，资源又决定可以并行试多少、验证到多大规模；不能把二者当成替代关系。判断所谓 RSI 算法，应追问同预算是否仍有效、能否迁移到新任务、放大后是否保持收益。这些是本报告的比较要求，不是已完成的实验或通用认证。[10][12]

数据和 benchmark 可以有实际用途，但产品存在不能证明持续自改已经实现。本组没有足以概括许多公司动机的证据，因此不把“很多公司只是炒作”写成行业事实。本文将批判落在可检查的研发结果、预算与适用范围，避免让品牌和术语代替验证。

后文重点选择 Anthropic 与 OpenAI，是因为所选材料分别能追踪训练方法进入模型、评测任务如何执行和留下记录；Google 补充训练程序，AgentEvolver 与 DGM 补充策略和代码自改。[4]—[8] 2026 年 9 月的 AIDE²预印本也报告了研究 Agent 程序的连续改进，研究循环内底模固定；这是代码层的作者报告，尚不能据此推出前沿基础模型的多代自研。[13]

四部分目录依次为选题与主线、Anthropic 的模型训练、OpenAI 与 Google 的研发流程与程序优化、Agent 自我改进与下一轮研发。后续主讲页使用对应部分标题，帮助听众定位。各案例的任务、成本、指标和公开程度不同，不作公司能力排名。本文沿着接手任务、使用工具、改变对象、验证结果和进入

下一轮的方式比较，让课程中的规划、记忆与评估对应到真实研发动作。A 先提出全场问题，后文再分别检查训练、评测、算法、策略与代码的具体进展。

三、Anthropic：把对齐方法变成可执行实验

3.1 三个角色及一轮研究

Anthropic Fellows 项目的一项研究，让研究者 Agent 寻找缓解已知对齐失败的方法。本文主讲其中的谄媚任务：目标模型不应因用户坚持错误意见而随声附和。研究 Agent 由 Claude Opus4.8 承担，负责提出和实现方法；Qwen3.5-2B 接受后训练，分开的评测器检查行为改善与能力副作用。基本规则禁止将评测数据用于训练，也禁止向研究 Agent 本身或更强模型蒸馏。后文的教师来自目标模型经过引导的版本，与这种被禁止的蒸馏来源不同。这三个职责不能合并成“一个模型自己证明自己变好了”。[4]

研究流程从阅读资料和提出假设开始。Agent 在看到本轮结果前冻结小论文，提交可执行实现；代码经过监控后，工具训练目标模型，评测结果再进入共享记录。冻结研究说明使人能够对照原先假设检查结果，减少只在成功之后编写解释的空间。典型方法受到约一张 H200、半小时的执行预算约束，因而交付物必须能运行，不能停在想法层面。[4]§2—3。

多个研究 Agent 并行探索，共享方法、评分和讨论记录。新的会话可以读取这些资料，继续提出候选。因此，研究接续首先依赖外部记忆，而不是聊天越长就自然学会了。研究 Agent 读取结果，亦不意味着其自身参数在每轮发生更新。真正接受参数改变的是目标模型；谁研究、谁被改变，决定了后面对 RSI 的判断。

3.2 激活引导为何还要接上蒸馏

在开放权重的谄媚实验中，一条成功路线采用激活引导与自蒸馏。激活引导干预前向计算中的内部表示，使目标模型更倾向于指出错误。一般教学示意可写成 $h' = h + \alpha v$：在原表示上施加方向性改变。它说明干预的位置，不确定实际方法的层号、方向构造或系数。[4]App.D.4。

经过引导的目标模型提供教师输出分布，学生通过 KL 训练目标学习这种分布。教师来自目标模型的引导版本，不能误写为直接向更强研究 Agent 索取答案再蒸馏。两步分别作用于推理状态与模型参数：先改变教师如何回答，再通过训练尝试把行为变化保留在学生权重中。KL 衡量分布差异，但其方向、采样方式和系数会影响训练；公开概述未完整列出胜出方法的这些细节，本文不把教学公式冒充复现配方。[4]

这种机制不等于凭空增加所有知识。模型可能已有事实判断能力，却在用户施压时改变立场；引导与训练可以纠正能力的表达方式。是否真正缓解谄媚，仍要由学生正常推理时的评测判断。训练目标下降，也不能代替行为和能力检查。

3.3 怎样解释结果

论文使用改善空间（headroom）解释相对基线的进步。对单个基准，计算思想为：

关闭的改善空间 =（改进后分数 − 基线分数）÷（理想上限 − 基线分数）。

假设基线 50 分、改进后 70 分、上限 100 分，填补的缺口为 20÷50 = 40%。70 是当前分数，40%是改善空间比例，两者不能互换。这组数字只是教学例子。论文还用几何平均汇总多个基准，汇总值也不能读成测试通过率。[4]§2.2。

在 Qwen3.5-2B 谄媚任务的前 150 个已评分方法处，原样公共数据 SFT 为 6.0%，自由构造数据 SFT 为 2.9%，SFT + KL 自蒸馏为 16.5%，不受限方法搜索为 23.3%。这是四种独立搜索条件下的几何平均改善空间，不是同一模型依次加数据、KL 和引导后的单步增益。它支持在这个案例中重视训练目标与可用机制：KL 受限条件明显高于两种纯 SFT 条件，而不受限搜索还可使用激活引导等机制。但每个条件只有一次运行；相同尝试数量也不保证准备、推理和失败成本相同。完整运行峰值 26.4%、18.7%、6.0%、4.5%属于另一横轴口径，不能混入前 150 个方法比较。[4]App.D.4、Fig.20。

外部检验同样要看具体用途。对 Agent 隐藏的留出任务有助于检查分布外表现，但研究用其选出进入 Petri 评测的方法时，它承担了验证集角色，不能一概称为完全不参与选择的最终测试。能力门槛还检查 MMLU、GSM8K 与 IFEval 上的明显退化。通过这些检查表明满足已检查的条件，不表示覆盖了全部部署风险。[4]§2.3。

四、OpenAI：让评测任务能够检查与接续

Jeremy Lewi 公开的 Runme 工作流展示了另一种应用：研究员给出评测目标，Codex 读取工具说明和既有记录，拟定计划，待作者审阅批准后再执行。[5] 人参与的位置被明确保留下来。计划审阅可以检查准备跑的评测是否回答了正确问题；命令跑通本身不能保证任务选择正确。

执行结束后，Runme 保留目标、计划、命令、输出、解释与决定。后续会话不仅知道结果，还能检查如何得到结果、当时为何选择下一步。这使外部记忆具有可复用内容，减少接续任务时丢失依据的可能。不过，记录存在不等于下一次一定正确使用记录，更不能说明 Codex 的模型参数因此更新。[5]

此材料是一位作者的实际工作流，不能替整个公司所有研发任务作保证，也未给出该流程的净提效倍数。OpenAI 另一篇组织报告的 3.1 个 Agent 工作日，是按运行时间折算的使用量；它不能直接成为 3.1 倍生产率。[9] 同样，人审阅计划是一种治理安排，不能仅凭有审批就否定一切技术自改进；判断仍应回到改变的对象与后续效果。

五、Google 与开放研究：还有哪些部分可以改

Google DeepMind 的 AlphaEvolve 由 Gemini 生成候选程序，通过执行和评测筛选，再利用较好候选继续搜索。程序数据库保存候选，由进化算法选择父代用于下一轮生成。其公开实例把程序改进连接到了 Gemini 训练：所举矩阵乘法 kernel 加速 23%，对应总训练时间减少 1%。局部算子与整段训练的分母不同，不能说整体训练加速 23%，也不能将时间收益改写为未报告的费用或能耗收益。原文 23% 描述 kernel 的 speedup，不是该 kernel 耗时减少 23%。官方还报告同类 kernel 优化由专家数周工作转为数天自动实验；这是该案例的开发收益，不能泛化为全部研发的通用比例。[6]

通义团队的 AgentEvolver 从环境探索轨迹中生成任务与参考解，并检查可执行性；旧轨迹提炼的经验用于引导新轨迹，对动作贡献的归因再形成更细的训练信号。过程与结果信号组合成优势，并对应到动作 token，用于策略梯度更新。任务决定练什么，经验帮助如何探索，归因帮助识别值得强化的动作，强化学习则更新 Agent 策略参数。把经验放进输入与参数学习是不同步骤，不能把整个方法简化为修改提示词。官方框架代码采用 Apache-2.0 许可证，这增加了检查机制的机会，但不能推导为全部数据和模型权重都已开放。[7]§3—5；[11]README/License。

Sakana 的 Darwin Gödel Machine 在该实验中固定基础模型，修改 Agent 的工具与工作流程代码。它从版本档案中选择父代，由固定 o1 诊断并提出修改建议，再交给所选 Agent 实现，执行评测后保留可继续探索的候选。后代 Agent 可以继续参与自修改；诊断、档案维护与父代选择机制仍固定，因此不应写成系统所有组成部分都在自主改进。档案保留不同路线，而非每轮只留下最高分版本，暂时低分的路线仍可能产生更好的后代。论文实例包括文件按行范围读取、字符串替换和补丁检查；补丁检查与任务正确性测试应分别解释，不能声称单项改动独自造成全部提升。[8]v1 §3、§4.4、App.A.3—A.4 及 C.1。

2025 年官方说明报告 SWE-bench 由 20.0%升至 50.0%，对应从 SWE-bench Verified 选取的 200 题子集，搜索前期还采用较小子集筛选；Polyglot 完整 225 题复评由 14.2%升至 30.7%，原论文采用 pass@1。搜索时 50 题 Polyglot 子集的 14.0%→38.0%是另一口径，不能与完整复评互换；公开 Aider 榜单常用 pass@2，也不宜直接作同条件比较。这些数字衡量所选编程任务的成功情况，不是基

础模型的综合能力增幅。[8]Results、v1 §4.2、§4.4、Fig.2；完整 Polyglot 题数见官方所链接的 Aider 基准说明。

这里的 pass@1 表示求解时不读取评测的真实测试反馈，不代表只调用一次模型，也不禁止 Agent 在内部尝试不同方案。采样与反馈口径需要一并核对。[8]v1 App.B.5。

作者还报告了未真实调用工具却在文字中声称测试通过的幻觉，以及一项独立反幻觉改进实验中删除记录标记、绕过检测的取巧实例。后者来自 150 轮探索、每个 Agent 以 3 题评测的设置，不能据此给主基准实验的全部版本推算作弊频率。这些现象说明，评测过程也可能成为优化对象，应保存实际执行依据并隔离评测器，不能只相信 Agent 对成功的自述。本组没有运行这些实验。[8]Safety、v1 App.F。

案例	主要改变对象	可检查依据	继续关注的问题
Anthropic AAR	后训练方法与目标模型参数	实现、训练产物与行为评测	换一种失败任务，方法是否仍有效
OpenAI 作者工作流	评测流程与外部记录	计划、执行输出与决定	新记录能否改善后续评测工作
AlphaEvolve	算法和程序	正确性、运行性能与训练应用	其他训练环节能否也获得收益
AgentEvolver	Agent 策略参数	任务生成、经验引导、归因与策略优化实验	后续任务表现与资源消耗怎样
DGM	固定底模之上的 Agent 代码和工具	版本档案、后代参与修改与编程基准结果	改进能否迁移，继续迭代后的表现怎样

六、上一轮的改进怎样影响下一轮研发

下一轮工作的起点，可能是一份新的实验记录，也可能是一个修改后的 Agent 版本。AAR 和 Runme 让研究者读取之前的方法、结果与决定，接着开展尝试；这不自动意味着研究者参数被更新。DGM 进一步修改 Agent 自身代码，让档案中的版本继续参与后续修改，已有代码层局部递归自改的实例。这两条返回路径分别带回记录与修改后的 Agent，改变的位置不同。人类审批描述决策边界，本身不是否

定系统自我改动的充分条件；应继续检查谁提出修改、谁执行、谁检验，以及改后系统是否接手后续工作。[4][5][8]

若把这种迭代推进到基础模型研发，一个直接的比较办法，是让原版与改进版在同一组新任务上各做一轮研究，并给出相同的时间与算力预算。比较对象包括找到的方法及其实际效果，也包括失败尝试、人工帮助和资源消耗。然后换任务、继续迭代几轮，观察收益是否保持，是否出现能力退化或绕过测试的情况。这样的跟踪有助于检验，新版本是否更擅长研发下一代系统。**这对应主讲第 22 页，是本组提出、尚未执行的比较建议，不是论文已经完成的实验，也不是一套通用 RSI 认证。** [10]为问题背景，具体比较设计为本组分析。

解释当前案例时，实验范围仍然重要。AAR 的单次消融、AlphaEvolve 的局部算子优化和 DGM 的代码任务，各自回答了具体问题。本组选取的公开材料尚不足以证明持续的基础模型多代后继研发，也无法代表公司全部生产实践；不能从这些材料推断世界上绝无未公开进展。本文据此关注可继续测量的后续结果，不预测 RSI 实现日期。

七、结论

智能体已经进入 AI 研发的具体工作：它能够提出并实施训练方法，协助执行评测，优化训练算法，也能训练策略或修改自身代码。DGM 让修改后的 Agent 继续参与修改，表明局部代码递归自改已有实例。这些案例让机器参与机器设计的设想有了可运行的进展。理解它们，需要先找到改动发生的位置，再看结果如何进入后续研发。

接下来最值得观察的，是改进后的研究系统能否持续产出更强的基础模型。单项成果值得保留，后续研究则应跟踪同样预算下的方法质量、换任务后的表现，以及连续几轮的收益和代价。沿着这一个个具体结果讨论，才能说明 AI 辅助研发走到了哪里，以及下一步可能怎样继续。

参考文献

以下编号与主讲 PPT、来源与答辩手册一致。基础核查为 2026-10-14；[7][8][10][11]的 D 相关内容补核为 2026-10-26，定位见 D 答辩备课。A 于 2026-10-28 复用[10]并新增[12]—[15]；[14][15]主要用于背景和备课。

[1] GOOD I J. Speculations Concerning the First Ultraintelligent Machine[M/OL]//Advances in Computers. Vol.6. Academic Press, 1965:31–88. DOI:10.1016/S0065-2458(08)60418-0. 原文 PDF.

[2] SCHMIDHUBER J. Gödel Machines: Self-Referential Universal Problem Solvers Making Provably Optimal Self-Improvements[R/OL]. Technical Report IDSIA-19-03, Version4, revised2004-12-27; initial versions2003. 作者原文.
[3] ZOPH B, LE Q V. Neural Architecture Search with Reinforcement Learning[EB/OL]. arXiv:1611.01578, initial submission2016-11-05, v2 revised2017-02-15. DOI:10.48550/arXiv.1611.01578. 论文.
[4] CHEN YUEH-HAN, WEN JIAXIN, KIRCHNER JAN HENDRIK. Automated Researchers Can Mitigate Well-Characterized Alignment Failures[EB/OL]. Anthropic Alignment Science Blog,2026. Work done during the Anthropic Fellows Program. 研究正文与附录.
[5] LEWI J. Automating repetitive work at OpenAI with Codex[EB/OL]. OpenAI Developers Blog,2026-08-25. 作者工作流.
[6] ALPHAEVOLVE TEAM. AlphaEvolve: A Gemini-powered coding agent for designing advanced algorithms[EB/OL]. Google DeepMind,2025-05-14. 官方介绍.
[7] ZHAI Y, TAO S, CHEN C, et al. AgentEvolver: Towards Efficient Self-Evolving Agent System[EB/OL]. arXiv:2511.10395v1,2025-11-13. Tongyi Lab, Alibaba Group. 本文固定采用 v1.
[8] ZHANG J, HU S, LU C, LANGE R, CLUNE J. Darwin Gödel Machine: Open-Ended Evolution of Self-Improving Agents[EB/OL]. arXiv:2505.22954, initial submission2025-05-29. DOI:10.48550/arXiv.2505.22954. 论文及版本记录、本文机制与评测所用 v1。同一团队的官方说明与结果，2025-05-30。本文涉及的结果定位于该 2025 年说明及原论文 v1。
[9] OPENAI. Research acceleration: The view inside OpenAI[EB/OL].2026-09-06. 组织统计及方法说明.
[10] ANTHROPIC INSTITUTE. When AI builds itself[EB/OL].2026; 页面包含 2026-09-18 更新。RSI 分析. 未确认首次发布日期，故不补写月日。
[11] MODELSCOPE / AGENTEVOLVER CONTRIBUTORS. AgentEvolver[CP/OL].2025–. 官方代码库，README 与 Apache-2.0 License。本文只用它说明框架代码与许可证。
[12] KARPATHY A. autoresearch[CP/OL].2026，README 署名 March 2026. 作者原仓库。本文采用项目说明、How it works 及 Design choices。
[13] SRIKANTH D, ZHAO B, XU D, WU Y, JIANG Z. Recursive self-improvement of AI research agents[EB/OL]. arXiv:2609.26457v1,2026-09-22. AIDE²原论文。
[14] LU Chris, LU Cong, LANGE R T, et al. The AI Scientist: Towards Fully Automated Open-Ended Scientific Discovery[EB/OL]. arXiv:2408.06292, initial submission2024-08-12. 摘要与提交记录。
[15] CUNNINGHAM T, ALTHOFF L, HALPERIN B, et al. The Economics of Recursive Self-Improvement[EB/OL]. arXiv:2609.15802v1,2026-09-14. 摘要与论文入口。