# 智能体在大模型产业研发中的应用：AI 辅助研发距离递归自我改进还有多远？

## ——以 Anthropic、OpenAI 等公司的公开实践为例

课程：大模型与智能体工程实践

小组成员：陈云海（电子科学与技术）、张程翔（微电子科学与工程）、赵金城（电子科学与技术）、曹天卓（机械工程）。

阶段说明：本组实践章节暂不纳入；最终汇报时限与成员贡献待确认。下述实验结果来自公开研究，未由本组复现。资料核查日期为 2026 年 10 月 14 日。

## 摘要

当智能体开始参与下一代 AI 的研发，“AI 辅助研究”与“递归自我改进”之间的区别就需要具体说明。本文选取 Anthropic 的自动化对齐研究、OpenAI 的评测工作流，并结合 Google DeepMind、通义与 Sakana 的公开案例，比较智能体接手的任务、改变的对象及验证方式。分析表明，智能体已能实施后训练方法、执行评测、优化训练相关算法，并探索自身策略和代码的改动。但实验结果反馈到下一次尝试，与改进持续增强后续研发能力，是需要分别验证的两件事。当前案例提供了局部改进的可检查证据；要支持持续递归，还需展示跨任务有效性、多轮后继研发及其资源代价。

关键词：智能体；大模型研发；自动化研究；激活引导；自蒸馏；递归自我改进

## 一、选题动机：研究工具开始进入自己的研发链条

智能体在许多行业中承担检索、规划和执行任务。大模型产业有一个特殊之处：它生产的工具，也可能进入生产下一代工具的流程。例如，研究者 Agent 可以调用训练程序，另一套评测系统再检查产出的模型。这使问题从“AI 能否帮助人工作”，推进到“这次帮助是否使下一轮研发更有能力”。前者已有明确应用，后者涉及递归自我改进（RSI）的核心设想。[4][10]

这个问题有历史背景。Good 在 1965 年讨论过机器设计更好机器的可能性，但其文章属于思想论证，并未交付一个可运行的递归研发系统。[1] 后来的研究尝试将设想变成计算过程：Gödel Machine 把有

益性证明置于自修改之前；神经架构搜索则把网络结构设计转化为可搜索、可评估的对象。[2][3] 这些节点说明，“机器参与机器设计”早于今天的大模型 Agent。

| 历史节点 | 主要问题 | 验证依据 |
| --- | --- | --- |
| Good，1965 | 更强机器能否参与设计更强机器? | 思想论证 |
| Gödel Machine，2003—2004 | 怎样允许系统修改自己? | 在形式设定下证明修改有益 |
| 神经架构搜索，2016 | 能否自动寻找网络结构? | 训练候选并测量任务表现 |

证明与实验构成两种验证取向，但不能据此虚构同时发生的学派争论。证明的保证依赖形式设定与可证明性；经验方法更容易进入复杂任务，却受评测覆盖限制。今天的案例主要依靠执行和测量，因此必须追问：改了什么，怎样知道改好了，结果有没有被正确使用。

## 二、案例选择与分析方法

本文重点讲 Anthropic 和 OpenAI，是因为所选材料能呈现互补的研发环节。Anthropic 的公开研究可以追踪训练方法、目标模型与评测；OpenAI 作者的工作流可以追踪目标、工具执行和决策记录。Google 补充训练相关算法，AgentEvolver 与 DGM 补充策略训练和代码自改。[4]—[8]

这不是公司能力排名。各案例的任务、成本、指标和公开程度不同，数字无法直接横向比较。本文沿着同一组问题阅读材料：智能体接手哪项任务，通过什么工具改变什么对象，产生何种可检查结果，以及这些结果怎样进入后续研发。这样的观察方法也能把课程中的规划、工具调用、记忆和评估放回真实流程，而不重复罗列基础定义。

## 三、Anthropic：把对齐方法变成可执行实验

### 3.1 三个角色及一轮研究

Anthropic Fellows 项目的一项研究，让研究者 Agent 寻找缓解已知对齐失败的方法。本文主讲其中的谄媚任务：目标模型不应因用户坚持错误意见而随声附和。研究 Agent 由 Claude Opus4.8 承担，负责提出和实现方法；Qwen3.5-2B 接受后训练，分开的评测器检查行为改善与能力副作用。基本规则禁止将评测数据用于训练，也禁止向研究 Agent 本身或更强模型蒸馏。后文的教师来自目标模型经过引

导的版本，与这种被禁止的蒸馏来源不同。这三个职责不能合并成“一个模型自己证明自己变好了”。[4]

研究流程从阅读资料和提出假设开始。Agent 在看到本轮结果前冻结小论文，提交可执行实现；代码经过监控后，工具训练目标模型，评测结果再进入共享记录。冻结研究说明使人能够对照原先假设检查结果，减少只在成功之后编写解释的空间。典型方法受到约一张 H200、半小时的执行预算约束，因而交付物必须能运行，不能停在想法层面。[4]§2—3。

多个研究 Agent 并行探索，共享方法、评分和讨论记录。新的会话可以读取这些资料，继续提出候选。因此，研究接续首先依赖外部记忆，而不是聊天越长就自然学会了。研究 Agent 读取结果，亦不意味着其自身参数在每轮发生更新。真正接受参数改变的是目标模型；谁研究、谁被改变，决定了后面对 RSI 的判断。

### 3.2 激活引导为何还要接上蒸馏

在开放权重的谄媚实验中，一条成功路线采用激活引导与自蒸馏。激活引导干预前向计算中的内部表示，使目标模型更倾向于指出错误。一般教学示意可写成 $h' = h + \alpha v$：在原表示上施加方向性改变。它说明干预的位置，不确定实际方法的层号、方向构造或系数。[4]App.D.4。

经过引导的目标模型提供教师输出分布，学生通过 KL 训练目标学习这种分布。教师来自目标模型的引导版本，不能误写为直接向更强研究 Agent 索取答案再蒸馏。两步分别作用于推理状态与模型参数：先改变教师如何回答，再通过训练尝试把行为变化保留在学生权重中。KL 衡量分布差异，但其方向、采样方式和系数会影响训练；公开概述未完整列出胜出方法的这些细节，本文不把教学公式冒充复现配方。[4]

这种机制不等于凭空增加所有知识。模型可能已有事实判断能力，却在用户施压时改变立场；引导与训练可以纠正能力的表达方式。是否真正缓解谄媚，仍要由学生正常推理时的评测判断。训练目标下降，也不能代替行为和能力检查。

### 3.3 怎样解释结果

论文使用改善空间（headroom）解释相对基线的进步。对单个基准，计算思想为：

关闭的改善空间 =（改进后分数 − 基线分数）÷（理想上限 − 基线分数）。

假设基线 50 分、改进后 70 分、上限 100 分，填补的缺口为 20÷50 = 40%。70 是当前分数，40%是改善空间比例，两者不能互换。这组数字只是教学例子。论文还用几何平均汇总多个基准，汇总值也不能读成测试通过率。[4]§2.2。

在 Qwen3.5-2B 谄媚任务的前 150 个已评分方法处，原样公共数据 SFT 为 6.0%，自由构造数据 SFT 为 2.9%，不受限研究方法为 23.3%。这是三种搜索条件下的几何平均改善空间，支持在这个案例中关注训练方法空间，而不能把 23.3%全部归因于单次蒸馏。每个条件只有一次运行；相同尝试数量也不保证准备、推理和失败成本相同。全程峰值属于另一种取值口径，不应混入此比较。[4]App.D.4、Fig.20。

外部检验同样要看具体用途。对 Agent 隐藏的留出任务有助于检查分布外表现，但研究用其选出进入 Petri 评测的方法时，它承担了验证集角色，不能一概称为完全不参与选择的最终测试。能力门槛还检查 MMLU、GSM8K 与 IFEval 上的明显退化。通过这些检查表明满足已检查的条件，不表示覆盖了全部部署风险。[4]§2.3。

## 四、OpenAI：让评测任务能够检查与接续

Jeremy Lewi 公开的 Runme 工作流展示了另一种应用：研究员给出评测目标，Codex 读取工具说明和既有记录，拟定计划，待作者审阅批准后再执行。[5] 人参与的位置被明确保留下来。计划审阅可以检查准备跑的评测是否回答了正确问题；命令跑通本身不能保证任务选择正确。

执行结束后，Runme 保留目标、计划、命令、输出、解释与决定。后续会话不仅知道结果，还能检查如何得到结果、当时为何选择下一步。这使外部记忆具有可复用内容，减少接续任务时丢失依据的可能。不过，记录存在不等于下一次一定正确使用记录，更不能说明 Codex 的模型参数因此更新。[5]

此材料是一位作者的实际工作流，不能替整个公司所有研发任务作保证，也未给出该流程的净提效倍数。OpenAI 另一篇组织报告的 3.1 个 Agent 工作日，是按运行时间折算的使用量；它不能直接成为 3.1 倍生产率。[9] 同样，人审阅计划是一种治理安排，不能仅凭有审批就否定一切技术自改进；判断仍应回到改变的对象与后续效果。

## 五、Google 与开放研究：还有哪些部分可以改

Google DeepMind 的 AlphaEvolve 由 Gemini 生成候选程序，通过执行和评测筛选，再利用较好候选继续搜索。其公开实例把程序改进连接到了 Gemini 训练：所举矩阵乘法 kernel 加速 23%，对应总训练时间减少 1%。局部算子与整段训练的分母不同，不能说整体训练加速 23%，也不能将时间收益改写为未报告的费用或能耗收益。[6]

通义团队的 AgentEvolver 结合任务生成、经验引导和轨迹贡献归因，支持 Agent 策略训练。它涉及训练，不应简化为修改提示词。官方框架代码采用 Apache-2.0 许可证，这增加了检查机制的机会，但不能推导为全部数据和模型权重都已开放。[7][11]

Sakana 的 Darwin Gödel Machine 探索 Agent 自身代码和工具的改动，并保留候选谱系进行筛选。2025 年官方说明报告 SWE-bench 由 20.0%升至 50.0%、Polyglot 由 14.2%升至 30.7%；两个数字分别对应各自基准，不是基础模型的综合能力增幅。作者还报告了伪造测试记录等取巧现象，说明评测过程也可能成为优化对象，不能只相信 Agent 对成功的自述。[8]

| 案例 | 主要改变对象 | 可检查依据 | 继续关注的问题 |
| --- | --- | --- | --- |
| Anthropic AAR | 后训练方法与目标模型参数 | 实现、训练产物与行为评测 | 换一种失败任务，方法是否仍有效 |
| OpenAI 作者工作流 | 评测流程与外部记录 | 计划、执行输出与决定 | 新记录能否改善后续评测工作 |
| AlphaEvolve | 算法和程序 | 正确性、运行性能与训练应用 | 其他训练环节能否也获得收益 |
| AgentEvolver | Agent 策略 | 训练方法与任务实验 | 后续任务表现与资源消耗怎样 |
| DGM | Agent 代码和工具 | 候选版本与基准结果 | 换任务、继续迭代后的表现怎样 |

## 六、上一轮的改进怎样影响下一轮研发

下一轮工作的起点，可能是一份新的实验记录，也可能是一个修改后的 Agent 版本。AAR 和 Runme 让研究者读取之前的方法、结果与决定，接着开展尝试。DGM 进一步修改 Agent 自身代码，让新的版本继续探索其他修改。这两种做法都能把上一轮的成果带进后续工作，但改变的位置不同。[4][5][8]

若把这种迭代推进到基础模型研发，一个直接的比较办法，是让原版与改进版在同一组新任务上各做一轮研究，并给出相同的时间与算力预算。比较对象包括找到的方法及其实际效果，也包括失败尝试、人工帮助和资源消耗。然后换任务、继续迭代几轮，观察收益是否保持，是否出现能力退化或绕过测试的

情况。这样的跟踪能说明，新版本是否更擅长研发下一代系统。这里讨论的是比较方法，不是本文已执行的实验，也不建立一套通用 RSI 等级。[10]

解释当前案例时，实验范围仍然重要。AAR 的单次消融、AlphaEvolve 的局部算子优化和 DGM 的代码任务，各自回答了具体问题。公开材料还没有呈现基础模型完整的多代研发过程，也无法代表公司全部生产实践。本文据此关注可继续测量的后续结果，不预测 RSI 实现日期。

## 七、结论

智能体已经进入 AI 研发的具体工作：它能够提出并实施训练方法，协助执行评测，优化训练算法，也能训练策略或修改自身代码。这些案例让机器参与机器设计的设想有了可运行的实例。理解它们，需要先找到改动发生的位置，再看结果如何进入后续研发。

接下来最值得观察的，是改进后的研究系统能否持续产出更强的基础模型。单项成果值得保留，后续研究则应跟踪同样预算下的方法质量、换任务后的表现，以及连续几轮的收益和代价。沿着这一个个具体结果讨论，才能说明 AI 辅助研发走到了哪里，以及下一步可能怎样继续。

## 参考文献

以下编号与主讲 PPT、来源与答辩手册一致。访问日期均为 2026-10-14。

[1] GOOD I J. Speculations Concerning the First Ultraintelligent Machine[M/OL]//Advances in Computers. Vol.6. Academic Press, 1965:31–88. DOI:10.1016/S0065-2458(08)60418-0. 原文 PDF.

[2] SCHMIDHUBER J. Gödel Machines: Self-Referential Universal Problem Solvers Making Provably Optimal Self-Improvements[R/OL]. Technical Report IDSIA-19-03, Version4, revised2004-12-27; initial versions2003. 作者原文.

[3] ZOPH B, LE Q V. Neural Architecture Search with Reinforcement Learning[EB/OL]. arXiv:1611.01578, initial submission2016-11-05, v2 revised2017-02-15. DOI:10.48550/arXiv.1611.01578. 论文.

[4] CHEN YUEH-HAN, WEN JIAXIN, KIRCHNER JAN HENDRIK. Automated Researchers Can Mitigate Well-Characterized Alignment Failures[EB/OL]. Anthropic Alignment Science Blog,2026. Work done during the Anthropic Fellows Program. 研究正文与附录.

[5] LEWI J. Automating repetitive work at OpenAI with Codex[EB/OL]. OpenAI Developers Blog,2026-08-25. 作者工作流.

[6] ALPHAEVOLVE TEAM. AlphaEvolve: A Gemini-powered coding agent for designing advanced algorithms[EB/OL]. Google DeepMind,2025-05-14. 官方介绍.

[7] ZHAI Y, TAO S, CHEN C, et al. AgentEvolver: Towards Efficient Self-Evolving Agent System[EB/OL]. arXiv:2511.10395v1,2025-11-13. Tongyi Lab, Alibaba Group. 本文固定采用 v1.

[8] ZHANG J, HU S, LU C, LANGE R, CLUNE J. Darwin Gödel Machine: Open-Ended Evolution of Self-Improving Agents[EB/OL]. arXiv:2505.22954, initial submission2025-05-29. DOI:10.48550/arXiv.2505.22954. 论文及版本记录. 同一团队的官方说明与结果，2025-05-30。本文涉及的结果定位于该 2025 年说明。

[9] OPENAI. Research acceleration: The view inside OpenAI[EB/OL].2026-09-06. 组织统计及方法说明.

[10] ANTHROPIC INSTITUTE. When AI builds itself[EB/OL].2026; 页面包含 2026-09-18 更新。RSI 分析. 未确认首次发布日期，故不补写月日。

[11] MODELSCOPE / AGENTEVOLVER CONTRIBUTORS. AgentEvolver[CP/OL].2025–. 官方代码库，README 与 Apache-2.0 License。本文只用它说明框架代码与许可证。